

Ensino que te conecta

BACHARELADO EM

CIÊNCIA DA COMPUTAÇÃO

SISTEMA AUTÔNOMO DE CAPTURA DE OBJETOS NÃO COOPERATIVOS POR VANTS UTILIZANDO SERVOVISÃO

GABRIEL QUEIROZ TELES

Brasília - DF, 2026

GABRIEL QUEIROZ TELES

SISTEMA AUTÔNOMO DE CAPTURA DE OBJETOS NÃO COOPERATIVOS POR VANTS UTILIZANDO SERVOVISÃO

Undergraduate Thesis submitted in partial fulfillment of the requirements for the degree of Bachelor of at the Brazilian Institute of Education, Development and Research (IDP).

Advisor

Patrícia da Silva Oliveira

Brasília - DF, 2026

GABRIEL QUEIROZ TELES

SISTEMA AUTÔNOMO DE CAPTURA DE OBJETOS NÃO COOPERATIVOS POR VANTS UTILIZANDO SERVOVISÃO

Undergraduate Thesis submitted in partial fulfillment of the requirements for the degree of Bachelor of at the Brazilian Institute of Education, Development and Research (IDP).

Approved on 08/05/2025

Examining Committee

Patrícia da Silva Oliveira (Advisor) - IDP

Dr. Dom Quixote de la Mancha (Internal Member) - IDP

Dra. Anna Karienina (Internal Member) - IDP

DEDICATÓRIA

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

AGRADECIMENTOS

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

ABSTRACT

The autonomous capture of non-cooperative targets by Unmanned Aerial Vehicles (UAVs) faces critical challenges due to the semantic gap of classical vision algorithms and the computational latency that destabilizes the aircraft. To overcome these limitations, this work develops a real-time Position-Based Visual Servoing (PBVS) system for the approach and capture of objects using an underside gripper. The architecture integrates deep learning models from the YOLO family for robust, marker-less target detection. To mitigate occlusions and noise caused by the rotors, an Extended Kalman Filter (EKF) acts in the image plane as a kinematic predictor. The two-dimensional coordinates are converted to metric three-dimensional space via the Pinhole model, feeding a cascaded Proportional-Derivative (PD) flight controller responsible for compensating visual latency. The system was modeled in a Software-in-the-Loop (SITL) simulation environment using ROS and Gazebo. The project targets a visual processing rate above 20 FPS, a 20% reduction in trajectory error (RMSE), overshoot maintenance below 15%, and a final approach precision of 0.30 meters, validating a viable and stable solution for autonomous aerial manipulation.

Keywords: Unmanned Aerial Vehicles. Visual Servoing. YOLO. Kalman Filter. Aerial Manipulation..

RESUMO

A captura autônoma de alvos não cooperativos por Veículos Aéreos Não Tripulados (VANTs) enfrenta desafios críticos devido à lacuna semântica dos algoritmos de visão clássicos e à latência computacional que desestabiliza a aeronave. Para superar essas limitações, este trabalho desenvolve um sistema de Servovisão Baseada em Posição (PBVS) em tempo real para a aproximação e captura de objetos utilizando uma garra inferior (underside). A arquitetura integra modelos de aprendizado profundo da família YOLO para a detecção robusta e sem marcadores do alvo. Para mitigar oclusões e ruídos causados pelos rotores, um Filtro de Kalman Estendido (EKF) atua no plano da imagem como previsor cinemático. As coordenadas bidimensionais são convertidas para o espaço tridimensional métrico via modelo Pinhole, alimentando um controlador de voo Proporcional-Derivativo (PD) em cascata responsável por compensar a latência visual. O sistema foi modelado em ambiente de simulação Software-in-the-Loop (SITL) utilizando ROS e Gazebo. O projeto estabelece como metas o processamento visual superior a 20 FPS, a redução de 20% no erro de trajetória (RMSE), a manutenção do sobressinal (overshoot) abaixo de 15% e uma precisão final de aproximação de 0,30 metros, validando uma solução viável e estável para a manipulação aérea autônoma.

Palavras-chave: Veículos Aéreos Não Tripulados. Servovisão. YOLO. Filtro de Kalman. Manipulação Aérea..

LIST OF FIGURES

1 Eixos de rotação e convenção de atitude angular (rolagem, arfagem e guinada) em um multirrotor 8

2 Disposição motopropulsora e sentidos de rotação das hélices na configuração coaxial Octaquad X 9

3 Diagrama em blocos da arquitetura de hardware e malha inercial de baixo nível do VANT..... 11

4 Arquitetura conceitual da família YOLO, ilustrando a divisão da imagem em grade espacial e a regressão direta das caixas delimitadoras 13

5 Exemplo prático de detecção de alvos em imagens aéreas obtidas por VANT utilizando modelos YOLO 16

6 Fluxograma do algoritmo do Filtro de Kalman Estendido (EKF). 18

7 Exemplo de suporte mecânico estabilizado (*gimbal*) motorizado de três eixos acoplado a uma câmera 20

8 Comparação qualitativa entre os esquemas clássicos de Servovisão Baseada em Imagem (IBVS) e Servovisão Baseada em Posição (PBVS)..... 21

9 Representação geométrica da projeção em perspectiva baseada no modelo de câmera *Pinhole*, ilustrando a conversão de um ponto no espaço para o plano bidimensional da imagem..... 22

10 Classificação dos espaços operacionais e zonas de contato em sistemas de manipulação aérea..... 24

11 Exemplo de sistema de manipulação e captura aérea acoplado diretamente sob a fuselagem de um multirrotor 25

12 Sequência de captura dinâmica e empoleiramento (*perching*) sobre alvo cilíndrico por manobra descendente rápida (*swooping*) 27

13 Sequência temporal da aproximação e captura aérea dinâmica em voo livre utilizando garra macia complacente 28
14 Comparação entre a estimativa do Filtro de Kalman e a saída direta da detecção de objetos para largura e altura da caixa delimitadora..... 31
15 Comparação experimental do erro de rastreamento no plano da imagem entre controlador PID convencional e PID Neural (PID-ANN) sob perturbação de massa de 50% 36
16 Arquitetura geral em malha fechada e fluxo operacional em duas fases do sistema 42
17 Visão geral do ambiente de simulação no Gazebo apresentando o VANT em altitude de busca e o alvo no solo 44
18 Representação tridimensional do VANT OctaQuad X8 com mecanismo de captura ventral e indicação do deslocamento geométrico (*offset*) de 42,16 mm entre a câmera e o dispositivo de engate.. 47
19 Geometria da armadilha de monitoramento de vetores biológicos com dimensões estruturais e disposição angular assimétrica das três alças triangulares de captura..... 48
20 Visão lateral esquemática do acoplamento mecânico terminal entre o gancho ventral do VANT e a alça da armadilha, ilustrando a tolerância vertical dos pés de pouso e o alinhamento de engate..... 49

LIST OF TABLES

1 Análise Comparativa dos Trabalhos Relacionados 37

CONTENTS

1 Introduction 2

2 Literature Review 7

2.1 Theoretical Foundation 7

2.1.1 Veículos Aéreos Não Tripulados (VANTs) 7

2.1.2 Visão Computacional Aplicada a VANTs 11

2.1.3 Servovisão (Visual Servoing) 19

2.1.4 Sistemas de Captura e Manipulação Aérea 23

2.2 Trabalhos Relacionados 26

2.2.1 Captura Autônoma de Objetos por VANTs 26

2.2.2 Detecção e Rastreamento de Alvos em VANTs 30

2.2.3 Servovisão Aplicada a VANTs 33

2.2.4 Análise Comparativa dos Trabalhos Relacionados 36

3 Methodology 41

3.1 Visão Geral e Classificação da Pesquisa 41

3.2 Ambiente de Simulação e Modelagem da Plataforma Aérea 44

4 Results and Discussion 51

5 Conclusion 53

References 54

Appendices 59

Appendix A - Título do apêndice A 60

Annexes 61

A Título do Anexo A 62

Ensino que te **conecta** idp


1

1 INTRODUCTION

O avanço tecnológico dos Veículos Aéreos Não Tripulados (VANTs) aumentou bastante suas possibilidades de aplicação, o que permitiu superar as limitações de mobilidade dos robôs terrestres em tarefas como inspeção, agricultura e transporte de objetos para locais inacessíveis [1]. Com essa evolução, os VANTs deixaram de funcionar só como plataformas de observação e passaram a ser capazes de executar tarefas autônomas que envolvem interação física com o ambiente, como missões de *pick-and-place*, focadas na captura e posicionamento de objetos [2, 3]. A execução autônoma dessas tarefas exige o desenvolvimento de algoritmos de controle que permitam ao robô operar com segurança [1]. Além disso, em ambientes nos quais os sistemas de navegação global (GPS) não oferecem a precisão necessária para o alinhamento de uma garra robótica, o servocontrole visual, também chamado de servovisão, surge como a solução mais viável, utilizando o retorno visual de câmeras embarcadas para orientar o VANT [4].

A captura autônoma de um alvo não cooperativo, como uma gaiola ou um bloco sólido preto sem marcadores visuais, impõe desafios significativos aos métodos clássicos de percepção e à estabilidade da aeronave [5]. A motivação para investigar esse problema está relacionada à vulnerabilidade dos sistemas tradicionais de visão quando operam em ambientes externos e não estruturados [5]. No que diz respeito à percepção, algoritmos baseados exclusivamente em modelos de espaço de cores, como HSV, são altamente sensíveis às variações de iluminação. Da mesma forma, técnicas clássicas de extração de características geométricas, como SIFT, SURF e HOG, combinadas com estratégias de varredura por janelas deslizantes, exigem esforço computacional redundante e apresentam dificuldades para modelar a diversidade dos planos de fundo das imagens [5]. Como consequência, essas abordagens clássicas frequentemente sofrem com a chamada lacuna semântica (*semantic gap*), demonstrando incapacidade de abstrair o contexto da cena, o que leva o sistema a confundir a ausência de luz em um objeto escuro com sombras ou ruídos do próprio ambiente [5].

Em relação ao controle, a servovisão sofre com atrasos, uma vez que o processamento de imagens é computacionalmente intensivo e opera em frequências significativamente inferiores às dos sensores inerciais de voo. Isso resulta em um período de amostragem elevado e, consequentemente, gera intervalos sem retorno visual [4].

Além disso, a estratégia de captura adotada neste trabalho propõe que o VANT se posicione fisicamente sobre o alvo, acomodando a gaiola entre seus trens de pouso, de modo que garras robóticas possam ser alinhadas a pontos específicos de captura. Essa abordagem mecânica exige que o sistema visual forneça não apenas o posicionamento global da estrutura, mas também referências para o alinhamento preciso da orientação (*yaw*) durante a descida.

Diante da necessidade de superar essas limitações tecnológicas, surge a seguinte questão de pesquisa: como algoritmos de detecção baseados em aprendizado profundo podem ser integrados a estratégias de controle dinâmico para realizar a captura autônoma de um alvo não cooperativo por um VANT, mitigando as interferências de iluminação e os atrasos no processamento de imagens e assegurando o alinhamento físico das garras robóticas?

Para contextualizar o problema abordado, este trabalho está inserido no projeto VTS (*Vector Tracking System*), financiado pela Fundação de Apoio à Pesquisa do Distrito Federal (FAPDF) e desenvolvido pelo IDP em parceria com a Universidade de Brasília (UnB) e a Fiocruz. O projeto tem como objetivo central a vigilância e o mapeamento automatizado do mosquito *Aedes aegypti*. Nesse contexto, que envolve diferentes tecnologias, como armadilhas inteligentes, telemetria LoRaWAN, modelos de classificação biológica e aeronaves autônomas, este trabalho concentra-se no desenvolvimento de um sistema de transporte e captura aérea. Enquanto outras frentes do projeto são responsáveis pelo desenvolvimento da eletrônica embarcada e dos sensores das armadilhas, esta pesquisa aborda os mecanismos de percepção visual e controle de voo necessários para que um VANT seja capaz de localizar a estrutura da armadilha, ajustar sua posição e realizar o acoplamento físico de forma autônoma. Com isso, busca-se contribuir para a implantação e o recolhimento desses dispositivos, especialmente em locais remotos ou de difícil acesso.

Para enfrentar os desafios relacionados à detecção, a literatura tem se concentrado cada vez mais em modelos de aprendizado profundo (*Deep Learning*) [6]. Nesse contexto, a família YOLO (*You Only Look Once*) de redes neurais convolucionais destaca-se por realizar a detecção de objetos em uma única passagem pela rede, proporcionando um equilíbrio entre precisão e velocidade de processamento [6–8]. Considerando a evolução dessas arquiteturas e a necessidade de atender às restrições computacionais de sistemas embarcados em VANTs, torna-se relevante investigar o desempenho de diferentes gerações desses modelos. Assim, este trabalho propõe uma avaliação comparativa das arquiteturas YOLOv8n, YOLOv10n, YOLO11n e YOLO26n, buscando identificar aquela que oferece o melhor equilíbrio entre precisão e custo computacional para a detecção embarcada de gaiolas.

Embora as redes neurais ofereçam alta precisão na extração de características semânticas, a percepção visual em VANTs é frequentemente afetada por ruídos dinâmi-

cos. A detecção de objetos com VANTs está sujeita a falhas momentâneas e mudanças abruptas nas caixas delimitadoras devido às vibrações que ocorrem durante o voo [9]. Para atenuar essas falhas e as oscilações ruidosas das redes neurais aplicadas a drones, o filtro de Kalman tem sido utilizado como uma solução eficaz [9]. Essa técnica de estimação permite obter uma aproximação contínua e confiável não apenas da posição do alvo, mas também de sua velocidade cinemática, compensando as deficiências geradas durante períodos de perda do rastreamento visual [9].

Além da filtragem do sinal visual, o referencial espacial adotado para a navegação representa outro desafio. Isso decorre das limitações de implementar o laço de controle do VANT exclusivamente no plano bidimensional da imagem (2D). Quando a navegação se baseia apenas em coordenadas de pixels, o sistema torna-se suscetível à ambiguidade de profundidade e sensível a incertezas geométricas, uma vez que variações de altitude alteram a escala do objeto na imagem capturada pela câmera. Nesse contexto, existem vantagens significativas na aplicação do modelo analítico de câmera Pinhole [10, 11]. O uso de matrizes de transformação geométrica permite converter diretamente as coordenadas dos pixels em um espaço cartesiano métrico tridimensional (3D), reduzindo a sensibilidade a incertezas durante a fase de aproximação e proporcionando uma dinâmica de voo substancialmente mais estável [11].

Com base nesse cenário, a principal hipótese deste trabalho é que a integração de um algoritmo de detecção de objetos para o isolamento semântico de um alvo não cooperativo, operando em série com um filtro de Kalman e uma transformação espacial de 2D para 3D baseada no modelo Pinhole, pode mitigar o ruído visual e permitir o controle de voo estável necessário à execução de um sistema autônomo de captura de objetos utilizando VANTs e servovisão. Além disso, considera-se a hipótese de que, ao fornecer ao laço de controle de um controlador PD (*Proportional-Derivative*) em cascata a velocidade filtrada extraída pelo estimador, o sistema será capaz de compensar os atrasos de amostragem da câmera e suprimir a ultrapassagem do ponto de referência (*overshoot*) causada pelo termo integral tradicional [4, 11, 12].

Diante do exposto, o objetivo geral desta monografia é desenvolver e validar um sistema autônomo de captura de objetos utilizando VANTs e servovisão, visando à busca, à aproximação e ao alinhamento com um objeto não cooperativo para a realização da captura em ambiente simulado. Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos:

- Treinar e comparar quatro gerações da família YOLO (v8n, v10n, v11n e v26n) em duas fases de voo, buscando alcançar uma precisão média ($mAP@50$) superior a 90% na detecção da armadilha e das alças, mantendo o processamento acima de 20 quadros por segundo (20 FPS) para guiar o drone em tempo real;
- Implementar filtros de Kalman para eliminar os tremores da detecção visual e

suavizar a leitura do ângulo de rotação, garantindo que o drone mantenha sua trajetória estável por até 4,0 segundos de predição caso a câmera perca a visão do alvo temporariamente;

- Converter as coordenadas da imagem em distâncias reais em metros e aplicar uma regra de histerese visual (zona segura nos 40% centrais da tela e bloqueio de descida se o erro passar de 60%), garantindo que a armadilha permaneça 100% do tempo dentro do campo de visão da câmera durante a descida de 18 a 2 metros;

- Projetar uma estratégia de voo em cascata (estabilização de atitude a 400 Hz no piloto automático e navegação visual a 20 Hz) que evite oscilações bruscas na aproximação e faça o drone girar autonomamente para se alinhar à tampa da armadilha, atingindo um erro angular de guinada (*Yaw*) inferior a 1,0 grau;

- Validar a missão autônoma completa no simulador, comprovando uma taxa de sucesso superior a 60% no acoplamento, com alinhamento fino cravado sobre o ponto de captura com margem de erro milimétrica (inferior a 8 mm sustentada por 1,5 segundo), seguido de uma descida cega vertical para a conclusão da missão.

A metodologia desta pesquisa caracteriza-se como um estudo de modelagem e validação realizado integralmente em ambiente de simulação. Inicialmente, são coletadas imagens para o treinamento e a avaliação de diferentes arquiteturas de detecção de objetos baseadas em aprendizado profundo (família YOLO), comparando seu desempenho em termos de precisão e custo computacional. Em seguida, é implementado um filtro de Kalman para a estimação de estados e atenuação do ruído visual, bem como uma transformação espacial baseada no modelo de câmera Pinhole com compensação do deslocamento físico da lente para converter coordenadas bidimensionais em distâncias métricas tridimensionais. Posteriormente, é desenvolvida uma estratégia de controle de voo baseada em controladores PD, utilizando as estimativas para orientar a aproximação translacional e o alinhamento angular de guinada (*Yaw*) do VANT em relação ao alvo. Por fim, os componentes são integrados utilizando o ecossistema do ROS 2 para o transporte dos dados de visão da câmera simulada no Gazebo, enquanto a dinâmica de voo é governada pelo piloto automático ArduPilot em arquitetura *Software-in-the-Loop* (SITL). A comunicação de controle e telemetria entre o algoritmo em Python e o firmware ArduPilot é realizada de forma direta pelo protocolo MAVLink (via DroneKit/PyMAVLink), garantindo a troca de comandos de velocidade e estados de navegação em tempo real.



2

2 LITERATURE REVIEW

2.1 THEORETICAL FOUNDATION

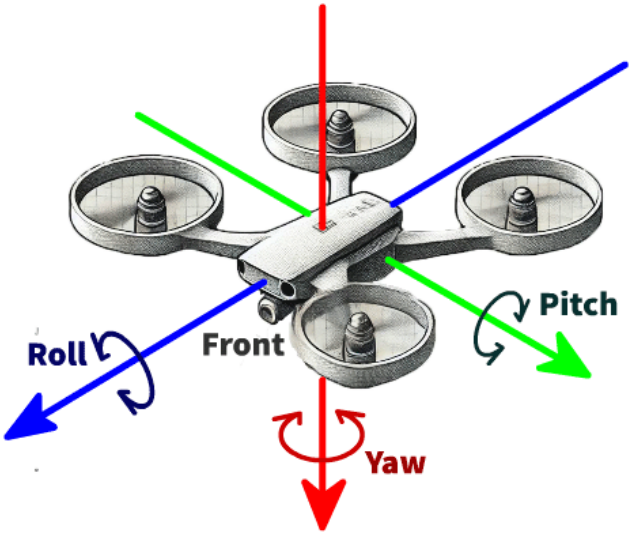
2.1.1 Veículos Aéreos Não Tripulados (VANTs)

Os Veículos Aéreos Não Tripulados (VANTs), popularmente conhecidos como *drones*, são aeronaves projetadas para operar sem a presença de um piloto a bordo. Seu controle pode ser realizado remotamente, por meio de uma estação de controle em solo (*Ground Control Station* – GCS), ou de forma totalmente autônoma, utilizando computadores de bordo e sensores de navegação [13]. Na literatura aeronáutica, essas aeronaves são geralmente classificadas de acordo com seu sistema de sustentação em três categorias: asa fixa, asas rotativas (multirrotores) e configurações híbridas [1]. Os VANTs de asa fixa possuem características semelhantes às de aviões convencionais, apresentando maior autonomia de voo e velocidade de deslocamento. Entretanto, precisam de pistas ou lançadores para operar e não conseguem permanecer parados no ar. Já os VANTs de asas rotativas utilizam a rotação de seus motores e hélices para gerar a força necessária à sustentação. Entre suas principais características estão a capacidade de decolagem e pouso vertical (VTOL, do inglês *Vertical Take-Off and Landing*) e a possibilidade de manter uma posição estável no ar, capacidade conhecida como voo pairado (*hovering*) [3].

Em missões que envolvem manipulação aérea e captura de objetos não cooperativos, a capacidade de manter um voo pairado estável e realizar movimentos precisos em baixas velocidades é fundamental. Essas características permitem alinhar os mecanismos de captura e aproximar a aeronave do objeto de maneira controlada e suave [3, 13, 14]. Para descrever os movimentos e as forças que atuam nessas aeronaves, a literatura utiliza o formalismo de Newton–Euler, que representa o VANT como um corpo rígido em um espaço tridimensional. Essa modelagem considera dois referenciais cartesianos principais: um referencial inercial fixo à Terra (F_0) e outro associado ao centro de massa da aeronave (F_b) [15]. O movimento da aeronave é descrito por seis Graus de Liberdade (6 DoF, do inglês *Degrees of Freedom*), divididos em três movimentos de translação (x, y, z) e três movimentos de rotação, representados pelos ângulos de Euler: rolagem (*roll*, ϕ), arfagem (*pitch*, θ) e guinada (*yaw*, ψ), conforme

apresentado na Figura 1 [16].

Figure 1: Eixos de rotação e convenção de atitude angular (rolagem, arfagem e guinada) em um multirrotor

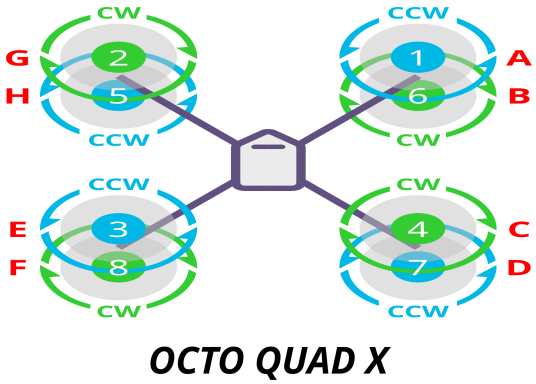


Fonte: adaptado de [17].

A matriz de rotação direcional permite converter as coordenadas do referencial do corpo (F_b) para o referencial inercial (F_0), sendo importante para representar as forças de empuxo e os vetores de velocidade no espaço. Embora o quadricóptero convencional, apresentado na Figura 1, seja frequentemente utilizado como modelo de referência para o estudo da cinemática e das rotações de atitude, missões que envolvem contato físico exigem maior capacidade de carga útil (*payload*) e maior capacidade de geração de empuxo. Isso ocorre devido à necessidade de transportar sensores e mecanismos de captura, como garras robóticas. Nesse contexto, a literatura destaca o uso de configurações coaxiais contra-rotativas, especialmente o arranjo *Octaquad X*, ilustrado na Figura 2 [3, 14].

Nessa configuração, oito motores sem escovas (*brushless*) são distribuídos em pares coaxiais sobre quatro braços mecânicos em X. Em cada braço, as hélices superior e inferior giram em sentidos opostos: horário (*Clockwise* – CW) e anti-horário (*Counter-Clockwise* – CCW). Esse arranjo contra-rotativo compensa os torques de reação do arrasto das pás, eliminando giros indesejados no eixo vertical (z) em voo pairado. O controle coordenado da velocidade dos motores gera os torques de atitude: a guinada (τ_ψ) decorre da diferença entre os conjuntos horários e anti-horários, enquanto a rolagem (τ_ϕ) e a arfagem (τ_θ) resultam do empuxo diferencial entre os braços opostos da estrutura [16].

Figure 2: Disposição motopropulsora e sentidos de rotação das hélices na configuração coaxial Octaquad X



Fonte: adaptado de [18].

Uma das principais dificuldades na modelagem e no controle de sistemas multirrotores está relacionada ao fato de serem sistemas subatuados. Embora possuam seis graus de liberdade de movimento no espaço, esses sistemas contam com apenas quatro entradas de controle independentes: a força de empuxo vertical total e os três torques de atitude ($\tau_\phi, \tau_\theta, \tau_\psi$). Como os vetores de empuxo gerados pelos motores atuam paralelamente ao eixo vertical (z) do corpo da aeronave [16], o VANT não consegue gerar diretamente forças horizontais nos eixos globais x e y. Dessa forma, para se deslocar para frente, para trás ou para os lados durante a aproximação ao alvo, a aeronave precisa inclinar sua estrutura em rolagem ou arfagem. Essa inclinação altera a direção do vetor de empuxo total, fazendo com que parte da força seja direcionada horizontalmente e produza a aceleração necessária ao movimento [3, 16].

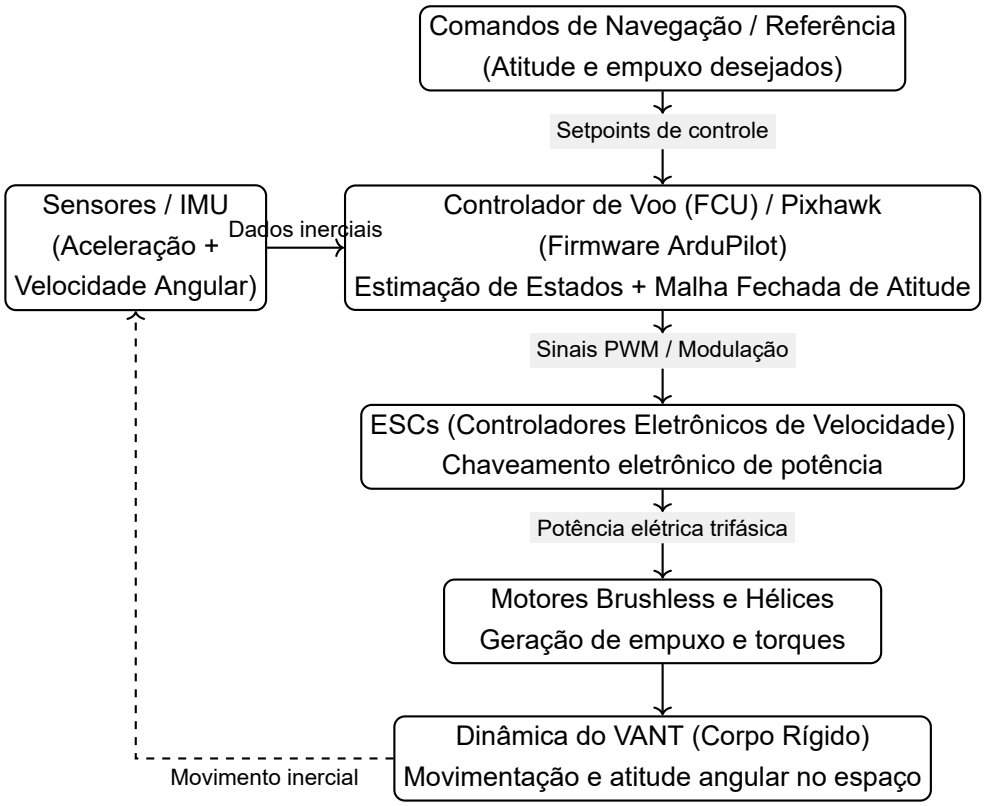
Essa limitação faz com que as variáveis de movimento da aeronave estejam fortemente acopladas, tornando sua dinâmica altamente não linear [19]. Esse comportamento exige atenção especial durante a aproximação final e descida vertical em direção ao alvo, etapa na qual o VANT precisa realizar correções translacionais contínuas em baixas velocidades para garantir o alinhamento da estrutura sobre o ponto de pouso [3]. Como a aeronave precisa inclinar constantemente sua fuselagem em rolagem ou arfagem para efetuar esses deslocamentos horizontais, uma câmera rigidamente fixada à estrutura sofreria oscilações angulares recorrentes. Essas inclinações desviariam o eixo óptico da vertical, distorcendo o enquadramento do alvo e podendo ocasionar sua perda do campo de visão (*Field of View* – FOV). Por esse motivo, recomenda-se o emprego do *gimbal* de três eixos estabilizado ativamente a câmera e garantindo o enquadramento ortogonal e contínuo do alvo durante toda a descida [4].

Para lidar com essas não linearidades e rejeitar distúrbios aerodinâmicos externos,

como rajadas de vento e turbulências em baixas altitudes, a literatura adota estratégias de controle organizadas em cascata [19]. Nesse tipo de arquitetura, a malha interna de controle atua em alta frequência, permitindo corrigir rapidamente pequenos desvios angulares e manter a plataforma inercialmente estável. Essa estabilização é essencial para mitigar vibrações transmitidas ao conjunto óptico, assegurando que a malha externa de servovisão e o modelo de aprendizado profundo recebam imagens nítidas ao longo da aproximação. Para operacionalizar esse esquema em cascata, a arquitetura de hardware e software do robô é dividida em dois níveis de processamento: controle inercial de baixo nível e navegação autônoma de alto nível [4, 16].

O controle inercial de baixo nível é realizado por uma Unidade Controladora de Voo (FCU, do inglês *Flight Control Unit*), sendo o ecossistema Pixhawk uma das plataformas de hardware de código aberto mais utilizadas na robótica aérea [4]. Essa controladora executa firmwares especializados no controle de voo, entre os quais se destaca o ArduPilot [16]. Conforme apresentado no diagrama em blocos da Figura 3, essa arquitetura funciona em malha fechada. A Unidade de Medição Inercial (IMU, do inglês *Inertial Measurement Unit*) mede a aceleração e a velocidade angular da fuselagem em altas taxas de amostragem. Com base nessas informações e nas referências de navegação recebidas do nível superior, a FCU calcula as correções necessárias e envia sinais de modulação por largura de pulso (PWM) aos Controladores Eletrônicos de Velocidade (ESCs, do inglês *Electronic Speed Controllers*). Esses controladores regulam a potência elétrica fornecida aos motores sem escovas (*brushless*), ajustando suas velocidades de rotação. As forças de empuxo geradas pelos motores atuam sobre a estrutura do VANT, permitindo corrigir sua atitude e compensar as perturbações que afetam o voo [16].

Figure 3: Diagrama em blocos da arquitetura de hardware e malha inercial de baixo nível do VANT



Fonte: elaboração própria.

2.1.2 Visão Computacional Aplicada a VANTs

Para viabilizar a aproximação autônoma e a captura de alvos não cooperativos, o sistema de percepção visual atua como o principal mecanismo de identificação e estimação de estados no ambiente. Tradicionalmente, a detecção de objetos baseava-se em métodos clássicos de visão computacional, como a segmentação por cor ou o reconhecimento de padrões geométricos pré-definidos [5]. No espaço de cores HSV (*Hue, Saturation, Value*), por exemplo, a imagem é decomposta em matiz, saturação e brilho para isolar o objeto por contraste de cor. Outra abordagem clássica consiste em extrair características geométricas da cena, como bordas, cantos e texturas, utilizando descritores manuais tradicionais, entre eles SIFT (*Scale-Invariant Feature Transform*), SURF (*Speeded-Up Robust Features*) e HOG (*Histogram of Oriented Gradients*) [5,6].

Com esses descritores geométricos, a detecção geralmente utiliza a técnica de janela deslizante (*sliding window*), que varre a imagem avaliando diversas regiões em diferentes escalas e posições [5,6]. Para cada sub-região amostrada, um classificador supervisionado, como as Máquinas de Vetores de Suporte (SVM, do inglês *Support*

Vector Machines), analisa os atributos extraídos e indica a probabilidade de presença do objeto [5, 6]. O principal inconveniente dessa abordagem reside na rigidez das regras formuladas manualmente, que têm baixa capacidade de generalização diante de mudanças no ambiente. Além disso, avaliar exaustivamente milhares de janelas por quadro impõe um custo computacional muito alto, tornando essa técnica inviável para sistemas aéreos que precisam de respostas rápidas em tempo real [5].

Em ambientes externos, esses métodos clássicos também sofrem com a chamada lacuna semântica (*semantic gap*) [5]. Como operam a partir de características de baixo nível (como pixels, linhas e gradientes locais), os algoritmos não conseguem construir representações conceituais robustas e invariantes do alvo. Em condições reais de voo, com variações constantes de iluminação solar, reflexos e sombras no solo, o sistema torna-se vulnerável a falsos positivos e à perda frequente do objeto rastreado [5].

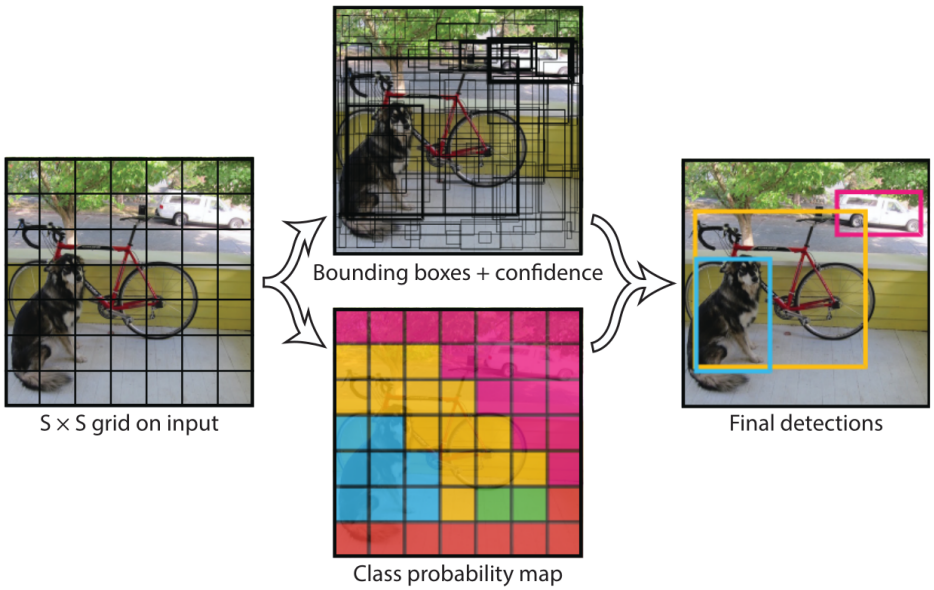
Para contornar as limitações da visão clássica, consolidou-se na literatura o uso de Aprendizado Profundo (*Deep Learning*) por meio de Redes Neurais Convolucionais (CNNs, do inglês *Convolutional Neural Networks*). No campo da detecção de objetos, esses modelos se dividem basicamente em duas categorias: os de dois estágios (*two-stage*), a exemplo da Faster R-CNN, e os de estágio único (*single-stage*) [5, 6, 20]. Os detectores de dois estágios geram inicialmente regiões candidatas de interesse para depois classificá-las e ajustar suas coordenadas. Embora alcancem alta precisão geométrica, esse processamento em etapas consecutivas gera latência elevada, inviabilizando a execução em tempo real nos computadores embarcados de VANTs [6].

Buscando maior velocidade, surgiram detectores de estágio único como o SSD (*Single Shot MultiBox Detector*) e a CenterNet. O SSD, contudo, apresenta dificuldades inerentes na detecção de alvos em escalas reduzidas [6], enquanto a CenterNet, apesar de dispensar caixas âncora, perde robustez quando o fundo da imagem é muito texturizado [21]. Paralelamente, o emprego de *Vision Transformers* (ViTs) e de arquiteturas como o DETR (*Detection Transformer*) trouxe avanços importantes na compreensão global da cena [6]. Entretanto, a alta demanda de operações em ponto flutuante exigida pelos mecanismos de atenção densa reduz drasticamente a taxa de quadros por segundo (FPS) em hardwares embarcados sob restrições Low-SWaP (*Low Size, Weight, and Power*), o que limita sua aplicação direta em malhas críticas de servovisão aérea [22].

Diante dessas restrições de processamento e da necessidade de rastreamento contínuo, a família de algoritmos YOLO (*You Only Look Once*) consolidou-se como a principal escolha na robótica aérea. Diferente dos detectores de dois estágios, o YOLO formula a detecção como um único problema de regressão espacial: em uma única passagem direta (*forward pass*) pela rede, o modelo extrai mapas de características e prevê conjuntamente as coordenadas das caixas delimitadoras (*bounding boxes*) e as probabilidades de cada classe [6, 7]. A Figura 4 ilustra o princípio conceitual da

arquitetura, mostrando a divisão da imagem de entrada em uma grade regular ($S \times S$) para a predição paralela e direta das caixas e de suas confianças [23].

Figure 4: Arquitetura conceitual da família YOLO, ilustrando a divisão da imagem em grade espacial e a regressão direta das caixas delimitadoras



Fonte: adaptado de [23].

Ao longo da evolução dessa família, o YOLOv8, desenvolvido pela Ultralytics, representou uma mudança importante ao adotar uma arquitetura totalmente livre de caixas âncora (*anchor-free*) [20, 24]. Ao dispensar dimensões pré-fixadas de caixas candidatas, o modelo simplifica o treinamento e lida melhor com variações contínuas na escala do alvo, situação frequente durante a aproximação vertical descendente de um VANT [7]. Além disso, a rede passou a separar a tarefa de classificação da regressão de coordenadas, o que melhora a convergência e a precisão das caixas estimadas [7, 24]. Na versão compacta YOLOv8n (*Nano*), o modelo conta com cerca de 3,2 milhões de parâmetros, permitindo taxas de inferência elevadas em computadores de bordo sem introduzir atrasos na malha de controle [7, 25].

Buscando eliminar outros gargalos de processamento, o YOLOv10, proposto por Wang *et al.* [26], abordou a dependência do algoritmo de Supressão de Não-Máximos (NMS, do inglês *Non-Maximum Suppression*) na etapa de pós-processamento. Tradicionalmente, o NMS é necessário para descartar caixas redundantes geradas pela rede, mas sua execução sequencial introduz uma latência variável que pode prejudicar a resposta temporal em sistemas embarcados. Para contornar essa etapa, o YOLOv10 implementou uma estratégia de atribuições duplas durante o treinamento (*Consistent Dual Assignments*), treinando a rede para prever caixas diretas e exclusi-

vas por objeto [26]. Na inferência, o modelo opera de forma puramente ponta a ponta (*end-to-end*) com latência NMS nula. Na versão leve YOLOv10n, a rede opera com cerca de 2,3 milhões de parâmetros em inferência (após o descarte da cabeça auxiliar utilizada no treino), garantindo tempos de ciclo visual constantes e previsíveis [26].

Dando continuidade ao aprimoramento dessas redes, a Ultralytics desenvolveu o YOLO11 (também chamado de YOLOv11), com foco em eficiência computacional e no refinamento da detecção sob condições adversas [27]. Essa versão incorporou mecanismos de autoatenção espacial para orientar a rede a distinguir alvos pequenos contra fundos com padrões visuais complexos, algo típico em imagens capturadas do alto por drones [27, 28]. Na versão ultraleve YOLO11n, a quantidade de parâmetros diminuiu para aproximadamente 2,6 milhões (redução superior a 15% em relação ao modelo v8n), mantendo alta precisão com menor demanda de operações em ponto flutuante (FLOPs) [27, 28].

Mais recentemente, a Ultralytics introduziu o YOLO26 (ou YOLOv26), concebido com foco direto em dispositivos de borda (*edge-first optimization*) [29]. O modelo combina inferência nativa ponta a ponta sem NMS com uma simplificação significativa na sua cabeça de predição, eliminando o cálculo de distribuições discretas de probabilidade para a regressão dos limites das caixas. Com cerca de 2,4 milhões de parâmetros na versão YOLO26n, essa otimização arquitetural reduz acessos à memória e acelera a execução em processadores compactos (CPUs e NPUs), tornando o modelo vantajoso para aeronaves com restrições severas de tamanho, peso e consumo de energia (Low-SWaP).

Para comparar o desempenho de diferentes modelos de detecção de forma objetiva, a literatura e as documentações especializadas empregam métricas padronizadas derivadas da matriz de confusão e da sobreposição geométrica entre predições e anotações reais (*ground truth*) [30, 31]. A métrica geométrica fundamental que define a validade de uma detecção é a Interseção sobre a União (IoU, do inglês *Intersection over Union*), formulada pela Equação (1):

$$\text{IoU} = \frac{\text{Área}(B_p \cap B_{gt})}{\text{Área}(B_p \cup B_{gt})} \tag{1}$$

em que B_p é a caixa delimitadora estimada pelo modelo e B_{gt} representa a caixa de referência correspondente. Define-se então um limiar de corte τ (geralmente $\tau = 0{,}50$): se a detecção corresponder à classe correta e satisfizer IoU $\geq \tau$, ela é considerada um Verdadeiro Positivo (TP). Se o IoU for inferior a τ ou a caixa surgir em uma região de fundo, categoriza-se como Falso Positivo (FP). Já os alvos presentes na imagem que não foram detectados pelo algoritmo constituem os Falsos Negativos (FN) [30].

A partir dessas quantidades, avalia-se a capacidade discriminatória da rede por meio da Precisão (P) e da Revocação (R, do inglês *Recall*), expressas nas Equações (2)

e (3):

$$P = \frac{TP}{TP + FP} \tag{2}$$

$$R = \frac{TP}{TP + FN} \tag{3}$$

A Precisão expressa a proporção de acertos em relação ao total de detecções sinalizadas pelo modelo (penalizando alarmes falsos), enquanto a Revocação avalia a sensibilidade da rede em identificar todos os objetos verdadeiramente presentes na cena (penalizando omissões) [30]. O equilíbrio entre ambas as métricas sob determinado limiar de confiança é avaliado pela média harmônica denominada pontuação F_1 (F_1-*score*), calculada pela Equação (4):

$$F_1 = 2 \cdot \frac{P \cdot R}{P + R} \tag{4}$$

Como os valores de Precisão e Revocação variam ao longo dos limiares de confiança da rede, gera-se a curva de Precisão-Revocação ($P \times R$). A Precisão Média (AP, do inglês *Average Precision*) resume essa curva quantificando a área sob a curva por interpolação, conforme a Equação (5):

$$AP = \int_0^1 p(r)\, dr \tag{5}$$

Para generalizar o desempenho em cenários que envolvem C classes de objetos, calcula-se a Média da Precisão Média (mAP, do inglês *Mean Average Precision*) pela média aritmética dos valores de AP de cada classe, de acordo com a Equação (6):

$$\text{mAP} = \frac{1}{C} \sum_{c=1}^{C} AP_c \tag{6}$$

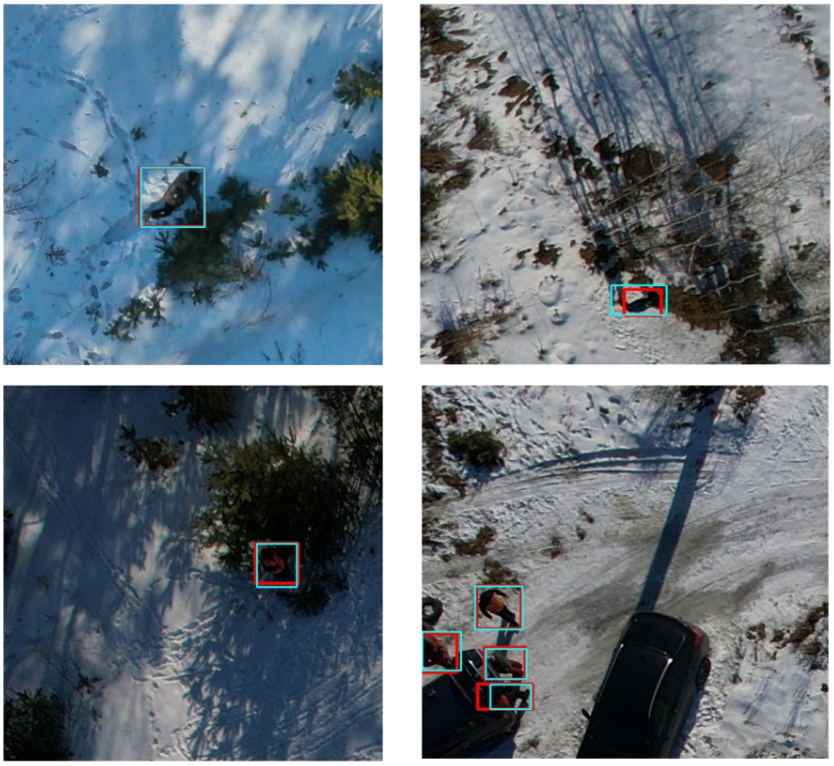
Na literatura e nos padrões do benchmark COCO (*Common Objects in Context*), duas variações de mAP são comumente comparadas [30, 31]:

- mAP@0.5 (ou mAP_{50}): calcula o AP médio fixando o limiar de sobreposição em IoU $\geq 0{,}50$, avaliando a capacidade geral de localização e categorização do alvo;
- mAP@0.5:0.95 (ou mAP_{50-95}): computa a média do mAP em 10 limiares sucessivos de IoU, variando de $0{,}50$ a $0{,}95$ com incrementos discretos de $0{,}05$. Por exigir grande rigor no alinhamento espacial dos limites da caixa sob limiares mais severos, o mAP@0.5:0.95 atua como o principal critério de fidelidade geométrica para tarefas robóticas em que a posição do centroide orienta o guiamento cinemático [31].

Além da acurácia de detecção, a comparação prática de modelos para plataformas aéreas considera parâmetros de eficiência computacional [31]. Entre eles destacam-se o total de parâmetros da rede (*Params*), o volume de cálculos em ponto flutuante (*FLOPs*), a latência média de inferência por quadro (τ_{inf}) e a correspondente taxa de quadros por segundo (FPS $= 1000/\tau_{\text{total}}$), fatores determinantes para viabilizar a execução embarcada sob as restrições Low-SWaP do VANT.

Em testes comparativos recentes voltados à visão computacional embarcada em drones, pesquisas como a conduzida por Zhexebay *et al.* [28] mostram que essas gerações compactas do YOLO mantêm desempenho consistente na detecção de alvos aéreos. Os modelos atingem patamares de mAP@0.5 superiores a 90% operando sob taxas de quadros estáveis, demonstrando maturidade tecnológica para guiamento robótico autônomo. A aplicação prática desses detectores no isolamento e rastreamento de alvos a partir da perspectiva de uma câmera aérea é ilustrada na Figura 5 [28].

Figure 5: Exemplo prático de detecção de alvos em imagens aéreas obtidas por VANT utilizando modelos YOLO



Fonte: adaptado de [28].

Apesar da alta capacidade de reconhecimento das redes convolucionais, a inferência visual durante o voo expõe o sistema a perturbações dinâmicas próprias da

operação aérea. O rastreamento contínuo no plano da imagem fica sujeito a ruídos frequentes, observados na forma de oscilações espúrias na posição do centroide e no tamanho da caixa delimitadora estimada. Esses distúrbios decorrem de vibrações mecânicas propagadas pelos motores, variações residuais de atitude da aeronave e oclusões transitórias provocadas por sombras ou pela passagem de hélices no campo de visão [9]. Uma vez que os controladores de voo exigem sinais de referência contínuos e suaves para evitar sobre-sinais (*overshoot*) e desgastes nos atuadores, os dados brutos de detecção não devem ser aplicados diretamente à malha cinemática.

Para contornar esse problema, a literatura utiliza estimadores estocásticos em cascata temporal com o modelo de aprendizado profundo, destacando-se o Filtro de Kalman. O filtro convencional, no entanto, é restrito a sistemas puramente lineares, o que limita sua aplicação direta em robótica aérea, já que a cinemática relativa entre a câmera do VANT e o alvo envolve projeções de perspectiva geométrica e dinâmicas não lineares no espaço tridimensional. Para contemplar essas características, adota-se o Filtro de Kalman Estendido (EKF, do inglês *Extended Kalman Filter*), que lineariza as equações do sistema a cada instante de amostragem por meio de aproximações em série de Taylor de primeira ordem, utilizando matrizes Jacobianas avaliadas em torno da estimativa corrente [32–34].

O ciclo de estimação do EKF desenvolve-se em duas etapas recursivas principais: a predição e a correção (ou atualização) [32, 33]. A modelagem dinâmica parte de um sistema descrito por um modelo de transição de estados e por um modelo de observação, expressos nas Equações (7) e (8):

$$x_k = M(x_{k-1}) + w_k \tag{7}$$

$$z_k = h(x_k) + v_k \tag{8}$$

em que x_k é o vetor de estado no instante k; $M(\cdot)$ representa a função não linear que descreve a cinemática do sistema; w_k é o vetor de ruído de processo, considerado branco e de média nula; z_k denota o vetor de medições fornecido pelo detector visual; $h(\cdot)$ é a função não linear de observação, responsável por relacionar as variáveis do espaço de estados às coordenadas medidas no plano da imagem; e v_k define o ruído de medição visual associado.

Na etapa de predição, o modelo projeta o comportamento do sistema para o instante seguinte a partir do estado anterior estimado. As equações de predição para o estado *a priori* ($\hat{x}_{k|k-1}$) e para a covariância do erro predita ($P_{k|k-1}$) são formuladas pelas Equações (9) e (10):

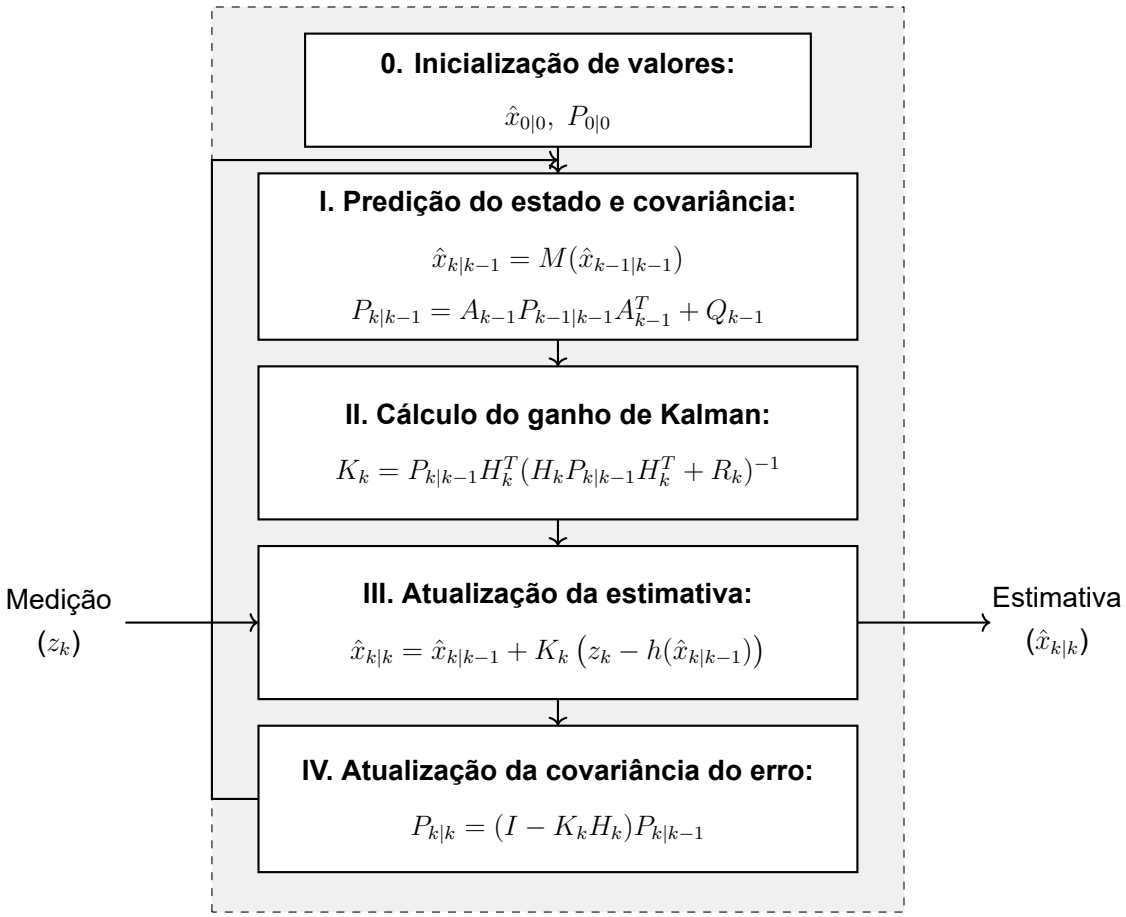
$$\hat{x}_{k|k-1} = M(\hat{x}_{k-1|k-1}) \tag{9}$$

$$P_{k|k-1} = A_{k-1} P_{k-1|k-1} A_{k-1}^T + Q_{k-1} \tag{10}$$

nas quais $\hat{x}_{k-1|k-1}$ e $P_{k-1|k-1}$ representam, respectivamente, o estado e a covariância estimados no passo anterior; A_{k-1} é a matriz Jacobiana associada à função não linear $M(\cdot)$, obtida pelo cálculo das derivadas parciais avaliadas em $\hat{x}_{k-1|k-1}$; e Q_{k-1} é a matriz de covariância do ruído de processo, calibrada para quantificar incertezas na modelagem cinemática e distúrbios externos [33].

Em seguida, na etapa de correção, o filtro incorpora a medição sensorial gerada pela rede neural para refinar a predição e reduzir a incerteza do estado. A dinâmica em malha fechada desse processo cíclico está sintetizada no fluxograma da Figura 6 [33]. O cálculo do Ganho de Kalman (K_k), a correção da estimativa *a posteriori* ($\hat{x}_{k|k}$) e a atualização da covariância do erro ($P_{k|k}$) são definidos pelas Equações (11), (12) e (13):

Figure 6: Fluxograma do algoritmo do Filtro de Kalman Estendido (EKF)



Fonte: adaptado de [33].

$$K_k = P_{k|k-1} H_k^T \left(H_k P_{k|k-1} H_k^T + R_k\right)^{-1} \tag{11}$$

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k \left(z_k - h(\hat{x}_{k|k-1}) \right) \tag{12}$$

$$P_{k|k} = (I - K_k H_k) P_{k|k-1} \tag{13}$$

em que K_k representa o Ganho de Kalman, responsável por balancear a contribuição entre o modelo predito e a nova medição; R_k expressa a matriz de covariância do ruído de medição v_k, calibrada para refletir a dispersão associada à detecção visual; H_k simboliza a matriz Jacobiana da função não linear de observação $h(\cdot)$, calculada a partir de suas derivadas parciais avaliadas em $\hat{x}_{k|k-1}$; $\hat{x}_{k|k}$ é a estimativa corrigida do estado; e $P_{k|k}$ corresponde à matriz de covariância do erro atualizada [33].

Ao atuar como um estimador recursivo no plano da imagem, o EKF atenua oscilações ruidosas causadas por vibrações e suaviza o sinal fornecido ao controlador cinemático. Além disso, nos instantes em que a rede neural falha transitoriamente em detectar o alvo, seja por oclusões breves ou variações bruscas de iluminação, o filtro mantém a estimativa futura com base no histórico de movimento, garantindo a continuidade do guiamento do VANT sem descontinuidades abruptas na malha de servovisão [9, 35].

2.1.3 Servovisão (*Visual Servoing*)

Na robótica autônoma, a servovisão (*Visual Servoing*) destaca-se como a técnica fundamental para guiar a movimentação de um robô por meio da realimentação visual extraída de uma ou mais câmeras em malha fechada [10]. Em sistemas baseados em VANTs, nos quais a navegação pode ocorrer em ambientes sem sinal de GPS ou onde a interação física exige rigor milimétrico, a servovisão atua como o elo direto entre a percepção exteroceptiva e a atuação cinemática da aeronave [4, 36].

A premissa da servovisão baseia-se na minimização contínua de um vetor de erro $e(t)$, definido pela diferença entre o estado atual das características visuais do alvo $s(t)$ e um estado de referência desejado s^* [36,37]. Na formulação analítica clássica, a taxa de variação dessas características relaciona-se à velocidade espacial da câmera por meio da Matriz de Interação, também conhecida como Jacobiano da Imagem (L_s) [38]. Tradicionalmente, leis de controle diferencial recorrem à pseudo-inversa dessa matriz (L_s^+) para calcular velocidades que assegurem um decaimento exponencial do erro visual à medida que a aeronave se aproxima do objeto [36, 38].

A literatura consolida os esquemas de servovisão em duas arquiteturas principais, diferenciadas pelo domínio espacial em que o vetor de erro $e(t)$ é computado: a Servovisão Baseada em Imagem (*Image-Based Visual Servoing*, ou IBVS) e a Servovisão Baseada em Posição (*Position-Based Visual Servoing*, ou PBVS) [10, 39–41].

Na abordagem IBVS (modelo bidimensional), a malha de controle atua diretamente

no plano da imagem utilizando coordenadas em pixels [37]. Embora o IBVS dispense um modelo tridimensional prévio do alvo e apresente boa robustez a incertezas de calibração intrínseca, ele introduz desvantagens importantes na robótica aérea. Devido ao subatuamento típico dos multirrotores, o VANT precisa variar sua inclinação em rolagem ou arfagem para realizar qualquer deslocamento horizontal [10]. Em uma câmera fixada rigidamente ao corpo do drone, essas inclinações geram um efeito de pêndulo óptico que desloca bruscamente a imagem e faz com que o alvo escape com facilidade do campo de visão (*Field of View*, ou FoV) [41]. Para mitigar essa oscilação, a literatura comumente adota suportes mecânicos estabilizados com atuadores independentes (*gimbals*), conforme exemplificado na Figura 7, frequentemente orientados em visada nadir (apontados verticalmente para baixo) [42]. Contudo, a estabilização mecânica por si só não resolve as limitações de trajetória do IBVS, já que, por operar a malha de controle puramente em pixels, o caminho percorrido pelo robô no espaço tridimensional permanece imprevisível, gerando ultrapassagens (*overshoots*) na fase de alinhamento final [37, 41].

Figure 7: Exemplo de suporte mecânico estabilizado (*gimbal*) motorizado de três eixos acoplado a uma câmera

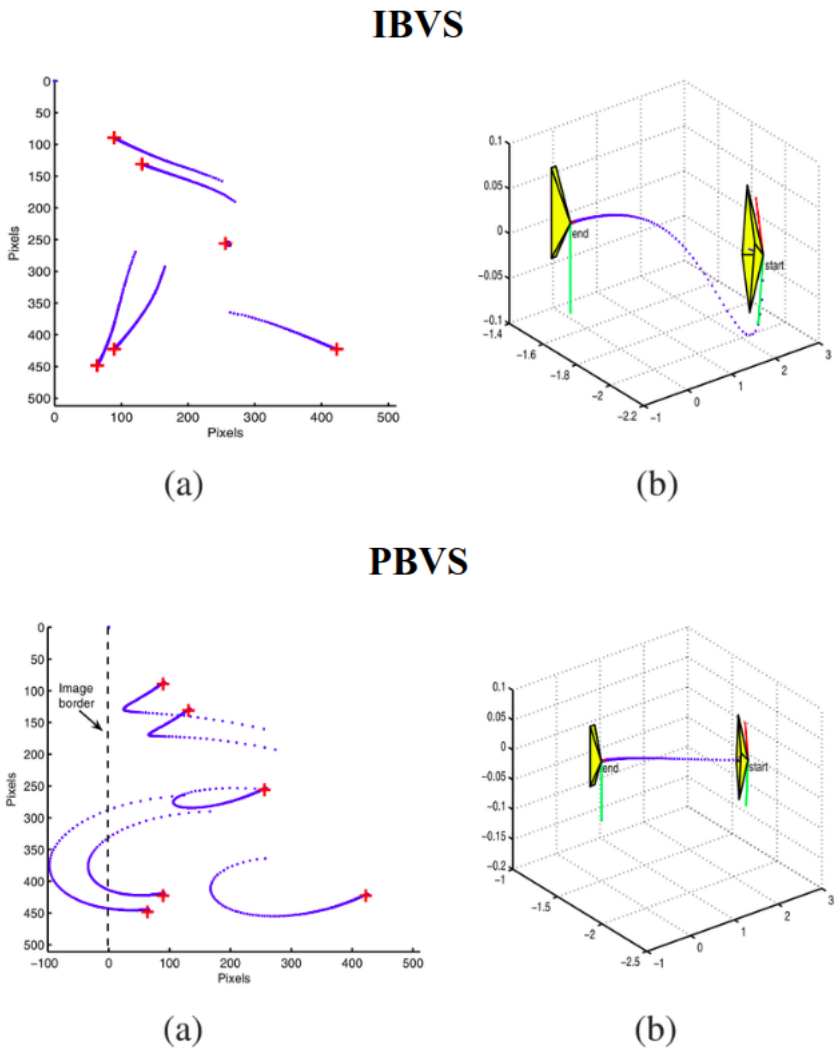


Fonte: TechTudo (2021).

Diante disso, a Servovisão Baseada em Posição (PBVS, com reconstrução tridimensional) surge como uma abordagem mais consistente para aproximações que demandam precisão geométrica. No PBVS, o objetivo de controle não consiste apenas em analisar variações em pixels, mas em estimar a pose métrica (distância e orientação) do alvo em relação à câmera antes de gerar o esforço de controle [10, 41]. A Figura 8 ilustra o contraste qualitativo entre os dois métodos. Enquanto o IBVS tende a

preservar caminhos regulares no plano da imagem ao custo de movimentos espaciais indiretos, o PBVS atua no espaço cartesiano métrico, favorecendo trajetórias retilíneas e previsíveis no ambiente físico [11, 37, 40]. Em contrapartida, como não há restrição direta sobre as coordenadas de pixel, o alvo pode descrever trajetórias mais amplas no plano focal, elevando o risco de escape pelas bordas do campo de visão durante manobras horizontais rápidas [37, 41].

Figure 8: Comparação qualitativa entre os esquemas clássicos de Servovisão Baseada em Imagem (IBVS) e Servovisão Baseada em Posição (PBVS)

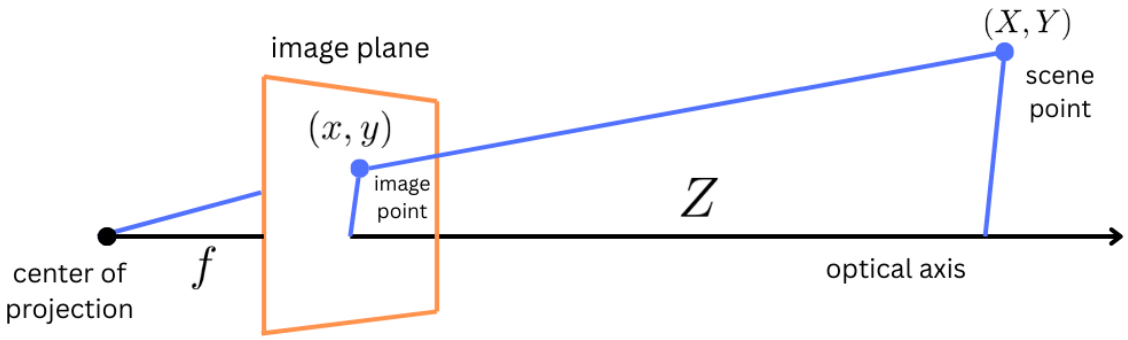


Fonte: adaptado de [41].

A reconstrução tridimensional no PBVS fundamenta-se inicialmente no modelo analítico de projeção perspectiva da câmera *Pinhole*, ilustrado na Figura 9. Esse modelo correlaciona as coordenadas da imagem a um vetor métrico no referencial óptico da

câmera a partir da matriz de calibração intrínseca, que reúne a distância focal e o centro óptico [11, 36, 37]. Conhecendo-se a altitude ou a profundidade relativa em relação ao plano do solo, a projeção inversa do modelo *Pinhole* permite determinar diretamente a posição métrica lateral e longitudinal do alvo no espaço cartesiano [11].

Figure 9: Representação geométrica da projeção em perspectiva baseada no modelo de câmera *Pinhole*, ilustrando a conversão de um ponto no espaço para o plano bidimensional da imagem



Fonte: Björkman (2023), citado por [37].

Ao operar com a visada nadir estabilizada pelo *gimbal*, o plano focal da câmera permanece continuamente paralelo ao plano do solo, neutralizando o efeito de pêndulo óptico durante as manobras [42]. Sob essa geometria perpendicular, a projeção inversa do modelo *Pinhole* decompõe as discrepâncias visuais diretamente nos eixos ortogonais de translação do corpo do VANT [11]. Associando a distância vertical fornecida pela telemetria de altitude aos deslocamentos horizontais métricos (X, Y) e à orientação angular de guinada (*yaw*) extraída do formato do alvo, o sistema recupera a pose relativa completa necessária para a malha de controle, dispensando o cálculo de matrizes complexas de transformação angular em tempo real.

Para conciliar a previsibilidade cartesiana do PBVS com a garantia de visibilidade contínua, a literatura recorre a esquemas de servovisão comutada ou particionada sob restrições de campo de visão (*FoV constraints*) [37, 41]. Nessa estratégia, o avanço translacional ou a taxa de descida vertical é condicionado à permanência do erro visual dentro de uma região delimitada no plano focal. Caso manobras horizontais aproximem o alvo das bordas da imagem, a aproximação vertical é pausada para priorizar a centralização no plano, retomando a descida assim que o enquadramento for restabelecido [41].

Por fim, a integração computacional de inferência visual, filtragem de estados e reconstrução métrica introduz atrasos de processamento que inviabilizam o fechamento da malha diretamente no microcontrolador de baixo nível do piloto automático [36].

Como solução de engenharia consolidada, adota-se uma arquitetura de controle em cascata com separação temporal [4, 16]:

1. **Malha Externa (Cinemática):** Executada em um computador de bordo auxiliar (*companion computer*) integrado ao ecossistema ROS, operando a uma taxa moderada compatível com a visão (tipicamente entre 15 e 30 Hz) [16]. Essa camada calcula o erro cartesiano reconstruído e emprega controladores cinemáticos lineares. Para compensar o atraso de transporte introduzido pela aquisição de imagem e inferência, controladores Proporcionais-Derivativos (PD) são amplamente adotados, conferindo amortecimento ativo e evitando a saturação e as oscilações cíclicas (*overshoots*) provocadas pelo acúmulo de atraso do termo integrativo [1, 4].

2. **Malha Interna (Dinâmica):** Os sinais de velocidade linear e de taxa angular calculados na malha externa são enviados via protocolo de comunicação serial (como MAVLink/MAVROS) ao piloto automático de baixo nível (como a placa Pixhawk operando ArduPilot) [4, 16]. O firmware, operando em alta frequência (400 Hz), encarrega-se da estabilização inercial rápida de atitude (rolagem, arfagem e guinada) e da distribuição de comandos aos motores.

Essa estrutura consolida a servovisão como o sistema de guiamento de alto nível da aeronave, combinando a precisão espacial da visão tridimensional com a robustez e a estabilidade inercial do piloto automático.

2.1.4 Sistemas de Captura e Manipulação Aérea

Historicamente, a atuação dos Veículos Aéreos Não Tripulados concentrou-se em missões de sensoriamento e observação remota passiva. A necessidade de interagir fisicamente com o ambiente impulsionou o desenvolvimento dos Manipuladores Aéreos Não Tripulados (*Unmanned Aerial Manipulators*, ou UAMs), plataformas compostas por uma aeronave acoplada a mecanismos projetados para prender, transportar e posicionar cargas (*pick-and-place*) [2, 13, 14]. No contexto de missões de captura de dispositivos no solo, como armadilhas e sensores autônomos em áreas remotas ou de difícil acesso, a captura aérea exige a transição rápida do voo livre para o contato físico com alvos estáticos e não cooperativos [3, 13].

Na literatura de manipulação aérea, diferentes configurações mecânicas são investigadas para viabilizar essa interação, desde cabos suspensos e guinchos até braços robóticos articulados de múltiplos graus de liberdade (multi-DoF) [13, 43]. Contudo, para aeronaves multirrotores operando sob restrições severas de carga útil (*payload*), esses sistemas introduzem complexidades críticas. Braços articulados pesados deslocam dinamicamente o centro de gravidade (CoG) do robô a cada movimento de junta, gerando torques inerciais acoplados que sobrecarregam os controladores de atitude

da aeronave [13, 14]. Por sua vez, mecanismos suspensos por cabos mitigam a interferência aerodinâmica do fluxo descendente (*downwash*), mas induzem oscilações pendulares na carga e são incapazes de transmitir torque em guinada (*yaw*), inviabilizando o alinhamento angular com alvos que demandam encaixe em uma orientação geométrica específica [43].

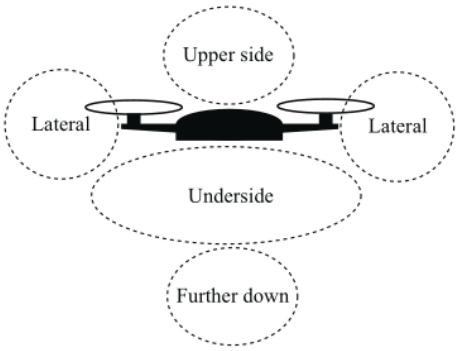
Diante dessas limitações, a literatura classifica o espaço de trabalho da manipulação aérea em três zonas operacionais principais de contato, conforme ilustrado na Figura 10 [43]:

1. **Captura Ventral (*Underside*):** Configuração padrão para a recuperação de cargas situadas no solo ou em plataformas horizontais abaixo do nível de voo do VANT [43];

2. **Captura Dorsal (*Upper-side*):** Mecanismos instalados no topo da aeronave para interagir com estruturas elevadas, tetos ou operações de fixação e pouso invertido (*perching*) sob pontes e vigas, onde os rotores representariam um obstáculo mecânico [14, 43];

3. **Captura Lateral (*Lateral-side*):** Projetada para atuar em superfícies verticais, como fachadas de edifícios, exigindo hastes extensoras que mantenham os rotores afastados da parede para prevenir colisões [43].

Figure 10: Classificação dos espaços operacionais e zonas de contato em sistemas de manipulação aérea

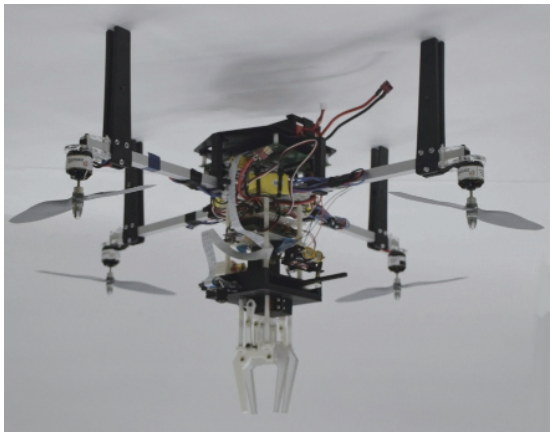


Fonte: adaptado de Ladig *et al.* [43].

Como o objetivo deste trabalho concentra-se no resgate de armadilhas pousadas na superfície, a abordagem mais eficiente consiste na adoção da zona ventral (*underside*), empregando garras mecânicas ou interfaces de engate posicionadas diretamente sob a fuselagem da aeronave [14, 43]. A Figura 11 ilustra um sistema representativo dessa classe de manipulação acoplada diretamente à base do VANT. Posicionar

o mecanismo de contato próximo ao Centro de Massa (CoM) e acomodar a carga simetricamente entre os trens de pouso minimiza as variações nos momentos de inércia durante o voo [14, 46]. Enquanto garras ativas dependem de servomotores elétricos ou atuadores pneumáticos para fechar mandíbulas sobre o objeto [45, 46], interfaces mecânicas de engate passivo ou guiado (*latches* e guias cônicas) dispensam atuadores dedicados, aproveitando a própria descida controlada da aeronave para travar o acoplamento [14, 44]. Essa abordagem elimina peso morto na aeronave e transfere a responsabilidade do sucesso da captura para a precisão milimétrica da malha de servovisão.

Figure 11: Exemplo de sistema de manipulação e captura aérea acoplado diretamente sob a fuselagem de um multirrotor



Fonte: adaptado de Ubellacker *et al.* [46].

A fase terminal de acoplamento sobre o solo impõe restrições aerodinâmicas particulares. À medida que o multirrotor se aproxima da superfície a altitudes inferiores ao diâmetro de seus rotores, manifesta-se o efeito solo (*Ground Effect*), no qual o fluxo de ar descendente acelerado pelas hélices (*downwash*) rebate no solo e no topo da carga, gerando recirculações turbulentas e sustentação assimétrica [13, 43]. Essas correntes ascendentes podem empurrar alvos mais leves ou induzir perturbações de atitude na aeronave instantes antes do contato [43, 44]. Para assegurar o acoplamento sem sofrer derivas induzidas pela turbulência de solo, a literatura recomenda conduzir o alinhamento fino em uma altitude de espera (*hover*) controlada e realizar a aproximação terminal por meio de uma descida contínua e firme, reduzindo o tempo de exposição à camada de recirculação de ar [14, 46].

Por fim, a aproximação milimétrica introduz desafios práticos para o sistema de visão. Ao chegar muito perto da armadilha, o alvo passa a ocupar quase todo o campo de visão da câmera e pode sofrer com a sombra projetada pelo próprio drone e pelos trens de pouso [45,46]. Para contornar essa perda de visibilidade, o sistema precisa co-

ordenar a aproximação em etapas, utilizando a servovisão para garantir o alinhamento fino em translação (X, Y, Z) e em guinada (*yaw*) ainda a uma distância segura, para então concluir o acoplamento físico por meio de uma descida vertical guiada pela estabilidade da aeronave [44, 46].

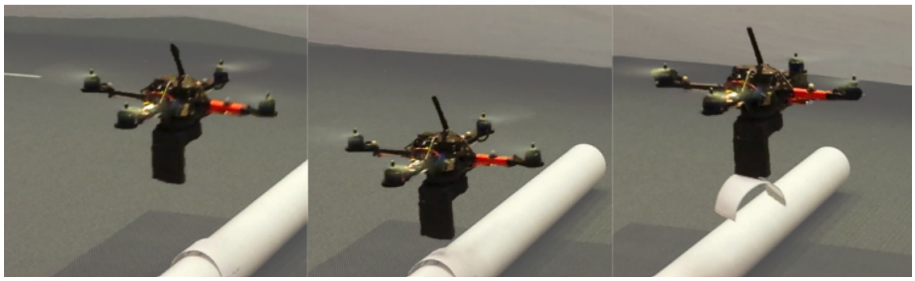
2.2 TRABALHOS RELACIONADOS

2.2.1 Captura Autônoma de Objetos por VANTs

O trabalho pioneiro desenvolvido por Thomas *et al.* [44] investigou o desafio de realizar manobras dinâmicas de aproximação e pouso (*perching*) de microveículos aéreos sobre estruturas cilíndricas elevadas. Em operações convencionais, a manipulação aérea apoia-se em braços robóticos articulados de múltiplos graus de liberdade, cuja massa elevada e consumo energético reduzem drasticamente a autonomia de voo e introduzem acoplamentos inerciais severos na aeronave. Para contornar essa restrição, os autores inspiraram-se nos mecanismos biomecânicos adotados por aves de rapina durante a caça, projetando uma estratégia na qual a energia cinética e a própria aceleração de aproximação do VANT são convertidas em esforço de fixação mecânica.

A arquitetura experimental foi estruturada em torno de um quadirrotor leve de 388 g equipado com um mecanismo de fixação passivo montado na base, totalizando uma massa de 866 g com carga útil. A garra mecânica incorpora mandíbulas complacentes que disparam o travamento instantâneo por contato físico mecânico, dispensando motores ou servomecanismos elétricos dedicados. O guiamento terminal da aeronave foi executado por uma malha de servovisão baseada em imagem (IBVS), formulada a partir das restrições geométricas tangentes projetadas pela silhueta do cilindro no plano óptico da câmera frontal, com o auxílio de câmeras externas de laboratório (MOCAP) para a estabilização inercial de guinada e eixos laterais. A Figura 12 ilustra a sequência temporal da manobra descendente e rápida (*swooping*) executada pelo sistema durante a captura do alvo.

Figure 12: Sequência de captura dinâmica e empoleiramento (*perching*) sobre alvo cilíndrico por manobra descendente rápida (*swooping*)



Fonte: adaptado de Thomas *et al.* [44].

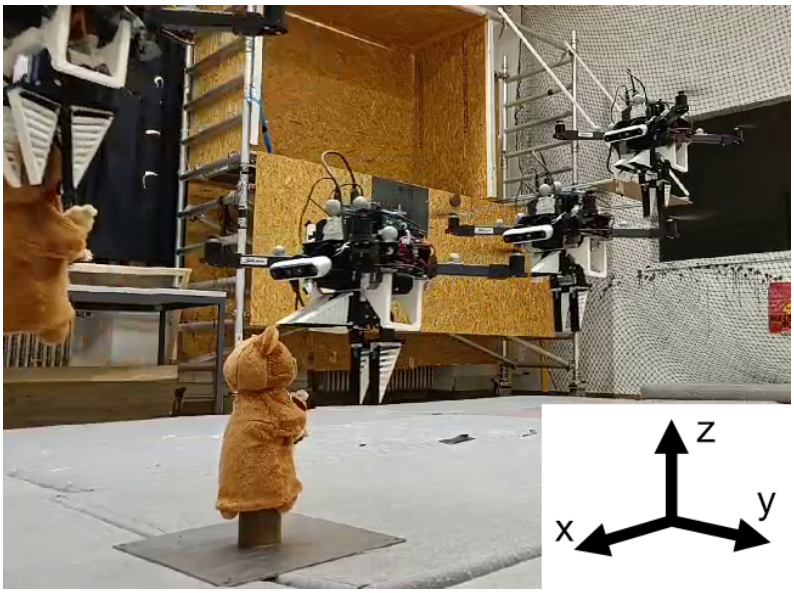
Nos ensaios empíricos em bancada de voo livre, o sistema validou a captura de corpos cilíndricos com massa de 77 g operando sob velocidades de voo de 1,0 m/s a 3,0 m/s (equivalente a cerca de 9 comprimentos de fuselagem por segundo), obtendo uma taxa de sucesso mecânico de 100% nas tentativas executadas. Os resultados demonstraram que o mecanismo passivo suporta o impacto dinâmico e assegura a sustentação do robô no alvo, viabilizando o corte integral da alimentação dos quatro rotores e eliminando o consumo elétrico durante o monitoramento estacionário. Entretanto, os próprios pesquisadores ressaltaram que a dependência de um sistema MOCAP estruturado em ambiente fechado restringe a aplicação direta dessa técnica em cenários operacionais externos não instrumentados.

Bauer *et al.* [45] avançaram no estado da arte ao investigar a captura aérea dinâmica de objetos não cooperativos em voo livre, eliminando integralmente o uso de marcadores fiduciais artificiais (como códigos ArUco ou AprilTags). Em trajetórias de alta velocidade, impactos mecânicos imprevistos contra alvos desconhecidos representam riscos de fratura estrutural aos atuadores rígidos e desestabilizam violentamente os controladores de atitude da aeronave. Além disso, a presença de perturbações aerodinâmicas e a latência de processamento visual tendem a gerar pequenas discrepâncias na estimativa de posição métrica durante a fase terminal de acoplamento.

Para solucionar essas dificuldades, a plataforma aérea (um quadirrotor de porte médio) foi equipada com uma garra macia complacente (*soft gripper*) baseada em polímeros flexíveis, instalada na parte ventral do chassi. O subsistema de percepção operou com uma câmera de profundidade embarcada Intel RealSense, responsável por transmitir pares sincronizados de imagens coloridas e mapas de profundidade via enlace sem fio de baixa latência para uma estação em solo dotada de GPU NVIDIA GeForce RTX 3070. Nessa estação, uma rede neural convolucional de segmentação de instâncias (Mask R-CNN) isolou a máscara geométrica do alvo em tempo real, fornecendo os dados para um estimador de geometria tridimensional que sintetizou

nuvens de pontos e definiu o vetor ideal de aproximação. A evolução temporal do processo de guiamento e fechamento passivo da garra complacente durante o voo livre é apresentada na Figura 13.

Figure 13: Sequência temporal da aproximação e captura aérea dinâmica em voo livre utilizando garra macia complacente



Fonte: adaptado de Bauer *et al.* [45].

Em baterias de testes experimentais envolvendo alvos com diferentes formas, texturas e massas (incluindo garrafas plásticas de 220 g, peças de isopor e bichos de pelúcia), o sistema computou a segmentação e a estimativa de pose com uma latência média de 42 ms por quadro (taxa de atualização de 23,8 FPS). Em voo autônomo, o algoritmo alcançou uma taxa global de sucesso na captura de 89%, equivalente a 94,5% do índice de referência obtido sob infraestrutura laboratorial de câmeras MOCAP. Os dados confirmaram que a complacência mecânica dos dedos flexíveis foi capaz de tolerar erros de alinhamento residual de até ± 25 mm no instante do toque, absorvendo o choque físico sem transferir momentos destrutivos à fuselagem do robô.

No trabalho de Ubellacker *et al.* [46], os autores enfrentaram o desafio de conceber um manipulador aéreo macio capaz de realizar interceptações em alta velocidade dependendo estritamente de sensores e processamento embarcados, eliminando qualquer comunicação com estações de solo ou sistemas MOCAP externos. O foco central consistiu em assegurar que as restrições estritas de campo de visão da câmera fossem rigorosamente respeitadas durante trajetórias agressivas de aproximação, impedindo a perda de visibilidade do objeto em manobras rápidas.

A aeronave utilizada, denominada *Soft Drone*, foi construída com quatro rotores

e dotada de uma garra complacente com fechamento passivo baseado em tendões elásticos, mantida aberta ativamente por servomotores apenas até a detecção do contato físico. O sensoriamento baseou-se em uma câmera estéreo frontal acoplada a um computador de bordo compacto, onde uma rede neural convolucional especializada na detecção de pontos-chave (*keypoints*) estimou a posição tridimensional e a orientação da carga a partir da imagem direta. Essa estimativa alimentou em tempo real um planejador de trajetória polinomial de tranco mínimo (*minimum-snap*), o qual incorporou as restrições de campo focal da câmera como inequações matemáticas no espaço de estados, garantindo que o eixo óptico permanecesse continuamente orientado para o alvo durante as acelerações de descida.

Nos testes práticos com alvos estáticos em ambientes externos, o sistema registrou um desempenho perfeito de 100% de sucesso na captura de garrafas plásticas (10 capturas em 10 tentativas) e de 90% para caixas de kits médicos (9 capturas em 10 tentativas) sob velocidade de aproximação terminal de 0,5 m/s. Em ensaios dinâmicos com a carga fixada no topo de um robô quadrúpede deslocando-se a 0,3 m/s, a taxa de sucesso manteve-se em 80%. Entretanto, ao forçar a velocidade relativa de interceptação para o patamar agressivo de 2,0 m/s, o índice de sucesso sofreu uma queda abrupta para 30% (3 em 10 ensaios). A análise pós-teste demonstrou que essa degradação resultou do acúmulo de atrasos no pipeline de inferência dos pontos-chave, gerando derivas métricas superiores à largura útil de engate da garra e comprovando que velocidades excessivas comprometem a integridade da malha de controle puramente embarcada.

Luo *et al.* [38] propuseram uma metodologia de manipulação aérea em malha fechada guiada exclusivamente por características visuais naturais presentes na superfície do objeto, descartando qualquer padrão fiducial artificial. Os autores observaram que, embora garras acopladas diretamente à fuselagem simplifiquem a estrutura mecânica, a necessidade de mover o drone inteiro para efetuar correções milimétricas sujeita a aproximação final às turbulências aerodinâmicas do fluxo descendente das hélices sobre o solo.

A plataforma desenvolvida foi composta por um hexarrotor de grande porte equipado com um braço robótico articulado leve de 6 graus de liberdade (6-DoF), com peso total de 0,9 kg, fixado em posição ventral. Uma câmera monocular foi instalada diretamente na extremidade do manipulador (*eye-in-hand*), sendo processada a bordo por um computador Intel NUC acoplado ao controlador de voo. A estratégia de controle foi particionada em três estágios sucessivos: navegação global por GPS a partir de 3,0 m de distância; transição para voo pairado (*hover*) estabilizado ao atingir 0,4 m (40 cm) do alvo; e acionamento da malha de servovisão visual do braço robótico. Nessa última etapa, um extrator de características naturais ORB combinado ao algoritmo RANSAC selecionou e acompanhou pontos salientes de textura, mapeando o erro visual em

velocidades articulares por meio da matriz Jacobiana do manipulador.

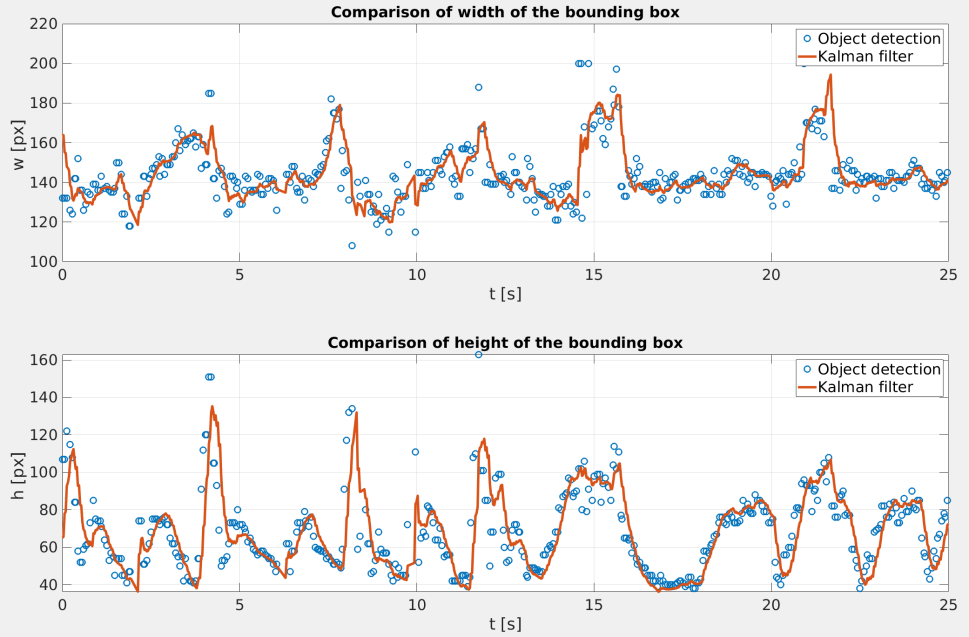
Nos ensaios experimentais com caixas e objetos texturizados dispostos no solo, o sistema convergiu com alta estabilidade, conduzindo a ferramenta terminal de 40 cm para a distância de acoplamento de 20 cm com um erro posicional cartesiano final inferior a 5,0 mm. Essa precisão geométrica permitiu o acionamento confiável do efetuador de sucção, garantindo 100% de êxito na fixação e subsequente içamento da carga. Não obstante a alta precisão alcançada, os autores destacaram que a presença do manipulador multiarticulado adiciona inércia significativa ao robô e que o método de características ORB perde eficácia em superfícies reflexivas, metálicas ou com texturas uniformes, ressaltando a relevância de detectores baseados em redes neurais profundas para alvos homogêneos.

2.2.2 Detecção e Rastreamento de Alvos em VANTs

O problema de localizar, acompanhar e seguir continuamente um alvo dinâmico no ar foi investigado por Barisic *et al.* [9]. Em aplicações que envolvem a perseguição de aeronaves ou o alinhamento com estruturas sob vibração constante, os algoritmos de visão de máquina enfrentam severas oscilações nas dimensões e na posição do centroide estimado, decorrentes de acelerações bruscas, turbulências mecânicas propagadas pelas pás e variações rápidas de escala no plano de projeção.

Para viabilizar a detecção em tempo real sob limitações estritas de hardware embarcado, os pesquisadores implementaram e treinaram uma rede neural convolucional YOLOv3-Tiny a partir de um conjunto de dados composto por 10.000 imagens aéreas anotadas. Com o intuito de filtrar as dispersões espaciais geradas pela saída da rede, os autores acoplaram um Filtro de Kalman Discreto formulado no espaço de estados para estimar conjuntamente oito variáveis contínuas: as coordenadas centrais do retângulo delimitador (x_c, y_c), sua largura (w), sua altura (h) e as quatro taxas de variação temporal correspondentes. A eficácia da filtragem na suavização dos sinais e na mitigação de picos espúrios de detecção é ilustrada na Figura 14.

Figure 14: Comparação entre a estimativa do Filtro de Kalman e a saída direta da detecção de objetos para largura e altura da caixa delimitadora



Fonte: adaptado de Barisic *et al.* [9].

Nos ensaios de validação em voo, a rede YOLOv3-Tiny operou em regime contínuo a uma taxa de 20 quadros por segundo (20 FPS) a bordo do computador de bordo, atingindo uma precisão média (mAP) de 97,88%. A introdução do Filtro de Kalman reduziu a variância de ruído de alta frequência nas dimensões das caixas delimitadoras em mais de 60%, eliminando falsas perdas de rastreamento decorrentes da oclusão periódica de hélices no campo visual e permitindo à aeronave seguidora manter o alvo centrado durante trajetórias agressivas em formato de oito.

A mitigação do fenômeno de deriva de rastreamento visual (*camera drift*) em sequências contínuas de vídeo foi o tema central do trabalho de Vidal e Casanova [35]. Esse erro crítico manifesta-se quando algoritmos clássicos de casamento de padrões perdem a referência semântica do alvo e passam a rastrear falsas texturas do fundo, bordas de sombras móveis ou elementos de alta frequência no cenário, degradando progressivamente a malha de controle do robô.

Para solucionar essa fragilidade em ambientes dinâmicos, os autores desenvolveram uma metodologia preditiva que combinou técnicas de correspondência por janelas deslizantes (*Window-Matching*) em múltiplas escalas (matrizes de 15×15 e 50×50 pixels) a um Filtro de Kalman linear recursivo. O fluxo de vídeo foi processado na resolução de 320×240 pixels, com o modelo dinâmico do filtro projetando a região de busca prioritária para o quadro subsequente, reduzindo drasticamente o espaço de

varredura computacional e prevenindo saltos abruptos de posição.

Os testes de campo abrangeram múltiplos cenários desafiadores, incluindo o rastreamento de veículos automotores em cruzamentos com iluminação variável, pedestres caminhando sob oclusão temporária e garrafas flutuando na superfície marítima sujeitas à ondulação de ondas. Nos experimentos, os detectores baseados puramente em casamento de janelas divergiram e perderam o alvo em menos de 10 quadros consecutivos devido às mudanças locais de contraste. Em contrapartida, a malha integrada com o Filtro de Kalman manteve o acompanhamento contínuo e estável ao longo de oclusões parciais e totais de até 25 quadros sucessivos, retendo o erro médio de desvio espacial abaixo de 3,2 pixels e comprovando a robustez de estimadores estocásticos na sustentação da coerência temporal da percepção.

Na busca por aprimorar a capacidade de reconhecimento em imagens aéreas obtidas em grandes altitudes ou distâncias elevadas, Shen *et al.* [47] desenvolveram o modelo neural DS-YOLOv8. Em missões de busca e resgate conduzidas por drones, alvos de pequenas dimensões ocupam poucas dezenas de pixels na imagem e sofrem com a atenuação de gradientes visuais, fazendo com que detectores convolucionais convencionais percam capacidade discriminatória ao aplicar sucessivas camadas de agrupamento (*pooling*) e redução espacial de escala.

Para superar esse gargalo, os autores modificaram a espinha dorsal (*backbone*) e a rede de agregação de características do YOLOv8 por meio de divisões convolucionais em canais densos (*Dense Channel Splitting*). Essa reestruturação direcionou ramificações de processamento dedicadas à preservação de mapas de características superficiais de altíssima resolução, acoplando mecanismos de convolução com parâmetros compartilhados para evitar a explosão do volume computacional da rede.

A validação em bases de dados públicas de imagens aéreas e sensoriamento remoto demonstrou que o DS-YOLOv8 superou expressivamente os modelos concorrentes, alcançando uma Precisão Média ($mAP@50$) de 91,0% e um índice F_1-score de 90,4%. Nos testes focados em alvos ultracompactos, com área geométrica inferior a 16×16 pixels, o modelo apresentou um ganho de precisão de 3,8% em relação ao YOLOv8 padrão, mantendo um tempo de inferência de 14,2 ms por quadro em processadores de borda e garantindo viabilidade para identificação precoce de cargas em altitudes seguras de aproximação.

Investigando o isolamento de alvos não cooperativos em ambientes com restrições severas de peso, volume e consumo de energia (*Low-SWaP*), Zhang *et al.* [48] propuseram a rede neural leve LCNN-DMT. Um dos problemas documentados em missões de acoplamento com objetos não estruturados (como satélites ou equipamentos industriais) reside na fragmentação indevida de detecções, na qual subcomponentes salientes (painéis, suportes ou baterias) são interpretados erroneamente pelo modelo de aprendizado profundo como múltiplos objetos independentes, dispersando o cálculo

do centroide.

Para sanar essa inconsistência, a arquitetura integrou uma rede convolucional leve baseada na topologia SqueezeNet, modificada por módulos de atenção visual espacial, a um algoritmo inovador de mesclagem e supressão de caixas redundantes denominado MBRT-D (*Multi-Box Reduction Technique*). Esse algoritmo analisa a conectividade topológica e a geometria global do artefato, unificando caixas parciais em um único invólucro circunscrito que encapsula o centro de massa geométrico real do conjunto.

Os experimentos quantitativos comprovaram que o modelo LCNN-DMT atingiu uma precisão média (mAP) de 97,50%, superando redes tradicionais de grande porte como Faster R-CNN (89,17%) e T-SCNN (86,64%). Em termos de custo operacional embarcado, o modelo destacou-se pelo perfil ultra-eficiente: consumo computacional de apenas 0,464 GFLOPs, total de 0,928 milhão de parâmetros e latência média de inferência de apenas 6,1 ms por quadro. Esses parâmetros confirmam que a combinação de espinhas dorsais leves com módulos de atenção visual é capaz de fornecer alta precisão métrica sem sobrecarregar os recursos limitados de baterias e processadores em drones.

2.2.3 Servovisão Aplicada a VANTs

No domínio do guiamento em malha fechada para contato físico, Pramono [37] investigou uma arquitetura híbrida de servovisão combinada a Controle Preditivo Baseado em Modelo (MPC) para a acoplagem autônoma (*docking*) de robôs voadores. O desafio central abordado consistiu em equilibrar as características divergentes das abordagens clássicas: enquanto a servovisão baseada em posição (PBVS) assegura trajetórias cartesianas retilíneas e suaves, ela ignora limites de visibilidade óptica; por outro lado, a servovisão baseada em imagem (IBVS) garante o enquadramento na lente, mas frequentemente induz manobras espaciais imprevisíveis com excesso de oscilação (*overshoot*).

A solução formulada estruturou um esquema híbrido coordenado por um controlador MPC, no qual a aproximação em longo alcance opera no domínio cartesiano métrico tridimensional (PBVS) até a proximidade da interface de engate. Ao ingressar no envelope de proximidade crítica, a lei de controle realiza uma transição suave para restrições baseadas em pixels (IBVS), orientando os atuadores a centralizar as feições visuais no sensor. A plataforma sensorial utilizou uma câmera estéreo RGB-D gerando nuvens de pontos tratadas a 30 Hz, enquanto o algoritmo preditivo calculou vetores de aceleração para a planta motopropulsora a uma taxa de 15 Hz.

A validação experimental em bancada de testes laboratoriais evidenciou índices de sucesso consistentes entre 80% e 100% em operações de acoplagem dinâmica a partir de afastamentos iniciais superiores a 1,5 m. Na fase final de contato, o sistema

amortizou as perturbações de atitude e alcançou um erro de alinhamento residual estacionário de apenas 1,0 mm no espaço métrico cartesiano e desvio de guinada (*yaw*) inferior a 0,25°, confirmando que a servovisão orientada por estimativa métrica combinada à observância de limites focais oferece suporte ideal para operações de engate milimétrico.

Shang *et al.* [4] investigaram o problema da estabilização de multirrotores operando sob severos atrasos de amostragem na aquisição e no processamento de imagens. Em sistemas computacionais de bordo sujeitos a gargalos de transmissão ou modelos pesados de visão, o tempo decorrido entre a captura do quadro óptico e o cálculo do comando cinemático pode introduzir atrasos de fase consideráveis, provocando instabilidade e oscilações cíclicas divergentes quando controlados por malhas PID analíticas convencionais.

Para suplantar essa barreira, os pesquisadores propuseram uma lei de controle de servovisão baseada em cálculo de Ordem Fracionária, desenvolvendo um controlador Proporcional-Derivativo de Ordem Fracionária (FOPD) aplicado em estrutura hierárquica em cascata. Nessa topologia, a camada de alto nível processa a cinemática de servovisão visual e transmite referências de velocidade ao piloto automático em frequências compatíveis com o sensor, enquanto a camada inercial de baixo nível executa a estabilização dinâmica de atitude a alta taxa de amostragem.

Em ensaios de voo pairado conduzidos a 10 metros de altitude sobre um marcador terrestre, os autores impuseram deliberadamente um atraso severo de transporte computacional, configurando o ciclo visual para o período elevado de 0,58 segundo por imagem (equivalente a uma taxa inferior a 2 FPS). Sob essas condições extremas de latência, o controlador PID padrão perdeu a capacidade de amortecimento, acumulando oscilações amplas que geraram desvios superiores a 68 pixels no plano focal. Em contraste, o algoritmo FOPD compensou ativamente o atraso de fase na malha fechada e reteve a fuselagem da aeronave dentro de um raio de confinamento de 58 pixels, demonstrando uma elevação de 20% na estabilidade espacial da servovisão diante de atrasos temporais no sensoriamento.

O acompanhamento autônomo de alvos terrestres com trajetórias desconhecidas e sob influência de rajadas aerodinâmicas foi avaliado por Carvajal *et al.* [1]. Durante perseguições a baixa altitude, o tempo de resposta inercial do VANT associado a ventos cruzados tende a provocar erros acumulados de rastreamento, fazendo com que a câmera perca o alinhamento com o centroide do objeto e desestabilize a missão de monitoramento contínuo.

Os autores implementaram uma malha de servovisão orientada por Controle por Modos Deslizantes (SMC, do inglês *Sliding Mode Control*) dotada de um módulo de compensação dinâmica de velocidade. A percepção visual foi processada em alta frequência a 50 FPS (50 Hz), realimentando o algoritmo de rastreamento de uma esfera

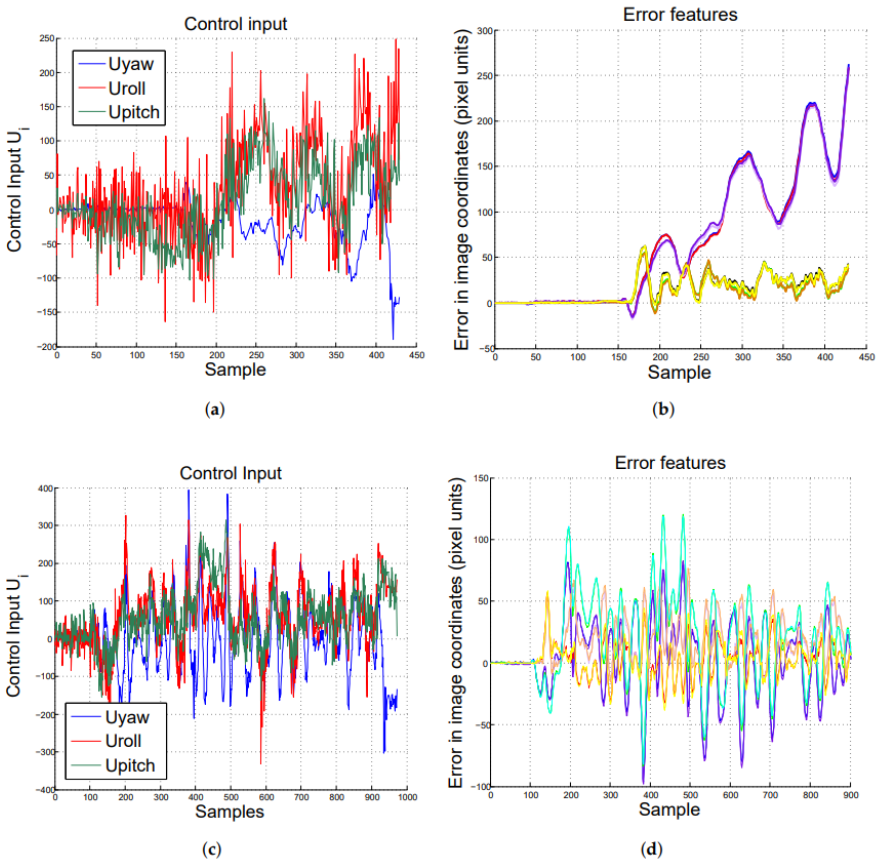
móvel. O compensador dinâmico estimou em tempo real as derivadas de aceleração relativa do alvo, antecipando correções cinemáticas antes que as discrepâncias de posição se convertessem em desvios no enquadramento óptico.

Nos ensaios de campo com duração contínua de 120 segundos, nos quais o veículo terrestre manobrou em trajetórias complexas em forma de oito e com acelerações variáveis, o sistema rejeitou rajadas de vento e manteve a distância de seguimento estabilizada em 2,5 m. O erro de acompanhamento de velocidade convergiu assintoticamente a zero, mantendo o alvo confinado no centro da lente com erro angular residual desprezível e confirmando a eficácia de estruturas cinemáticas com termos preditivos e derivativos em malhas visuais de alta taxa.

Com foco em resolver a vulnerabilidade das malhas de controle diante de variações mecânicas súbitas e perturbações de carga, Lopez-Franco *et al.* [36] desenvolveram um sistema de servovisão adaptativo para um hexarrotor utilizando controladores PID acoplados a Redes Neurais Artificiais (PID-ANN). Em cenários de transporte e engate de ferramentas, o instante de captura altera abruptamente a massa global do robô e seus momentos de inércia em torno dos eixos principais, situação que comumente conduz à desestabilização de controladores com ganhos fixos.

O método concebido empregou uma arquitetura na qual cada grau de liberdade da aeronave é governado por um bloco neural com pesos sinápticos recalibrados a cada ciclo amostral em tempo real. A realimentação sensorial utilizou uma câmera apontada em visada nadir rastreando os vértices de um código QR plano para conduzir a servovisão baseada em imagem (IBVS). A Figura 15 apresenta a resposta comparativa obtida em bancada experimental para os esforços de controle e o erro de pixel durante um ensaio em que distúrbios severos foram injetados no sistema físico.

Figure 15: Comparação experimental do erro de rastreamento no plano da imagem entre controlador PID convencional e PID Neural (PID-ANN) sob perturbação de massa de 50%



Fonte: adaptado de Lopez-Franco *et al.* [36].

Durante os testes em voo pairado, os autores impuseram um distúrbio drástico não modelado correspondente ao acréscimo instantâneo de 50% na massa total da aeronave, acompanhado por variações em suas matrizes inerciais. Conforme evidenciado na Figura 15, o controlador PID clássico pré-sintonizado foi incapaz de suportar a alteração paramétrica, resultando na perda de estabilidade e em um erro quadrático médio (RMSE) divergente de 1.741,9 pixels nas coordenadas da imagem. Em contrapartida, o controlador PID-ANN adaptou seus parâmetros em escala de milissegundos, mantendo a aeronave perfeitamente estável sobre o alvo e limitando o RMSE a 212,4 pixels, com Desvio Médio Absoluto (AAD) de 43,2 pixels. O experimento comprovou quantitativamente que estruturas de controle dotadas de ação adaptativa e amortecimento derivativo asseguram resiliência superior durante o manuseio de cargas em multirrotores.

2.2.4 Análise Comparativa dos Trabalhos Relacionados

Com o intuito de fundamentar as escolhas metodológicas deste trabalho, a Tabela 1 sintetiza de forma comparativa as principais pesquisas desenvolvidas nas áreas de manipulação aérea autônoma, detecção e rastreamento de alvos. O levantamento destaca as estratégias visuais empregadas, as técnicas de controle cinemático e dinâmico, os mecanismos de acoplamento físico adotados, bem como as limitações operacionais e os resultados quantitativos obtidos em cada estudo.

Table 1: Análise Comparativa dos Trabalhos Relacionados

Autor (Ano)	**Detecção e Rastreamento**	**Técnica de Controle**	**Mecanismo de Captura**	**Limitações do Estudo**	**Principais Resultados**
Thomas *et al.* [44]	Câmeras externas (MOCAP) e Servovisão (IBVS)	Estabilização reativa pós-impacto	Garra passiva de base (fechamento por impacto)	Dependência de laboratório com câmeras MOCAP; inviável em áreas externas.	100% de sucesso mecânico com cargas de 77 g; desligamento de motores em *perching*.
Bauer *et al.* [45]	Câmera de profundidade RGB-D (Mask R-CNN)	Aproximação autônoma não detalhada	Garra robótica flexível (*soft gripper*)	Processamento em GPU externa (RTX-3070); impacto em alta velocidade requer desaceleração.	89% de sucesso em voo livre; absorção mecânica de erros de estimativa de pose.
Ubellacker *et al.* [46]	Visão 3D embarcada e pontos-chave	Controle adaptativo de tranco mínimo	Garra macia com tendões passivos	Queda brusca para 30% de sucesso a velocidades acima de 2,0 m/s por erro de visão.	100% de sucesso a 0,5 m/s em garrafas e 90% em kits médicos em ambiente externo.
Luo *et al.* [38]	Características visuais naturais (extrator ORB)	Servovisão em estágios (IBVS/PBVS)	Braço robótico leve de 6-DoF (0,9 kg)	Adição de massa e inércia do braço; exige alvos com texturas ricas e bem definidas.	Captura iniciada a 3,0 m, estabilização a 0,4 m e encaixe fino a 20 cm com erro < 5 mm.
Barisic *et al.* [9]	YOLOv3-Tiny e Filtro de Kalman Discreto	Servovisão para perseguição ativa	Não aplicável (Rastreamento de outro VANT)	Oscilações da caixa delimitadora causadas por vibração estrutural e rotação de hélices.	mAP de 97,88% a 20 FPS; seguimento estável mesmo em trajetórias complexas em forma de oito.

Continua na página seguinte

Table 1 - Continuação da página anterior

Autor (Ano)	Detecção e Rastreamento	Técnica de Controle	Mecanismo de Captura	Limitações do Estudo	Principais Resultados
Vidal e Casanova [35]	*Window-Matching* e Filtro de Kalman	Visão preditiva em vídeo	Não aplicável (Rastreamento em vídeo)	Rastreamento visual puro sofre deriva de câmera (*drift*) e perde o alvo para o fundo.	Compensação de perdas visuais e oclusões dinâmicas em garrafas no mar e cruzamentos.
Shen *et al.* [47]	DS-YOLOv8 (Foco em pequenos alvos aéreos)	Não aplicável (Detecção remota)	Não aplicável	Queda de desempenho em cenários com alvos densamente aglomerados.	mAP@50 de 91,0% e F1-score de 90,4% em alvos com menos de 16×16 pixels.
Zhang *et al.* [48]	LCNN-DMT (SqueezeNet com atenção visual)	Não aplicável (Reconhecimento espacial)	Não aplicável	Tendência inicial da rede de fragmentar o alvo em caixas delimitadoras redundantes.	mAP de 97,50%; inferência em 6,1 ms consumindo 0,464 GFLOPs e 0,928M de parâmetros (*Low-SWaP*).
Pramono [37]	Câmera de profundidade e servovisão híbrida	Controle Preditivo Baseado em Modelo (MPC)	Mecanismo de acoplagem (*docking*)	Complexidade geométrica na comutação das matrizes visuais de PBVS para IBVS.	80% a 100% de sucesso; erro residual nulo de 1,0 mm em posição e 0,25° em orientação.
Shang *et al.* [4]	Servovisão com atraso de amostragem	Controle em cascata FOPD (Ordem Fracionária)	Não aplicável (Foco em voo pairado)	Atraso de processamento de imagem desestabiliza controladores PID convencionais.	Voo estabilizado sob atraso severo de 0,58 s, contendo o desvio em raio de 58 pixels (ganho de 20%).
Carvajal *et al.* [1]	Câmera a 50 Hz (Rastreamento de esfera)	Modos Deslizantes (SMC) com compensador	Não aplicável (Acompanhamento terrestre)	Inércia da aeronave induz atraso de perseguição sem compensador preditivo de aceleração.	Rastreamento durante 120 s em forma de oito a 2,5 m de distância com erro de velocidade nulo.

Continua na página seguinte

Table 1 - Continuação da página anterior

Autor (Ano)	Detecção e Rastreamento	Técnica de Controle	Mecanismo de Captura	Limitações do Estudo	Principais Resultados
Lopez-Franco *et al.* [36]	Servovisão 2D no plano da imagem	PID Neural adaptativo (PID-ANN)	Não aplicável (Alinhamento sobre o alvo)	Controladores convencionais divergem (1.741 pixels) sob variações súbitas de massa.	Erro contido a 212 pixels mesmo após aumento imprevisto de 50% no peso da aeronave.

Fonte: Elaborado pelo autor (2026).

A análise comparativa dos trabalhos correlatos evidencia que a manipulação aérea autônoma atingiu maturidade em subsistemas isolados, mas ainda carece de integração em arquiteturas que operem exclusivamente com percepção embarcada em tempo real e sem marcadores artificiais. Estudos pioneiros, como o de Thomas *et al.* [44], comprovaram a viabilidade mecânica do acoplamento ventral utilizando garras passivas; contudo, a dependência de laboratórios estruturados com sistemas MOCAP inviabiliza sua aplicação em ambientes abertos e não estruturados.

Visando superar essa dependência externa em cenários sem sinal de GPS, pesquisas como as de Bauer *et al.* [45] e Ubellacker *et al.* [46] demonstraram a viabilidade de realizar capturas utilizando sensores visuais e inteligência artificial embarcada. Nesse contexto, as abordagens clássicas baseadas em descritores manuais de características naturais sofrem com elevado custo computacional e sensibilidade a variações de iluminação [38]. Por outro lado, as contribuições de Shen *et al.* [47] e Zhang *et al.* [48] comprovam que modelos modernos de Redes Neurais Convolucionais alcançam elevados índices de precisão média ($mAP > 90\%$) com latências inferiores a 10 milissegundos. Essas evidências sustentam a escolha da família YOLO neste trabalho para realizar o isolamento semântico da gaiola em taxas elevadas de processamento (> 20 FPS) compatíveis com o computador de bordo auxiliar.

Entretanto, a literatura também demonstra que as saídas brutas dos modelos de detecção não devem ser injetadas diretamente na malha de controle cinemático. Conforme documentado por Barisic *et al.* [9], o rastreamento visual aéreo produz caixas delimitadoras sujeitas a ruídos de alta frequência decorrentes da vibração dos motores e de oclusões parciais pelas hélices. Tanto os achados de Barisic *et al.* [9] quanto os de Vidal e Casanova [35] reforçam a necessidade de acoplar estimadores de estado para atenuar tremores e manter predições contínuas durante lapsos temporários de visão. Assim, a presente pesquisa adota Filtros de Kalman para garantir suavidade no sinal de posição e orientação antes da geração dos comandos de voo.

Por fim, no domínio do controle cinemático, os trabalhos de Pramono [37] e Carvajal *et al.* [1] sustentam que a projeção espacial para o espaço métrico tridimensional (PBVS) confere previsibilidade geométrica essencial para aproximações milimétricas, superando as trajetórias espaciais irregulares do IBVS clássico. Além disso, Shang *et al.* [4] comprovaram que a separação hierárquica entre a malha cinemática externa (computador de bordo) e a malha dinâmica interna de atitude (piloto automático) atenua os impactos da latência visual. Essa fundamentação consolida a arquitetura adotada nesta monografia: o uso do modelo de câmera Pinhole com compensação de *offset* para converter pixels filtrados em coordenadas métricas reais (X, Y, Z) e guinada (*yaw*), combinada a controladores Proporcionais-Derivativos (PD) em cascata para assegurar o alinhamento cravado sobre a armadilha antes da descida final de acoplamento.



3

3 METHODOLOGY

Neste capítulo, apresentam-se os procedimentos metodológicos, os modelos matemáticos, as ferramentas computacionais e os critérios experimentais adotados para o desenvolvimento e a validação do sistema autônomo de captura de objetos por VANTs utilizando servovisão. A metodologia foi estruturada de modo a assegurar a reprodutibilidade do projeto, descrevendo detalhadamente a integração entre os módulos de percepção visual, filtragem estocástica de estados, reconstrução geométrica tridimensional, controle cinemático em cascata e o ambiente de simulação física em malha fechada.

3.1 VISÃO GERAL E CLASSIFICAÇÃO DA PESQUISA

Sob a perspectiva metodológica formal, este trabalho classifica-se como uma pesquisa aplicada, orientada pela necessidade de solucionar um problema técnico e operacional concreto, voltado ao recolhimento e ao transporte autônomo de armadilhas inteligentes para monitoramento de vetores biológicos no âmbito do projeto VTS. A abordagem adotada é quantitativa, fundamentada na coleta e na análise de dados numéricos mensuráveis, tais como taxas de precisão de detecção, métricas geométricas de sobreposição de caixas, tempos de ciclo computacional em milissegundos, taxas de amostragem em quadros por segundo e erros residuais de alinhamento métrico e angular durante as manobras de aproximação.

Quanto aos seus objetivos, a pesquisa possui natureza experimental e explicativa. O caráter experimental decorre da manipulação sistemática de variáveis de controle, parâmetros de filtragem e arquiteturas de redes neurais artificiais sob condições controladas de ensaio, permitindo avaliar a resposta do sistema diante de distúrbios introduzidos deliberadamente. O caráter explicativo manifesta-se no estabelecimento de relações de causa e efeito entre os fatores críticos de voo (como oscilações estruturais da fuselagem, variações de iluminação solar e atrasos de transporte no fluxo de imagens) e a estabilidade cinemática necessária para o acoplamento físico com a estrutura da armadilha.

Como procedimento técnico, o estudo fundamenta-se na modelagem matemática e na validação experimental por meio de simulação computacional no paradigma *Software-in-the-Loop* (SITL). Essa abordagem permite executar o firmware real do piloto automático acoplado a um motor de física tridimensional de alta fidelidade, submetendo a aeronave a modelos aerodinâmicos e inerciais equivalentes aos de uma operação em campo, sem os riscos de integridade física e os custos associados a testes preliminares com protótipos reais.

O desenvolvimento da pesquisa foi conduzido ao longo de seis etapas metodológicas consecutivas.

1. **Modelagem da plataforma e do cenário virtual,** compreendendo a configuração física do VANT multirrotor no simulador, a definição do mecanismo de captura ventral, a parametrização do suporte estabilizado (*gimbal*) com a câmera óptica em visada vertical e a inserção da armadilha não cooperativa no solo;

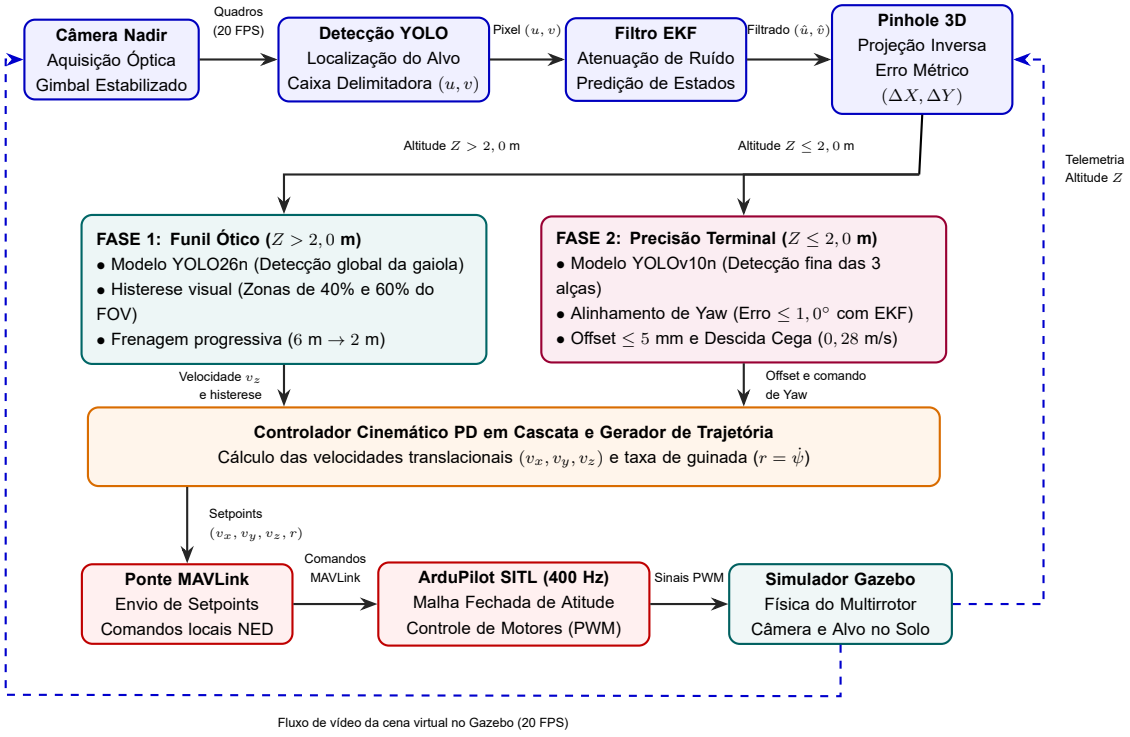
2. **Construção do dataset e treinamento visual,** envolvendo a geração de um conjunto de imagens sintéticas capturadas em diferentes altitudes de voo e condições de iluminação, seguido pelo treinamento supervisionado e pela avaliação comparativa de quatro arquiteturas compactas

da família YOLO (v8n, v10n, v11n e v26n);

3. **Implementação da filtragem estocástica,** com o desenvolvimento de um Filtro de Kalman Estendido (EKF) para atenuar ruídos de alta frequência nas caixas delimitadoras, estimar estados dinâmicos e prover estimativas preditivas contínuas durante lapsos transitórios de visibilidade;
4. **Reconstrução geométrica tridimensional,** aplicando a projeção inversa do modelo analítico de câmera *Pinhole* para converter os desvios visuais em metros reais no referencial da aeronave, com compensação do deslocamento físico da lente e extração do erro de guinada (*Yaw*);
5. **Projeto do controle cinemático e segurança de voo,** formulando controladores Proporcionais-Derivativos (PD) para o guiamento translacional e angular em malha externa, associados a uma envoltória de histerese visual para garantir a permanência contínua do alvo no campo de visão;
6. **Integração em malha fechada e ensaios experimentais,** conectando os módulos via protocolo de telemetria MAVLink e executando baterias de missões simuladas para validação dos índices de convergência e sucesso no acoplamento terminal.

Para operacionalizar essas etapas e coordenar a missão autônoma de descida e captura, o sistema foi estruturado em uma arquitetura em malha fechada organizada em três camadas funcionais hierárquicas, detalhada no diagrama da Figura 16.

Figure 16: Arquitetura geral em malha fechada e fluxo operacional em duas fases do sistema



Fonte: elaboração própria.

A arquitetura ilustrada na Figura 16 estabelece uma estrutura hierárquica multi-taxa (*multi-rate*) operando em três frequências de processamento coordenadas. A camada superior de software opera

a 20 Hz no computador de bordo auxiliar por meio do ROS 2, centralizando a inteligência visual com os modelos YOLO, a filtragem estocástica com o Filtro de Kalman Estendido e a geração de trajetórias translacionais. A camada intermediária roda a 400 Hz no piloto automático ArduPilot em arquitetura SITL, encarregada da malha fechada rápida de estabilização inercial de atitude e da modulação por largura de pulso (PWM) enviada aos atuadores. Por fim, a camada inferior de simulação no Gazebo Sim processa as equações dinâmicas da física em passo de 1 milissegundo (1000 Hz), viabilizando a integração numérica estável das forças aerodinâmicas e das reações de contato mecânico.

No fluxo de percepção, a câmera montada no suporte estabilizado com orientação nadir envia imagens brutas ao nó de visão. A rede neural YOLO processa cada quadro para localizar o alvo e extrair as coordenadas da caixa delimitadora no plano da imagem. Para atenuar as oscilações de alta frequência (*jitter*) decorrentes de ruídos da inferência e da vibração da aeronave, essas coordenadas são encaminhadas ao Filtro de Kalman Estendido (EKF), que estima a velocidade relativa do alvo e sustenta predições consistentes por até 4,0 segundos caso ocorra alguma oclusão transitória por sombras ou perda momentânea de visada.

Em seguida, o modelo analítico Pinhole inverso combina as coordenadas filtradas com a leitura de altitude fornecida pela telemetria do piloto automático para calcular a distância métrica horizontal $(\Delta X, \Delta Y)$ entre o centro do drone e o alvo. Essa informação métrica alimenta a estratégia operacional de guiamento, a qual é estruturada em duas fases distintas com base na altitude da aeronave, empregando modelos especializados da família YOLO em cada regime de voo.

1. **Fase 1 (Abordagem Ampla e Descida em Funil Ótico, executada acima de 2,0 m):** Nessa primeira fase, operada pelo nó de rastreamento inicial, adota-se o modelo **YOLO26n**, treinado para o reconhecimento da geometria macroscópica da armadilha como uma classe única. Esse modelo foi selecionado por sua capacidade de manter estabilidade contínua na caixa delimitadora e elevada taxa de detecção a médias e altas altitudes, orientando a aproximação e o afunilamento descendente. Para evitar que a aeronave perca o alvo durante manobras bruscas, aplica-se uma envoltória de histerese visual com dois limites concêntricos: uma zona segura interna correspondente a 40% do campo de visão e um limite de fuga externo fixado em 60% do enquadramento. A velocidade vertical de descida é modulada continuamente entre 0,0 e 1,5 m/s com base no alinhamento central, pausando automaticamente a descida se o alvo atingir o limite de fuga e retomando-a quando o erro for reabsorvido. Entre as altitudes de 6,0 m e 2,0 m, o sistema introduz uma curva de frenagem progressiva para dissipar a inércia descendente. Ao atingir com precisão a marca de 2,0 metros, o nó da Fase 1 encerra sua execução e transfere o controle para o nó de precisão terminal.

2. **Fase 2 (Alinhamento Fino, Compensação de Offset e Acoplamento, executada abaixo de 2,0 m):** Abaixo de 2,0 metros, a aproximação exige resolução geométrica subcentimétrica e identificação de subcomponentes específicos. O sistema encerra o primeiro detector e inicializa um segundo nó de visão baseado no modelo **YOLOv10n**, treinado com segmentação em duas classes distintas para distinguir individualmente a carcaça da gaiola e as três alças triangulares superiores da tampa. Essa discriminação fina fornece as referências espaciais necessárias para o alinhamento angular e a descida de contato (a fundamentação experimental detalhada, os parâmetros de treinamento e as métricas comparativas que orientaram a escolha desses dois modelos específicos são aprofundados na Seção 3.3). A operação da Fase 2 é regida por uma máquina de estados finitos estruturada em quatro etapas consecutivas:

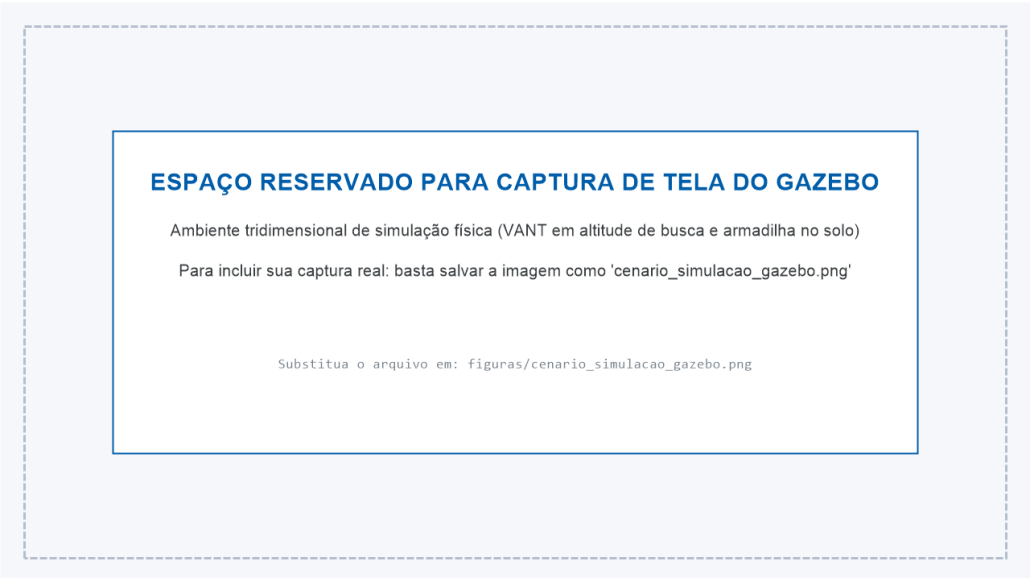
    - *Etapa 1 (Aproximação Inicial):* o VANT desce suavemente de 2,0 m para 1,50 m para estabilizar a visada sobre o topo da estrutura;

- *Etapa 2 (Alinhamento Angular de Guinada):* a aeronave mantém voo pairado (*hover*) a 1,50 m e efetua rotação sobre o próprio eixo até igualar seu ângulo de guinada (*Yaw*) à assimetria das alças da armadilha, exigindo erro angular menor ou igual a $1,0°$ sustentado continuamente, utilizando o filtro EKF angular;
- *Etapa 3 (Descida Intermediária e Ajuste Fino de Offset):* o drone desce até 0,35 m de altitude para alinhar o mecanismo mecânico de captura com a alça de travamento. O algoritmo compensa analiticamente o deslocamento físico (*offset*) de 42,16 mm existente entre a lente da câmera no gimbal e o eixo central do dispositivo de engate, exigindo permanência contínua com erro horizontal inferior a 5 mm por 1,5 segundo ininterrupto;
- *Etapa 4 (Descida Cega Terminal):* nos últimos 30 centímetros, o sistema executa uma descida vertical firme a 0,28 m/s para anular perturbações aerodinâmicas causadas pelo efeito solo, consumando o acoplamento físico na armadilha e desarmando automaticamente os motores ao atingir a altitude de toque de 0,05 m.

Os erros métricos e angulares computados em cada fase alimentam controladores Proporcionais-Derivativos (PD) em cascata, cujos ganhos foram ajustados para prover correções suaves sem sobressinais (*overshoot*). As velocidades de controle resultantes são convertidas em mensagens padronizadas do protocolo MAVLink (*SET_POSITION_TARGET_LOCAL_NED*) e enviadas ao ArduPilot, fechando o laço autônomo de captura no simulador Gazebo.

A configuração tridimensional desse ambiente simulado pode ser visualizada na Figura 17, que ilustra a disposição espacial inicial do VANT em altitude de busca sobre o terreno e a localização da armadilha de vetores biológicos posicionada estaticamente no solo. A partir dessa cena virtual, a câmera óptica acoplada ao gimbal gera o fluxo contínuo de quadros que alimenta a camada de percepção em malha fechada.

Figure 17: Visão geral do ambiente de simulação no Gazebo apresentando o VANT em altitude de busca e o alvo no solo



Fonte: elaboração própria.

3.2 AMBIENTE DE SIMULAÇÃO E MODELAGEM DA PLATAFORMA AÉREA

A validação de estratégias de servovisão aplicadas à manipulação e captura aérea requer um ambiente computacional capaz de reproduzir com fidelidade a dinâmica do veículo, o comportamento dos atuadores, a resposta inercial de sensores e as condições de iluminação e contato mecânico. Para atender a esses requisitos sem expor equipamentos físicos a danos durante o desenvolvimento das leis de controle, implementou-se um ecossistema de simulação tridimensional baseado no simulador Gazebo Sim, integrado ao piloto automático ArduPilot em arquitetura *Software-in-the-Loop* (SITL).

O cenário virtual foi estruturado no arquivo de mundo da simulação, no qual se configurou o motor de física com passo de integração temporal fixado em 1 milissegundo, correspondendo a uma frequência de cálculo dinâmico de 1000 Hz. Essa taxa de amostragem elevada é mandatória para garantir a convergência numérica do integrador do motor de física ODE, prevenindo divergências e oscilações espúrias no cômputo das forças aerodinâmicas não lineares atuantes em cada pá e nas forças normais e de atrito geradas pelo contato físico entre o gancho e a armadilha. Essa dinâmica rápida de 1000 Hz opera em conjunto perfeitamente sincronizado (*lockstep*) com a malha inercial de 400 Hz do firmware ArduPilot e com a malha visual de 20 Hz do ROS 2, constituindo a hierarquia multi-taxa do sistema. O fator de tempo real foi travado em 1,0, assegurando determinismo temporal absoluto durante as baterias de ensaios.

O ambiente gráfico adota o motor de renderização física OGRE 2.x, viabilizando iluminação realista por sombreamento bidirecional. O mundo inclui uma fonte de luz solar direcional com projeção dinâmica de sombras ativada, orientada pelo vetor de incidência solar $(-0,5, 0,1, -0,9)$. Essa parametrização deliberada introduz variações expressivas de contraste e oclusões parciais causadas pela sombra projetada pela fuselagem do próprio drone sobre a armadilha durante a fase final de aproximação, submetendo os algoritmos de visão computacional a perturbações ópticas representativas de cenários operacionais reais. A superfície do terreno foi modelada com uma camada de grama texturizada em alta resolução, incorporando mapas de difusão, normais e rugosidade para evitar um plano de fundo monocromático idealizado e reproduzir o ruído visual característico de vegetação rasteira.

Para a plataforma aérea, adotou-se uma configuração de multirrotor coaxial em arquitetura OctaQuad X8, composta por quatro braços estruturais dispostos em geometria em cruz, cada um sustentando um par de motores contra-rotativos (um superior e um inferior). Essa escolha fundamenta-se em três necessidades técnicas do projeto. Primeiramente, a disposição coaxial provê redundância mecânica e elevada capacidade de tração vertical sem ampliar a envergadura diagonal da aeronave, resultando em um chassi compacto que minimiza o risco de colisões dos rotores com galhos ou estruturas durante descidas em baixa altitude. Em segundo lugar, o arranjo de oito rotores gera ampla margem de empuxo para compensar com folga o acréscimo de carga útil decorrente do mecanismo ventral de captura, dos sensores embarcados e do peso da própria armadilha recolhida. Por fim, a distribuição simétrica dos pares contra-rotativos desacopla a geração de sustentação do momento de guinada, propiciando autoridade de controle angular firme e desacoplada mesmo sob as fortes perturbações de recirculação de ar geradas pelo efeito solo nas proximidades imediatas da superfície.

O modelo inercial do VANT totaliza uma massa de decolagem de 6,700 kg, dividida entre 6,300 kg atribuídos à estrutura central da fuselagem com baterias, eletrônica de bordo e mecanismo de engate, e 0,400 kg distribuídos entre os oito conjuntos rotativos de propulsão (0,050 kg por rotor). Os momentos principais de inércia foram calculados analiticamente no ambiente CAD por meio da integração numérica volumétrica das densidades reais dos materiais aplicados em cada componente da montagem tridimensional, como fibra de carbono nos tubos dos braços e placas centrais, ligas de alumínio e cobre nos motores elétricos, células de lítio-polímero na bateria 12S e polímeros termoplásticos nas peças estru-

turais impressas. Esse cômputo determinou os valores $I_{xx} = 0,903322$ kg · m^2, $I_{yy} = 0,903322$ kg · m^2 e $I_{zz} = 1,569346$ kg · m^2 em relação ao centro de massa, com produtos de inércia nulos em virtude da simetria ortogonal da montagem.

O sistema motopropulsor foi calibrado a partir do ajuste de curvas polinomiais de mínimos quadrados sobre dados empíricos de bancada dinamométrica disponibilizados pelo fabricante T-Motor para o motor sem escovas MN6007 II KV160, alimentado por bateria LiPo 12S sob tensão nominal de 44,4 V e hélices de fibra de carbono modelo P22x6.6. A relação aerodinâmica entre a velocidade angular do rotor (ω, em radianos por segundo) e a força de empuxo gerada (T, em Newtons) foi modelada pela Equação (14), enquanto o torque resistente de arrasto (Q, em Newtons-metro) obedece à Equação (15).

$$T = c_t \cdot \omega^2 = 1,88928 \times 10^{-4} \cdot \omega^2 \tag{14}$$

$$Q = c_q \cdot \omega^2 = 4,48871 \times 10^{-6} \cdot \omega^2 \tag{15}$$

Os coeficientes c_t e c_q obtidos na regressão reproduzem o comportamento real da bancada com erro residual inferior a 1,5%, atingindo velocidade de rotação máxima de 5456 RPM (571,35 rad/s) sob aceleração plena de 100%, o que equivale a um torque limite por eixo de 1,49 N·m. As forças dinâmicas atuantes em cada uma das pás das hélices foram individualizadas no simulador por meio de elementos de sustentação e arrasto (*LiftDrag*), parametrizados com coeficiente angular de sustentação $C_{L\alpha} = 4,25$, coeficiente de arrasto parasita $C_{D0} = 0,56097$, área alar equivalente de $0,0037982$ m^2 e densidade do ar padrão de $1,2041$ kg/m^3.

A estabilização angular das imagens adquiridas é garantida por um suporte motorizado de três eixos (*gimbal*) modelado com base nas especificações físicas e dinâmicas do dispositivo comercial SIYI A8 mini. O conjunto possui massa de 0,095 kg distribuída entre os elos mecânicos de rotação. O elo de guinada (*yaw*) permite excursão angular entre $-160°$ e $+160°$, o elo de rolagem (*roll*) atua na faixa de $-30°$ a $+30°$ e o elo de arfagem (*pitch*) desloca-se entre $-135°$ e $+45°$. No âmbito da missão de captura, o controle do gimbal é acionado por mensagens MAVLink padronizadas com a sinalização de travamento inercial ativada para os eixos de rolagem e arfagem. Essa configuração mantém a orientação da câmera continuamente travada no horizonte terrestre com inclinação de $-90°$ (visada nadir ortogonal ao solo), absorvendo as inclinações naturais que a aeronave executa para acelerar horizontalmente. Por outro lado, o eixo de guinada do gimbal é mantido alinhado ao corpo do drone, assegurando que as leituras angulares observadas no plano da imagem correspondam diretamente à rotação física da fuselagem em relação ao alvo no solo.

A câmera virtual acoplada ao estágio inferior do gimbal opera na resolução Full HD de 1920×1080 pixels em padrão cromático R8G8B8, com frequência de amostragem limitada a 20 FPS para compatibilidade com o ciclo de processamento da rede neural. O campo de visão horizontal (*Horizontal FOV*) foi estabelecido em 1,4137 radianos (aproximadamente $81,0°$), o que determina uma distância focal teórica $f_x = f_y = 1124,0$ pixels e centro óptico principal em $c_x = 960,0$ pixels e $c_y = 540,0$ pixels. O modelo de lente incorpora ainda coeficientes de distorção radial $k_1 = -0,05$ e $k_2 = 0,01$ para reproduzir as aberrações geométricas típicas de lentes grande-angulares compactas.

Sob o chassi central da aeronave, foi posicionado o mecanismo de engate mecânico ventral, composto por um gancho rígido de acoplamento passivo desenvolvido para travar mecanicamente na alça da armadilha. Esse dispositivo foi posicionado no ponto correspondente ao centro de gravidade (CG) do multirrotor para evitar a geração de momentos fletores ou desequilíbrios estáticos na atitude da aeronave no instante do contato e após o içamento da massa adicional do alvo.

Entretanto, em razão da geometria construtiva do chassi e da fixação física do gimbal, a lente da câmera óptica encontra-se deslocada espacialmente em relação ao centro do engate mecânico. A

coordenada de montagem do ponto focal da câmera no referencial do corpo da aeronave é dada pelo vetor de posição $\mathbf{p}_{\text{cam}} = (0,00057\ \text{m}, +0,04216\ \text{m}, -0,04551\ \text{m})$. Enquanto o desvio lateral no eixo X é inferior a 0,6 mm e pode ser desprezado, o deslocamento longitudinal no eixo Y introduz um *offset* estrutural constante de 42,16 mm à frente do centro do engate. Se o sistema de servovisão buscasse centralizar o alvo no ponto focal da câmera ($u = c_x, v = c_y$), o gancho físico ficaria posicionado mais de 4 centímetros atrás do ponto ótimo de contato, resultando em falha mecânica de engate ou colisão da fuselagem contra a tampa da armadilha. Esse arranjo espacial e a indicação do vetor de deslocamento são detalhados na Figura 18.

Figure 18: Representação tridimensional do VANT OctaQuad X8 com mecanismo de captura ventral e indicação do deslocamento geométrico (*offset*) de 42,16 mm entre a câmera e o dispositivo de engate



Fonte: elaboração própria.

Para sanar essa discrepância geométrica sem exigir alterações estruturais no chassi, desenvolveu-se uma compensação cinemática analítica no algoritmo de servovisão da Fase 2. Como a tampa da armadilha possui dimensão frontal padronizada de $0,2550$ m, a relação entre o deslocamento físico da câmera e a extensão do alvo no espaço métrico equivale a uma razão fixa dada pela Equação (16).

$$\eta_y = \frac{\Delta Y_{\text{offset}}}{L_{\text{alvo}}} = \frac{0,04216\ \text{m}}{0,2550\ \text{m}} \approx 0,1653 \tag{16}$$

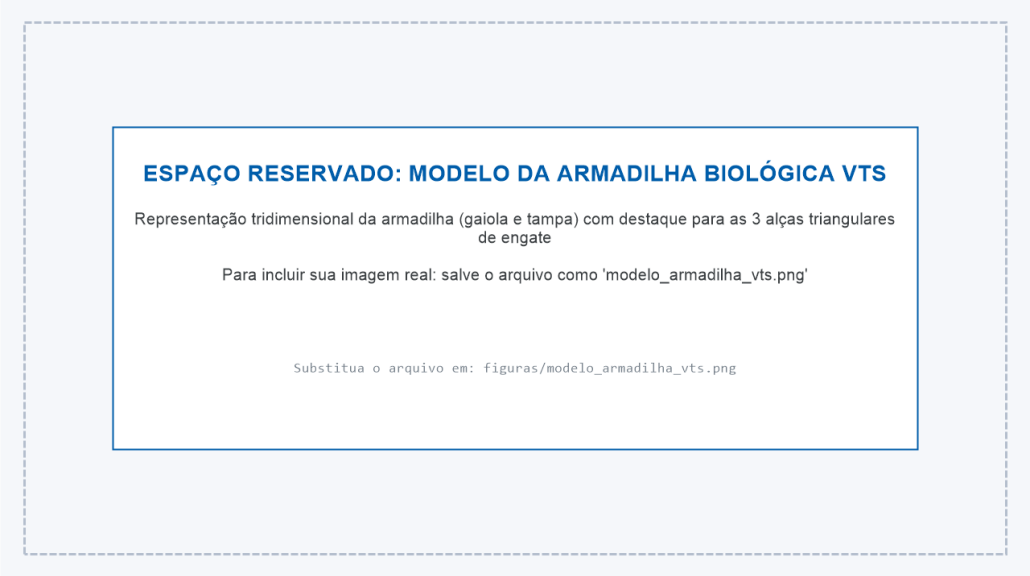
Dessa forma, o ponto de convergência visual do controlador no plano da imagem não é alinhado com o centro geométrico da caixa delimitadora predita pela rede neural, mas sim deslocado em $+16,53\%$ ao longo do eixo vertical de pixels proporcionalmente à altura da caixa. Essa correção analítica garante que, quando o erro de rastreamento visual converge para zero, o mecanismo físico de engate situado sob o CG do drone encontra-se rigorosamente perpendicular e alinhado à alça de captura.

O objeto-alvo não cooperativo modelado no ambiente virtual corresponde à armadilha inteligente de captura de vetores biológicos desenvolvida no âmbito do projeto VTS. A armadilha foi importada para o simulador como uma entidade dinâmica não estática, permitindo avaliar interações físicas reais de contato, atrito estático e forças de arraste mecânico durante o acoplamento do gancho. A estrutura

possui massa de 4,81162 kg, momentos principais de inércia $I_{xx} = 0,294868$ kg·m^2, $I_{yy} = 0,150069$ kg·m^2 e $I_{zz} = 0,258855$ kg · m^2, e coeficiente de atrito superficial com o solo $\mu = 1,0$ sob o motor de física ODE.

As dimensões externas da armadilha compreendem uma base quadrada de $0,2550$ m $\times$ $0,2550$ m (footprint de 255 mm de lado) e uma altura de $0,317$ m (317 mm) medida a partir do nível do solo até o plano superior da tampa. Sobre a tampa plástica, encontram-se três alças metálicas triangulares salientes destinadas ao içamento e travamento do dispositivo. A disposição geométrica dessas três alças não é simétrica em relação aos eixos cartesianos da gaiola, apresentando uma inclinação angular de rotação de $+93,37°$ em relação à linha de referência longitudinal da base, conforme ilustrado na Figura 19.

Figure 19: Geometria da armadilha de monitoramento de vetores biológicos com dimensões estruturais e disposição angular assimétrica das três alças triangulares de captura



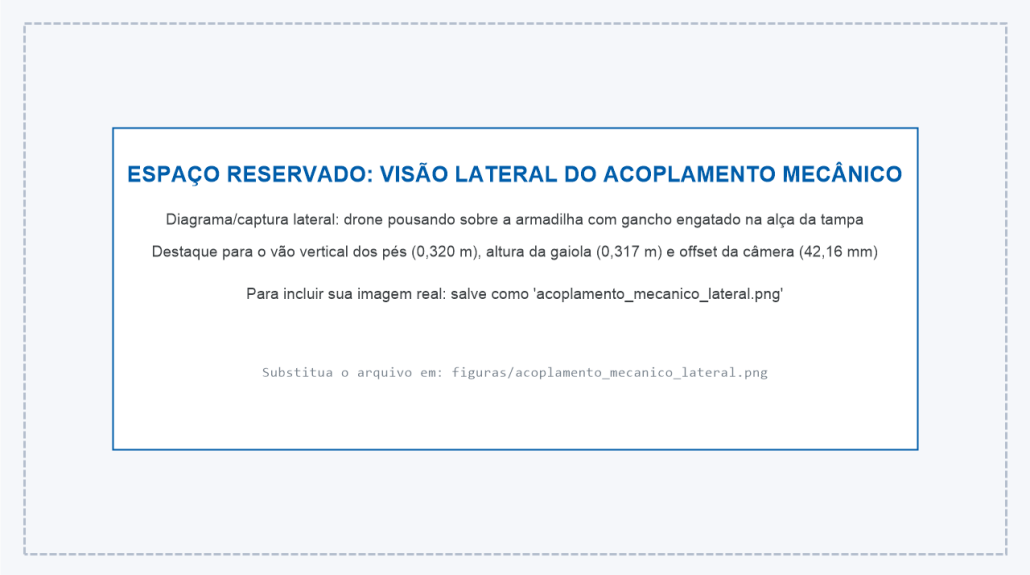
Fonte: elaboração própria.

A presença dessa assimetria geométrica no topo da armadilha impõe um requisito estrito ao sistema autônomo de navegação. A aeronave não pode efetuar a descida terminal orientada em qualquer ângulo arbitrário, pois a geometria da abertura do gancho ventral exige entrada com alinhamento angular rigoroso para consumar o travamento na alça. Por esse motivo, o controlador de voo na Fase 2 é programado para identificar a orientação relativa das alças a 1,50 m de altitude, computar a diferença angular em relação ao alvo nominal de $+93,37°$ e girar a fuselagem sobre o eixo de guinada até que o erro residual seja contido dentro do limiar de tolerância de $1,0°$. Apenas após a convergência conjunta desse alinhamento angular e da compensação longitudinal de 42,16 mm é que o sistema é autorizado a iniciar a descida de acoplamento final.

A geometria desse acoplamento terminal e as tolerâncias físicas envolvidas na aproximação são sintetizadas na Figura 20. Nessa vista lateral, evidencia-se a relação entre a distância vertical dos pés do trem de pouso da aeronave até a lente da câmera (0,320 m), a cota superior da armadilha até a base da tampa (0,317 m) e a trajetória de descida do gancho ventral até a alça. Essa configuração confere

uma folga vertical estrita no instante do toque, exigindo que o algoritmo execute a descida cega final a 0,28 m/s de forma rigorosamente vertical e nivelada, neutralizando perturbações aerodinâmicas de efeito solo e consumando o travamento mecânico antes do desarme automático dos motores na cota de 0,05 m.

Figure 20: Visão lateral esquemática do acoplamento mecânico terminal entre o gancho ventral do VANT e a alça da armadilha, ilustrando a tolerância vertical dos pés de pouso e o alinhamento de engate



Fonte: elaboração própria.



4

4 RESULTS AND DISCUSSION

Esta seção tem como objetivo apresentar, analisar e interpretar os resultados obtidos na pesquisa. Os dados devem ser organizados de forma clara, utilizando tabelas, gráficos, quadros ou figuras, quando necessário, para facilitar a compreensão.

A análise dos resultados deve ser feita de forma crítica, relacionando-os com os objetivos propostos e com o referencial teórico previamente abordado. É fundamental interpretar o significado dos dados, verificando se eles corroboram ou refutam as hipóteses levantadas ou os estudos anteriores consultados.

Nesta etapa, não basta apenas descrever os resultados; é necessário discutir suas implicações, possíveis limitações, e o que eles revelam sobre o problema de pesquisa. A discussão pode ser apresentada juntamente com os resultados ou em um capítulo separado, conforme as normas da instituição ou a natureza do trabalho.

Portanto, esta seção deve responder às seguintes perguntas:

- Quais foram os principais resultados obtidos?
- Como esses resultados se relacionam com os objetivos do trabalho?
- Eles confirmam ou refutam o que foi encontrado na literatura?
- Quais são as possíveis explicações para os achados?
- Existem limitações nos dados ou na metodologia que influenciam os resultados?

A apresentação dos resultados e sua discussão devem ser feitas de maneira clara, objetiva e fundamentada, garantindo coerência com todo o desenvolvimento do trabalho.


5

5 CONCLUSION

A conclusão é a seção final do trabalho, onde o autor retoma os objetivos propostos no início e apresenta as considerações finais com base nos resultados alcançados. Seu papel é responder se o problema de pesquisa foi solucionado e se os objetivos foram atingidos.

Neste capítulo, não se introduzem novos dados, informações ou discussões. O foco está em:

- Retomar brevemente os objetivos do trabalho;
- Apontar se os objetivos foram alcançados;
- Destacar os principais resultados obtidos;
- Apresentar reflexões sobre as limitações do estudo, quando houver;
- Sugerir possíveis desdobramentos, melhorias ou pesquisas futuras sobre o tema.

A conclusão deve ser clara, objetiva e coerente com tudo o que foi desenvolvido ao longo do trabalho, fechando o raciocínio de forma lógica e consistente.



REFERENCES

References

[1] C. P. Carvajal, V. H. Andaluz, J. Varela-Aldás, F. Roberti, C. Del-Valle-Soto, and R. Carelli, "Visual servoing using sliding-mode control with dynamic compensation for uavs' tracking of moving targets," *Drones*, vol. 8, no. 12, p. 730, 12 2024.

[2] I. Abuzayed, A. R. Itani, A. Ahmed, M. Alkharaz, M. A. Jaradat, and L. Romdhane, "Design of lightweight aerial manipulator with a cog compensation mechanism," in *2020 Advances in Science and Engineering Technology International Conferences (ASET)*. IEEE, 2020.

[3] S. Cocuzza and A. Doria, "Modeling and identification of vibrations in a uav for aerial manipulation," *Mechanisms and Machine Science*, vol. 91, pp. 182–190, 2021.

[4] B. Shang, J. Liu, T. Zhao, and Y. Chen, "Fractional order robust visual servoing control of a quadrotor uav with larger sampling period," in *2016 International Conference on Unmanned Aircraft Systems (ICUAS)*. Arlington, VA, USA: IEEE, 6 2016, pp. 1225–1233.

[5] Z. Q. Zhao, P. Zheng, S. T. Xu, and X. Wu, "Object detection with deep learning: A review," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 30, no. 11, pp. 3212–3232, 11 2019.

[6] A. B. Amjoud and M. Amrouch, "Object detection using deep learning, cnns and vision transformers: A review," *IEEE Access*, vol. 11, pp. 35 479–35 516, 2023.

[7] V. Afifah and S. Erniwati, "Yolov8 for object detection: A comprehensive review of advances, techniques, and applications," *IJACI: International Journal of Advanced Computing and Informatics*, vol. 2, no. 1, pp. 53–61, 7 2025.

[8] A. A. Adegun, J. V. Fonou-Dombeu, S. Viriri, and J. Odindi, "Ontology-based deep learning model for object detection and image classification in smart city concepts," *Smart Cities*, vol. 7, no. 4, pp. 2182–2207, 8 2024.

[9] A. Barišić, M. Car, and S. Bogdan, "Vision-based system for a real-time detection and following of uav," in *Proceedings of the 2019 Workshop on Research, Education and Development of Unmanned Aerial Systems (RED UAS)*. Cranfield, UK: IEEE, 11 2019.

[10] B. Thuilot, P. Martinet, L. Cordesses, and J. Gallice, "Position based visual servoing: keeping the object in the field of vision," in *Proceedings of the 2002 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2002.

[11] L. A. Fagundes-Junior, C. M. Soria, R. F. Vassallo, and A. S. Brandão, "Visual control and mapping for uav-based platform inspection," in *Proceedings of the 2025 International Conference on Unmanned Aircraft Systems (ICUAS)*. IEEE, 2025, pp. 542–548.

[12] M. Jiang, "Application of fuzzy pid control in uav control system," in *Proceedings of the 3rd International Conference on Inventive Research in Computing Applications (ICIRCA 2021)*. IEEE, 9 2021, pp. 197–200.

[13] H. Bonyan Khamseh, F. Janabi-Sharifi, and A. Abdessameud, "Aerial manipulation—a literature survey," *Robotics and Autonomous Systems*, vol. 107, pp. 221–235, 9 2018.

[14] X. Meng, Y. He, and J. Han, "Survey on aerial manipulator: System, modeling, and control," *Robotica*, vol. 38, no. 7, pp. 1288–1317, 7 2020.

[15] A. Adriansyah, B. Sulle, and A. Minarso, "Design of ahrs for quadrotor control using digital motion processor," *Journal of Telecommunication, Electronic and Computer Engineering*, vol. 9, no. 1-5, pp. 77–81, 2017.

[16] G. Sciortino *et al.*, “Ros/gazebo-based simulation of quadcopter aircrafts,” in *2018 IEEE RTSI: Research and Technologies for Society and Industry, 4th International Forum*. Palermo, Italy: IEEE, 9 2018.

[17] Stickman Physics, “Drone physics: Pitch, roll, and yaw dynamics,” https://stickmanphysics.com, 2025, acessado em: 05 nov. 2026.

[18] ArduPilot Development Team, “Connect ESCs and motors: Octo Quad frame layout,” https://ardupilot.org/copter/docs/connect-escs-and-motors.html, 2026, acessado em: 05 nov. 2026.

[19] G. Zhang, G. Tong, and P. Chen, “Robust adaptive control of uav,” in *Proceedings of the 33rd Chinese Control and Decision Conference (CCDC)*. IEEE, 2021, pp. 5181–5184.

[20] J. Terven, D. M. Córdova-Esparza, and J. A. Romero-González, “A comprehensive review of yolo architectures in computer vision: from yolov1 to yolov8 and yolo-nas,” *Machine Learning and Knowledge Extraction*, vol. 5, no. 4, pp. 1680–1737, 2023.

[21] X. Zheng, H. Wang, Y. Shang, G. Chen, S. Zou, and Q. Yuan, “Starting from the structure: A review of small object detection based on deep learning,” *Image and Vision Computing*, vol. 146, p. 105054, 4 2024.

[22] A. Rawat, A. Sharma, A. K. Awasthi, A. Sharma, S. S. Tiang, and W. H. Lim, “Review of recent trends in sensing methodologies and ai techniques for non-cooperative aerial target recognition,” *International Journal of Mathematical, Engineering and Management Sciences*, vol. 11, no. 2, pp. 566–611, 4 2026.

[23] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 6 2016, pp. 779–788.

[24] G. Jocher, A. Chaurasia, and J. Qiu, “Ultralytics YOLOv8,” https://github.com/ultralytics/ultralytics, 2023, acessado em: 06 nov. 2026.

[25] Z. Wang, F. Meng, G. Wang, X. Li, and S. Zhang, “Research on classification of chinese herbal medicine pieces based on fusion of yolov8n and hsv,” in *Proceedings of the 2025 4th International Symposium on Robotics, Artificial Intelligence and Information Engineering (RAIIE)*. IEEE, 2025, pp. 72–77.

[26] A. Wang, H. Chen, L. Liu, K. Chen, Z. Lin, J. Han, and G. Ding, “YOLOv10: Real-time end-to-end object detection,” *arXiv preprint arXiv:2405.14458*, 2024.

[27] G. Jocher and J. Qiu, “Ultralytics YOLO11,” https://github.com/ultralytics/ultralytics, 2024, acessado em: 06 nov. 2026.

[28] D. M. Zhexebay, A. A. Skabylov, D. A. Turlykozhayeva, A. Bolysbay, U. K. Turmaganbet, T. Namazbayev, and M. Tao, “Real-time small object detection with yolov8n/8s and yolov11n/11s models in complex natural landscapes,” *Physical Sciences and Technology*, vol. 12, no. 1-2, pp. 142–153, 6 2025.

[29] G. Jocher and J. Qiu, “Ultralytics YOLO26,” https://github.com/ultralytics/ultralytics, 2026, acessado em: 06 nov. 2026.

[30] R. Padilla, W. L. Passos, T. L. B. Dias, S. L. Netto, and E. A. B. da Silva, “A comparative analysis of object detection metrics with a companion open-source toolkit,” *Electronics*, vol. 10, no. 3, p. 279, 2021.

[31] Ultralytics, “YOLO Performance Metrics and Model Evaluation,” https://docs.ultralytics.com/guides/yolo-performance-metrics/, 2024, acessado em: 06 nov. 2026.

[32] M. H. Franco, “Análise comparativa de desempenho entre o filtro de kalman estendido e a fusão madgwick-kalman na navegação inercial de vants,” Joinville, SC, Brasil, 2025.

[33] P. Kim, *Kalman Filter for Beginners: With MATLAB Examples*. CreateSpace Independent Publishing Platform, 2011.

[34] V. Kordic, Ed., *Kalman Filter*. Rijeka, Croatia: InTech, 2010.

[35] F. B. Vidal and V. H. Casanova Alcalde, “Window-matching techniques with kalman filtering for an improved object visual tracking,” in *Proceedings of the IEEE Conference on Automation Science and Engineering (CASE)*, 2007, pp. 829–834.

[36] C. Lopez-Franco, J. Gomez-Avila, A. Y. Alanis, N. Arana-Daniel, and C. Villaseñor, “Visual servoing for an autonomous hexarotor using a neural network based pid controller,” *Sensors*, vol. 17, no. 8, p. 1865, 8 2017.

[37] T. F. Pramono, “Hybrid pbvs-ibvs model predictive visual servoing for autonomous docking of a free-flying robot,” Master’s Thesis, KTH Royal Institute of Technology, Stockholm, Sweden, 2025.

[38] B. Luo, H. Chen, F. Quan, S. Zhang, and Y. Liu, “Natural feature-based visual servoing for grasping target with an aerial manipulator,” *Journal of Bionic Engineering*, vol. 17, no. 2, pp. 215–228, 3 2020.

[39] S. Hutchinson, G. Hager, and P. Corke, “A tutorial introduction to visual servo control,” *IEEE Transactions on Robotics and Automation*, vol. 12, no. 5, pp. 651–670, 1996.

[40] F. Chaumette, S. Hutchinson, and P. Corke, “Visual servoing,” in *Springer handbook of robotics*. Springer, 2016, pp. 841–866.

[41] A. H. A. Hafez, E. Cervera, and C. V. Jawahar, “Stable hybrid visual servo control by a weighted combination of image-based and position-based algorithms,” *International Journal of Control and Automation*, vol. 6, no. 3, pp. 149–164, 2013.

[42] A. Keipour, G. A. S. Pereira, R. Bonatti, R. Garg, P. Rastogi, G. Dubey, and S. Scherer, “Visual servoing approach to autonomous uav landing on a moving vehicle,” *Sensors*, vol. 22, no. 17, p. 6549, 9 2022.

[43] R. Ladig, H. Paul, R. Miyazaki, and K. Shimonomura, “Aerial manipulation using multirotor uav: A review from the aspect of operating space and force,” *Journal of Robotics and Mechatronics*, vol. 33, no. 2, pp. 196–204, 2021.

[44] J. Thomas, G. Loianno, K. Sreenath, and V. Kumar, “Toward image based visual servoing for aerial grasping and perching,” in *Proceedings of the 2014 IEEE International Conference on Robotics and Automation (ICRA)*. Hong Kong, China: IEEE, 2014, pp. 2113–2118.

[45] E. Bauer, B. G. Cangan, and R. K. Katzschmann, “Autonomous marker-less rapid aerial grasping,” in *2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2023.

[46] S. Ubellacker, A. Ray, J. M. Bern, J. Strader, and L. Carlone, “High-speed aerial grasping using a soft drone with onboard perception,” *npj Robotics*, vol. 2, no. 1, p. 5, 8 2024.

[47] L. Shen, B. Lang, and Z. Song, “Ds-yolov8-based object detection method for remote sensing images,” *IEEE Access*, vol. 11, pp. 125 122–125 137, 2023.

[48] Y. Zhang, J. Wang, J. Chen, D. Shi, and X. Chen, “A space non-cooperative target recognition method for multi-satellite cooperative observation systems,” *Remote Sensing*, vol. 16, no. 18, p. 3368, 9 2024.



APPENDICES

Appendix A - Título do apêndice A

Os apêndices são materiais suplementares **elaborados pelo próprio autor**, que contribuem para a compreensão, fundamentação ou detalhamento do trabalho, mas que não são essenciais para o desenvolvimento principal do texto.

Eles podem incluir, por exemplo:

- Questionários e roteiros de entrevistas utilizados na pesquisa;
- Documentos, códigos-fonte, tabelas extensas ou informações complementares;
- Detalhes técnicos ou cálculos que, se inseridos no corpo principal, tornariam a leitura cansativa;
- Materiais que apoiam a metodologia ou os resultados, mas que não são obrigatórios para a compreensão geral.

Cada apêndice deve ser identificado por uma letra maiúscula (Apêndice A, Apêndice B, etc.) e ter um título claro e objetivo. Eles são inseridos após as referências bibliográficas e antes do índice remissivo, se houver.

A inclusão dos apêndices deve ser feita de maneira organizada e referenciada no texto principal, para que o leitor saiba quando e por que consultar esses materiais complementares.

ANNEXES

Annex A - Título do Anexo A

Os anexos são documentos, materiais ou informações que **não foram elaborados pelo autor do trabalho**, mas que servem para complementar, ilustrar ou fundamentar o conteúdo apresentado.

Exemplos comuns de anexos incluem:

- Legislações, normas técnicas ou regulamentos;
- Manuais, folhetos, publicações oficiais;
- Textos, tabelas ou documentos externos que deram suporte à pesquisa;
- Materiais gráficos ou audiovisuais cedidos por terceiros.

Assim como os apêndices, os anexos são organizados em sequência e identificados por letras maiúsculas (Anexo A, Anexo B, etc.), com títulos claros.

Eles são inseridos após os apêndices (quando houver) ou diretamente após as referências bibliográficas, e devem ser referenciados no corpo do trabalho para que o leitor saiba quando consultá-los.



idp

Ensino que
te **conecta**