Ensino que te conecta

BACHARELADO EM

CIÊNCIA DA COMPUTAÇÃO

SISTEMA AUTÔNOMO DE CAPTURA DE OBJETOS NÃO COOPERATIVOS POR VANTS UTILIZANDO SERVOVISÃO

GABRIEL QUEIROZ TELES

Brasília - DF, 2026

GABRIEL QUEIROZ TELES

SISTEMA AUTÔNOMO DE CAPTURA DE OBJETOS NÃO COOPERATIVOS POR VANTS UTILIZANDO SERVOVISÃO

Undergraduate Thesis submitted in partial fulfillment of the requirements for the degree of Bachelor of at the Brazilian Institute of Education, Development and Research (IDP).

Advisor

Patrícia da Silva Oliveira

Brasília - DF, 2026

GABRIEL QUEIROZ TELES

SISTEMA AUTÔNOMO DE CAPTURA DE OBJETOS NÃO COOPERATIVOS POR VANTS UTILIZANDO SERVOVISÃO

Undergraduate Thesis submitted in partial fulfillment of the requirements for the degree of Bachelor of at the Brazilian Institute of Education, Development and Research (IDP).

Approved on 08/05/2025

Examining Committee

Patrícia da Silva Oliveira (Advisor) - IDP

Dr. Dom Quixote de la Mancha (Internal Member) - IDP

Dra. Anna Karienina (Internal Member) - IDP

DEDICATÓRIA

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

AGRADECIMENTOS

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

ABSTRACT

The autonomous capture of non-cooperative targets by Unmanned Aerial Vehicles (UAVs) faces critical challenges due to the semantic gap of classical vision algorithms and the computational latency that destabilizes the aircraft. To overcome these limitations, this work develops a real-time Position-Based Visual Servoing (PBVS) system for the approach and capture of objects using an underside gripper. The architecture integrates deep learning models from the YOLO family for robust, marker-less target detection. To mitigate occlusions and noise caused by the rotors, an Extended Kalman Filter (EKF) acts in the image plane as a kinematic predictor. The two-dimensional coordinates are converted to metric three-dimensional space via the Pinhole model, feeding a cascaded Proportional-Derivative (PD) flight controller responsible for compensating visual latency. The system was modeled in a Software-in-the-Loop (SITL) simulation environment using ROS and Gazebo. The project targets a visual processing rate above 20 FPS, a 20% reduction in trajectory error (RMSE), overshoot maintenance below 15%, and a final approach precision of 0.30 meters, validating a viable and stable solution for autonomous aerial manipulation.

Keywords: Unmanned Aerial Vehicles. Visual Servoing. YOLO. Kalman Filter. Aerial Manipulation..

RESUMO

A captura autônoma de alvos não cooperativos por Veículos Aéreos Não Tripulados (VANTs) enfrenta desafios críticos devido à lacuna semântica dos algoritmos de visão clássicos e à latência computacional que desestabiliza a aeronave. Para superar essas limitações, este trabalho desenvolve um sistema de Servovisão Baseada em Posição (PBVS) em tempo real para a aproximação e captura de objetos utilizando uma garra inferior (underside). A arquitetura integra modelos de aprendizado profundo da família YOLO para a detecção robusta e sem marcadores do alvo. Para mitigar oclusões e ruídos causados pelos rotores, um Filtro de Kalman Estendido (EKF) atua no plano da imagem como previsor cinemático. As coordenadas bidimensionais são convertidas para o espaço tridimensional métrico via modelo Pinhole, alimentando um controlador de voo Proporcional-Derivativo (PD) em cascata responsável por compensar a latência visual. O sistema foi modelado em ambiente de simulação Software-in-the-Loop (SITL) utilizando ROS e Gazebo. O projeto estabelece como metas o processamento visual superior a 20 FPS, a redução de 20% no erro de trajetória (RMSE), a manutenção do sobressinal (overshoot) abaixo de 15% e uma precisão final de aproximação de 0,30 metros, validando uma solução viável e estável para a manipulação aérea autônoma.

Palavras-chave: Veículos Aéreos Não Tripulados. Servovisão. YOLO. Filtro de Kalman. Manipulação Aérea..

LIST OF FIGURES

1 Eixos de rotação e convenção de atitude angular (rolagem, arfagem e guinada) em um multirrotor 8

2 Disposição motopropulsora e sentidos de rotação das hélices na configuração coaxial Octaquad X 9

3 Diagrama em blocos da arquitetura de hardware e malha inercial de baixo nível do VANT..... 11

4 Arquitetura conceitual da família YOLO, ilustrando a divisão da imagem em grade espacial e a regressão direta das caixas delimitadoras 13

5 Exemplo prático de detecção de alvos em imagens aéreas obtidas por VANT utilizando modelos YOLO 17

6 Fluxograma do algoritmo do Filtro de Kalman Estendido (EKF). 19

7 Qualitative comparison between the classical Image-Based Visual Servoing (IBVS) and Position-Based Visual Servoing (PBVS) schemes..... 22

8 Geometric representation of perspective projection based on the Pinhole camera model, illustrating the relationship between focal length and the conversion of a point in space onto the two-dimensional image plane 23

9 Aerial manipulation using attached grippers..... 25

10 UAV equipped with an articulated robotic arm 25

11 Cable-suspended aerial manipulation system 26

12 Rigid-tool aerial manipulation system mounted on the UAV frame 27

13 Classification of operational spaces in aerial manipulation systems 28

14 Comparison between Kalman Filter estimation and object detection output for the width and height of the bounding box 32

LIST OF TABLES

1 Comparative Analysis of Related Works..... 37

CONTENTS

1 Introduction 2

2 Literature Review 7

2.1 Theoretical Foundation 7

2.1.1 Veículos Aéreos Não Tripulados (VANTs) 7

2.1.2 Visão Computacional Aplicada a VANTs 11

2.1.3 Visual Servoing 20

2.1.4 Aerial Capture and Manipulation Systems 24

2.2 Related Works 28

2.2.1 Autonomous Object Capture by UAVs 28

2.2.2 Object Detection and Tracking in UAVs 30

2.2.3 Visual Servoing Applied to UAVs 34

2.2.4 Comparative Analysis of Related Works 37

3 Methodology 42

4 Results and Discussion 44

5 Conclusion 46

References 47

Appendices 52

Appendix A - Título do apêndice A 53

Annexes 54

A Título do Anexo A 55


1

1 INTRODUCTION

O avanço tecnológico dos Veículos Aéreos Não Tripulados (VANTs) aumentou bastante suas possibilidades de aplicação, o que permitiu superar as limitações de mobilidade dos robôs terrestres em tarefas como inspeção, agricultura e transporte de objetos para locais inacessíveis [1]. Com essa evolução, os VANTs deixaram de funcionar só como plataformas de observação e passaram a ser capazes de executar tarefas autônomas que envolvem interação física com o ambiente, como missões de *pick-and-place*, focadas na captura e posicionamento de objetos [2, 3]. A execução autônoma dessas tarefas exige o desenvolvimento de algoritmos de controle que permitam ao robô operar com segurança [1]. Além disso, em ambientes nos quais os sistemas de navegação global (GPS) não oferecem a precisão necessária para o alinhamento de uma garra robótica, o servocontrole visual, também chamado de servovisão, surge como a solução mais viável, utilizando o retorno visual de câmeras embarcadas para orientar o VANT [4].

A captura autônoma de um alvo não cooperativo, como uma gaiola ou um bloco sólido preto sem marcadores visuais, impõe desafios significativos aos métodos clássicos de percepção e à estabilidade da aeronave [5]. A motivação para investigar esse problema está relacionada à vulnerabilidade dos sistemas tradicionais de visão quando operam em ambientes externos e não estruturados [5]. No que diz respeito à percepção, algoritmos baseados exclusivamente em modelos de espaço de cores, como HSV, são altamente sensíveis às variações de iluminação. Da mesma forma, técnicas clássicas de extração de características geométricas, como SIFT, SURF e HOG, combinadas com estratégias de varredura por janelas deslizantes, exigem esforço computacional redundante e apresentam dificuldades para modelar a diversidade dos planos de fundo das imagens [5]. Como consequência, essas abordagens clássicas frequentemente sofrem com a chamada lacuna semântica (*semantic gap*), demonstrando incapacidade de abstrair o contexto da cena, o que leva o sistema a confundir a ausência de luz em um objeto escuro com sombras ou ruídos do próprio ambiente [5].

Em relação ao controle, a servovisão sofre com atrasos, uma vez que o processamento de imagens é computacionalmente intensivo e opera em frequências significativamente inferiores às dos sensores inerciais de voo. Isso resulta em um período de amostragem elevado e, consequentemente, gera intervalos sem retorno visual [4].

Além disso, a estratégia de captura adotada neste trabalho propõe que o VANT se posicione fisicamente sobre o alvo, acomodando a gaiola entre seus trens de pouso, de modo que garras robóticas possam ser alinhadas a pontos específicos de captura. Essa abordagem mecânica exige que o sistema visual forneça não apenas o posicionamento global da estrutura, mas também referências para o alinhamento preciso da orientação (*yaw*) durante a descida.

Diante da necessidade de superar essas limitações tecnológicas, surge a seguinte questão de pesquisa: como algoritmos de detecção baseados em aprendizado profundo podem ser integrados a estratégias de controle dinâmico para realizar a captura autônoma de um alvo não cooperativo por um VANT, mitigando as interferências de iluminação e os atrasos no processamento de imagens e assegurando o alinhamento físico das garras robóticas?

Para contextualizar o problema abordado, este trabalho está inserido no projeto VTS (*Vector Tracking System*), financiado pela Fundação de Apoio à Pesquisa do Distrito Federal (FAPDF) e desenvolvido pelo IDP em parceria com a Universidade de Brasília (UnB) e a Fiocruz. O projeto tem como objetivo central a vigilância e o mapeamento automatizado do mosquito *Aedes aegypti*. Nesse contexto, que envolve diferentes tecnologias, como armadilhas inteligentes, telemetria LoRaWAN, modelos de classificação biológica e aeronaves autônomas, este trabalho concentra-se no desenvolvimento de um sistema de transporte e captura aérea. Enquanto outras frentes do projeto são responsáveis pelo desenvolvimento da eletrônica embarcada e dos sensores das armadilhas, esta pesquisa aborda os mecanismos de percepção visual e controle de voo necessários para que um VANT seja capaz de localizar a estrutura da armadilha, ajustar sua posição e realizar o acoplamento físico de forma autônoma. Com isso, busca-se contribuir para a implantação e o recolhimento desses dispositivos, especialmente em locais remotos ou de difícil acesso.

Para enfrentar os desafios relacionados à detecção, a literatura tem se concentrado cada vez mais em modelos de aprendizado profundo (*Deep Learning*) [6]. Nesse contexto, a família YOLO (*You Only Look Once*) de redes neurais convolucionais destaca-se por realizar a detecção de objetos em uma única passagem pela rede, proporcionando um equilíbrio entre precisão e velocidade de processamento [6–8]. Considerando a evolução dessas arquiteturas e a necessidade de atender às restrições computacionais de sistemas embarcados em VANTs, torna-se relevante investigar o desempenho de diferentes gerações desses modelos. Assim, este trabalho propõe uma avaliação comparativa das arquiteturas YOLOv8n, YOLOv10n, YOLO11n e YOLO26n, buscando identificar aquela que oferece o melhor equilíbrio entre precisão e custo computacional para a detecção embarcada de gaiolas.

Embora as redes neurais ofereçam alta precisão na extração de características semânticas, a percepção visual em VANTs é frequentemente afetada por ruídos dinâmi-

cos. A detecção de objetos com VANTs está sujeita a falhas momentâneas e mudanças abruptas nas caixas delimitadoras devido às vibrações que ocorrem durante o voo [9]. Para atenuar essas falhas e as oscilações ruidosas das redes neurais aplicadas a drones, o filtro de Kalman tem sido utilizado como uma solução eficaz [9]. Essa técnica de estimação permite obter uma aproximação contínua e confiável não apenas da posição do alvo, mas também de sua velocidade cinemática, compensando as deficiências geradas durante períodos de perda do rastreamento visual [9].

Além da filtragem do sinal visual, o referencial espacial adotado para a navegação representa outro desafio. Isso decorre das limitações de implementar o laço de controle do VANT exclusivamente no plano bidimensional da imagem (2D). Quando a navegação se baseia apenas em coordenadas de pixels, o sistema torna-se suscetível à ambiguidade de profundidade e sensível a incertezas geométricas, uma vez que variações de altitude alteram a escala do objeto na imagem capturada pela câmera. Nesse contexto, existem vantagens significativas na aplicação do modelo analítico de câmera Pinhole [10, 11]. O uso de matrizes de transformação geométrica permite converter diretamente as coordenadas dos pixels em um espaço cartesiano métrico tridimensional (3D), reduzindo a sensibilidade a incertezas durante a fase de aproximação e proporcionando uma dinâmica de voo substancialmente mais estável [11].

Com base nesse cenário, a principal hipótese deste trabalho é que a integração de um algoritmo de detecção de objetos para o isolamento semântico de um alvo não cooperativo, operando em série com um filtro de Kalman e uma transformação espacial de 2D para 3D baseada no modelo Pinhole, pode mitigar o ruído visual e permitir o controle de voo estável necessário à execução de um sistema autônomo de captura de objetos utilizando VANTs e servovisão. Além disso, considera-se a hipótese de que, ao fornecer ao laço de controle de um controlador PD (*Proportional-Derivative*) em cascata a velocidade filtrada extraída pelo estimador, o sistema será capaz de compensar os atrasos de amostragem da câmera e suprimir a ultrapassagem do ponto de referência (*overshoot*) causada pelo termo integral tradicional [4, 11, 12].

Diante do exposto, o objetivo geral desta monografia é desenvolver e validar um sistema autônomo de captura de objetos utilizando VANTs e servovisão, visando à busca, à aproximação e ao alinhamento com um objeto não cooperativo para a realização da captura em ambiente simulado. Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos:

- Treinar e comparar quatro gerações da família YOLO (v8n, v10n, v11n e v26n) em duas fases de voo, buscando alcançar uma precisão média ($mAP@50$) superior a 90% na detecção da armadilha e das alças, mantendo o processamento acima de 20 quadros por segundo (20 FPS) para guiar o drone em tempo real;
- Implementar filtros de Kalman para eliminar os tremores da detecção visual e

suavizar a leitura do ângulo de rotação, garantindo que o drone mantenha sua trajetória estável por até 4,0 segundos de predição caso a câmera perca a visão do alvo temporariamente;

- Converter as coordenadas da imagem em distâncias reais em metros e aplicar uma regra de histerese visual (zona segura nos 40% centrais da tela e bloqueio de descida se o erro passar de 60%), garantindo que a armadilha permaneça 100% do tempo dentro do campo de visão da câmera durante a descida de 18 a 2 metros;

- Projetar uma estratégia de voo em cascata (estabilização de atitude a 400 Hz no piloto automático e navegação visual a 20 Hz) que evite oscilações bruscas na aproximação e faça o drone girar autonomamente para se alinhar à tampa da armadilha, atingindo um erro angular de guinada (*Yaw*) inferior a 1,0 grau;

- Validar a missão autônoma completa no simulador, comprovando uma taxa de sucesso superior a 60% no acoplamento, com alinhamento fino cravado sobre o ponto de captura com margem de erro milimétrica (inferior a 8 mm sustentada por 1,5 segundo), seguido de uma descida cega vertical para a conclusão da missão.

A metodologia desta pesquisa caracteriza-se como um estudo de modelagem e validação realizado integralmente em ambiente de simulação. Inicialmente, são coletadas imagens para o treinamento e a avaliação de diferentes arquiteturas de detecção de objetos baseadas em aprendizado profundo (família YOLO), comparando seu desempenho em termos de precisão e custo computacional. Em seguida, é implementado um filtro de Kalman para a estimação de estados e atenuação do ruído visual, bem como uma transformação espacial baseada no modelo de câmera Pinhole com compensação do deslocamento físico da lente para converter coordenadas bidimensionais em distâncias métricas tridimensionais. Posteriormente, é desenvolvida uma estratégia de controle de voo baseada em controladores PD, utilizando as estimativas para orientar a aproximação translacional e o alinhamento angular de guinada (*Yaw*) do VANT em relação ao alvo. Por fim, os componentes são integrados utilizando o ecossistema do ROS 2 para o transporte dos dados de visão da câmera simulada no Gazebo, enquanto a dinâmica de voo é governada pelo piloto automático ArduPilot em arquitetura *Software-in-the-Loop* (SITL). A comunicação de controle e telemetria entre o algoritmo em Python e o firmware ArduPilot é realizada de forma direta pelo protocolo MAVLink (via DroneKit/PyMAVLink), garantindo a troca de comandos de velocidade e estados de navegação em tempo real.



2

2 LITERATURE REVIEW

2.1 THEORETICAL FOUNDATION

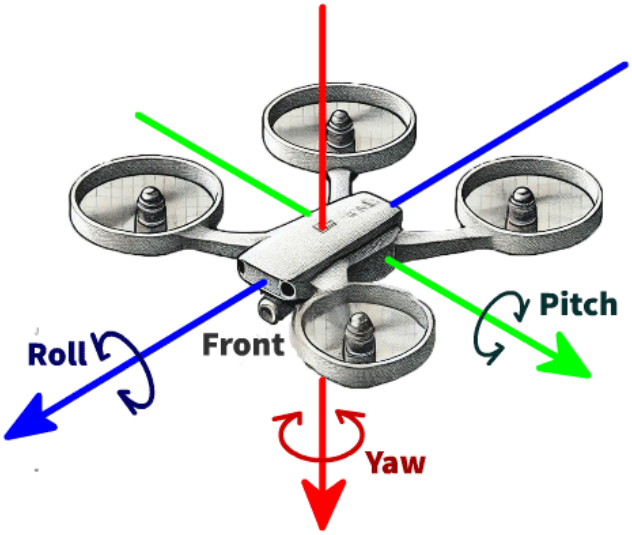
2.1.1 Veículos Aéreos Não Tripulados (VANTs)

Os Veículos Aéreos Não Tripulados (VANTs), popularmente conhecidos como *drones*, são aeronaves projetadas para operar sem a presença de um piloto a bordo. Seu controle pode ser realizado remotamente, por meio de uma estação de controle em solo (*Ground Control Station* – GCS), ou de forma totalmente autônoma, utilizando computadores de bordo e sensores de navegação [13]. Na literatura aeronáutica, essas aeronaves são geralmente classificadas de acordo com seu sistema de sustentação em três categorias: asa fixa, asas rotativas (multirrotores) e configurações híbridas [1]. Os VANTs de asa fixa possuem características semelhantes às de aviões convencionais, apresentando maior autonomia de voo e velocidade de deslocamento. Entretanto, precisam de pistas ou lançadores para operar e não conseguem permanecer parados no ar. Já os VANTs de asas rotativas utilizam a rotação de seus motores e hélices para gerar a força necessária à sustentação. Entre suas principais características estão a capacidade de decolagem e pouso vertical (VTOL, do inglês *Vertical Take-Off and Landing*) e a possibilidade de manter uma posição estável no ar, capacidade conhecida como voo pairado (*hovering*) [3].

Em missões que envolvem manipulação aérea e captura de objetos não cooperativos, a capacidade de manter um voo pairado estável e realizar movimentos precisos em baixas velocidades é fundamental. Essas características permitem alinhar os mecanismos de captura e aproximar a aeronave do objeto de maneira controlada e suave [3, 13, 14]. Para descrever os movimentos e as forças que atuam nessas aeronaves, a literatura utiliza o formalismo de Newton–Euler, que representa o VANT como um corpo rígido em um espaço tridimensional. Essa modelagem considera dois referenciais cartesianos principais: um referencial inercial fixo à Terra (F_0) e outro associado ao centro de massa da aeronave (F_b) [15]. O movimento da aeronave é descrito por seis Graus de Liberdade (6 DoF, do inglês *Degrees of Freedom*), divididos em três movimentos de translação (x, y, z) e três movimentos de rotação, representados pelos ângulos de Euler: rolagem (*roll*, ϕ), arfagem (*pitch*, θ) e guinada (*yaw*, ψ), conforme

apresentado na Figura 1 [16].

Figure 1: Eixos de rotação e convenção de atitude angular (rolagem, arfagem e guinada) em um multirrotor

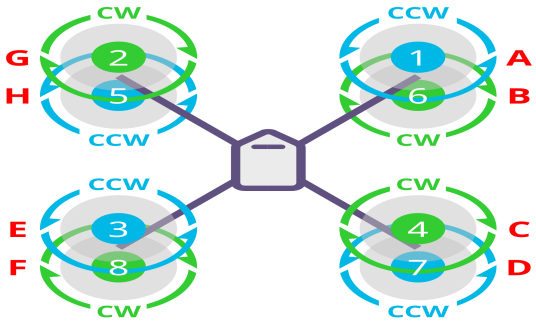


Fonte: adaptado de [17].

A matriz de rotação direcional permite converter as coordenadas do referencial do corpo (F_b) para o referencial inercial (F_0), sendo importante para representar as forças de empuxo e os vetores de velocidade no espaço. Embora o quadricóptero convencional, apresentado na Figura 1, seja frequentemente utilizado como modelo de referência para o estudo da cinemática e das rotações de atitude, missões que envolvem contato físico exigem maior capacidade de carga útil (*payload*) e maior capacidade de geração de empuxo. Isso ocorre devido à necessidade de transportar sensores e mecanismos de captura, como garras robóticas. Nesse contexto, a literatura destaca o uso de configurações coaxiais contra-rotativas, especialmente o arranjo *Octaquad X*, ilustrado na Figura 2 [3, 14].

Nessa configuração, oito motores sem escovas (*brushless*) são distribuídos em pares coaxiais sobre quatro braços mecânicos em X. Em cada braço, as hélices superior e inferior giram em sentidos opostos: horário (*Clockwise* – CW) e anti-horário (*Counter-Clockwise* – CCW). Esse arranjo contra-rotativo compensa os torques de reação do arrasto das pás, eliminando giros indesejados no eixo vertical (z) em voo pairado. O controle coordenado da velocidade dos motores gera os torques de atitude: a guinada (τ_ψ) decorre da diferença entre os conjuntos horários e anti-horários, enquanto a rolagem (τ_ϕ) e a arfagem (τ_θ) resultam do empuxo diferencial entre os braços opostos da estrutura [16].

Figure 2: Disposição motopropulsora e sentidos de rotação das hélices na configuração coaxial Octaquad X



Fonte: adaptado de [18].

Uma das principais dificuldades na modelagem e no controle de sistemas multirrotores está relacionada ao fato de serem sistemas subatuados. Embora possuam seis graus de liberdade de movimento no espaço, esses sistemas contam com apenas quatro entradas de controle independentes: a força de empuxo vertical total e os três torques de atitude ($\tau_\phi, \tau_\theta, \tau_\psi$). Como os vetores de empuxo gerados pelos motores atuam paralelamente ao eixo vertical (z) do corpo da aeronave [16], o VANT não consegue gerar diretamente forças horizontais nos eixos globais x e y. Dessa forma, para se deslocar para frente, para trás ou para os lados durante a aproximação ao alvo, a aeronave precisa inclinar sua estrutura em rolagem ou arfagem. Essa inclinação altera a direção do vetor de empuxo total, fazendo com que parte da força seja direcionada horizontalmente e produza a aceleração necessária ao movimento [3, 16].

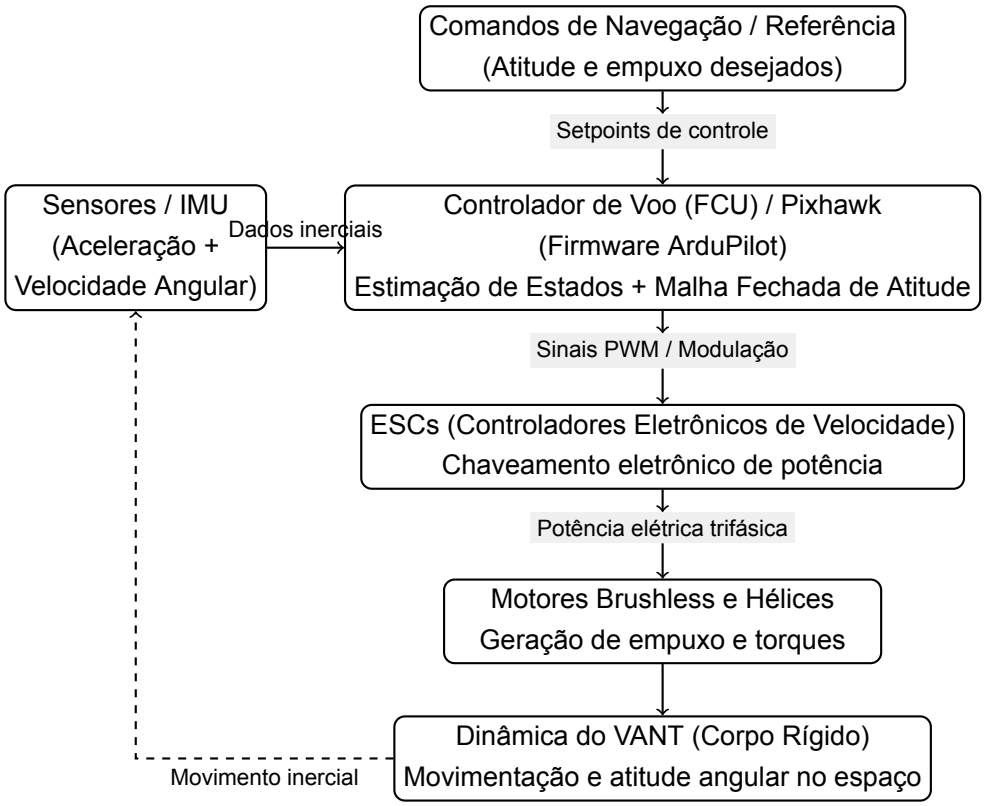
Essa limitação faz com que as variáveis de movimento da aeronave estejam fortemente acopladas, tornando sua dinâmica altamente não linear [19]. Esse comportamento exige atenção especial durante a aproximação final e descida vertical em direção ao alvo, etapa na qual o VANT precisa realizar correções translacionais contínuas em baixas velocidades para garantir o alinhamento da estrutura sobre o ponto de pouso [3]. Como a aeronave precisa inclinar constantemente sua fuselagem em rolagem ou arfagem para efetuar esses deslocamentos horizontais, uma câmera rigidamente fixada à estrutura sofreria oscilações angulares recorrentes. Essas inclinações desviariam o eixo óptico da vertical, distorcendo o enquadramento do alvo e podendo ocasionar sua perda do campo de visão (*Field of View* – FOV). Por esse motivo, recomenda-se o emprego do *gimbal* de três eixos estabilizado ativamente a câmera e garantindo o enquadramento ortogonal e contínuo do alvo durante toda a descida [4].

Para lidar com essas não linearidades e rejeitar distúrbios aerodinâmicos externos,

como rajadas de vento e turbulências em baixas altitudes, a literatura adota estratégias de controle organizadas em cascata [19]. Nesse tipo de arquitetura, a malha interna de controle atua em alta frequência, permitindo corrigir rapidamente pequenos desvios angulares e manter a plataforma inercialmente estável. Essa estabilização é essencial para mitigar vibrações transmitidas ao conjunto óptico, assegurando que a malha externa de servovisão e o modelo de aprendizado profundo recebam imagens nítidas ao longo da aproximação. Para operacionalizar esse esquema em cascata, a arquitetura de hardware e software do robô é dividida em dois níveis de processamento: controle inercial de baixo nível e navegação autônoma de alto nível [4, 16].

O controle inercial de baixo nível é realizado por uma Unidade Controladora de Voo (FCU, do inglês *Flight Control Unit*), sendo o ecossistema Pixhawk uma das plataformas de hardware de código aberto mais utilizadas na robótica aérea [4]. Essa controladora executa firmwares especializados no controle de voo, entre os quais se destaca o ArduPilot [16]. Conforme apresentado no diagrama em blocos da Figura 3, essa arquitetura funciona em malha fechada. A Unidade de Medição Inercial (IMU, do inglês *Inertial Measurement Unit*) mede a aceleração e a velocidade angular da fuselagem em altas taxas de amostragem. Com base nessas informações e nas referências de navegação recebidas do nível superior, a FCU calcula as correções necessárias e envia sinais de modulação por largura de pulso (PWM) aos Controladores Eletrônicos de Velocidade (ESCs, do inglês *Electronic Speed Controllers*). Esses controladores regulam a potência elétrica fornecida aos motores sem escovas (*brushless*), ajustando suas velocidades de rotação. As forças de empuxo geradas pelos motores atuam sobre a estrutura do VANT, permitindo corrigir sua atitude e compensar as perturbações que afetam o voo [16].

Figure 3: Diagrama em blocos da arquitetura de hardware e malha inercial de baixo nível do VANT



Fonte: elaboração própria.

2.1.2 Visão Computacional Aplicada a VANTs

Para viabilizar a aproximação autônoma e a captura de alvos não cooperativos, o sistema de percepção visual atua como o principal mecanismo de identificação e estimação de estados no ambiente. Tradicionalmente, a detecção de objetos baseava-se em métodos clássicos de visão computacional, como a segmentação por cor ou o reconhecimento de padrões geométricos pré-definidos [5]. No espaço de cores HSV (*Hue, Saturation, Value*), por exemplo, a imagem é decomposta em matiz, saturação e brilho para isolar o objeto por contraste de cor. Outra abordagem clássica consiste em extrair características geométricas da cena, como bordas, cantos e texturas, utilizando descritores manuais tradicionais, entre eles SIFT (*Scale-Invariant Feature Transform*), SURF (*Speeded-Up Robust Features*) e HOG (*Histogram of Oriented Gradients*) [5,6].

Com esses descritores geométricos, a detecção geralmente utiliza a técnica de janela deslizante (*sliding window*), que varre a imagem avaliando diversas regiões em diferentes escalas e posições [5,6]. Para cada sub-região amostrada, um classificador supervisionado, como as Máquinas de Vetores de Suporte (SVM, do inglês *Support*

Vector Machines), analisa os atributos extraídos e indica a probabilidade de presença do objeto [5, 6]. O principal inconveniente dessa abordagem reside na rigidez das regras formuladas manualmente, que têm baixa capacidade de generalização diante de mudanças no ambiente. Além disso, avaliar exaustivamente milhares de janelas por quadro impõe um custo computacional muito alto, tornando essa técnica inviável para sistemas aéreos que precisam de respostas rápidas em tempo real [5].

Em ambientes externos, esses métodos clássicos também sofrem com a chamada lacuna semântica (*semantic gap*) [5]. Como operam a partir de características de baixo nível (como pixels, linhas e gradientes locais), os algoritmos não conseguem construir representações conceituais robustas e invariantes do alvo. Em condições reais de voo, com variações constantes de iluminação solar, reflexos e sombras no solo, o sistema torna-se vulnerável a falsos positivos e à perda frequente do objeto rastreado [5].

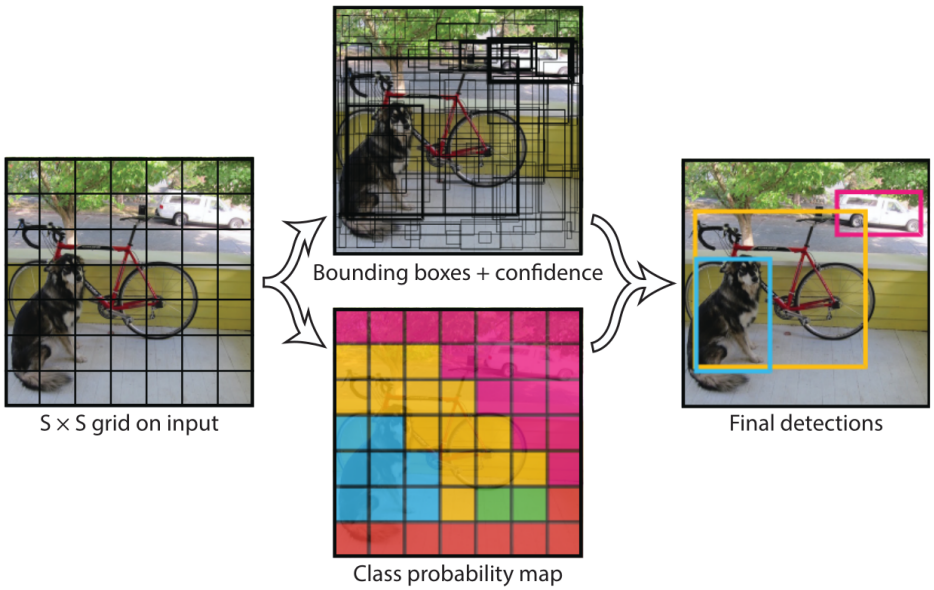
Para contornar as limitações da visão clássica, consolidou-se na literatura o uso de Aprendizado Profundo (*Deep Learning*) por meio de Redes Neurais Convolucionais (CNNs, do inglês *Convolutional Neural Networks*). No campo da detecção de objetos, esses modelos se dividem basicamente em duas categorias: os de dois estágios (*two-stage*), a exemplo da Faster R-CNN, e os de estágio único (*single-stage*) [5, 6, 20]. Os detectores de dois estágios geram inicialmente regiões candidatas de interesse para depois classificá-las e ajustar suas coordenadas. Embora alcancem alta precisão geométrica, esse processamento em etapas consecutivas gera latência elevada, inviabilizando a execução em tempo real nos computadores embarcados de VANTs [6].

Buscando maior velocidade, surgiram detectores de estágio único como o SSD (*Single Shot MultiBox Detector*) e a CenterNet. O SSD, contudo, apresenta dificuldades inerentes na detecção de alvos em escalas reduzidas [6], enquanto a CenterNet, apesar de dispensar caixas âncora, perde robustez quando o fundo da imagem é muito texturizado [21]. Paralelamente, o emprego de *Vision Transformers* (ViTs) e de arquiteturas como o DETR (*Detection Transformer*) trouxe avanços importantes na compreensão global da cena [6]. Entretanto, a alta demanda de operações em ponto flutuante exigida pelos mecanismos de atenção densa reduz drasticamente a taxa de quadros por segundo (FPS) em hardwares embarcados sob restrições Low-SWaP (*Low Size, Weight, and Power*), o que limita sua aplicação direta em malhas críticas de servovisão aérea [22].

Diante dessas restrições de processamento e da necessidade de rastreamento contínuo, a família de algoritmos YOLO (*You Only Look Once*) consolidou-se como a principal escolha na robótica aérea. Diferente dos detectores de dois estágios, o YOLO formula a detecção como um único problema de regressão espacial: em uma única passagem direta (*forward pass*) pela rede, o modelo extrai mapas de características e prevê conjuntamente as coordenadas das caixas delimitadoras (*bounding boxes*) e as probabilidades de cada classe [6, 7]. A Figura 4 ilustra o princípio conceitual da

arquitetura, mostrando a divisão da imagem de entrada em uma grade regular ($S \times S$) para a predição paralela e direta das caixas e de suas confianças [23].

Figure 4: Arquitetura conceitual da família YOLO, ilustrando a divisão da imagem em grade espacial e a regressão direta das caixas delimitadoras



Fonte: adaptado de [23].

Ao longo da evolução dessa família, o YOLOv8, desenvolvido pela Ultralytics, representou uma mudança importante ao adotar um paradigma totalmente livre de âncoras (*anchor-free*) [20,24]. Ao eliminar a dependência de caixas pré-definidas, o modelo simplifica o treinamento e lida melhor com variações na escala geométrica do alvo, situação recorrente durante a aproximação vertical descendente de um VANT [7]. Na sua estrutura interna, o YOLOv8 introduziu o bloco C2f (*Cross Stage Partial Bottleneck with 2 Convolutions*) em substituição aos módulos C3, otimizando o fluxo de gradientes sem inflar a contagem de parâmetros [20]. Além disso, a arquitetura adotou uma cabeça desacoplada (*decoupled head*), separando classificação e regressão de coordenadas em ramificações independentes coordenadas pelas funções de perda DFL (*Distribution Focal Loss*) e CIoU (*Complete Intersection over Union*) [7, 24]. Em sua versão compacta YOLOv8n (*Nano*), a rede conta com cerca de 3,2 milhões de parâmetros, permitindo taxas de inferência elevadas em computadores de bordo sem introduzir atrasos prejudiciais à estabilidade do controle cinemático [7, 25].

Buscando eliminar outros gargalos de processamento, o YOLOv10, proposto por Wang *et al*. [26], abordou uma limitação tradicional dos detectores de estágio único: a dependência da Supressão de Não-Máximos (NMS, do inglês *Non-Maximum Suppression*) no pós-processamento. Normalmente, o NMS é indispensável para filtrar

predições redundantes geradas por atribuições um-para-muitos durante o treino; no entanto, sua execução sequencial introduz uma latência variável que pode prejudicar sistemas embarcados. Para contornar essa etapa, o YOLOv10 implementou uma estratégia de atribuições duplas durante o treinamento (*Consistent Dual Assignments*): utiliza uma cabeça um-para-muitos para manter uma supervisão densa no *backbone* e uma cabeça um-para-um focada em gerar predições diretas e únicas por objeto [26]. No momento da inferência, a cabeça auxiliar é descartada, viabilizando detecção ponta a ponta (*end-to-end*) com latência NMS nula [26]. Combinada a blocos convolucionais compactos, a versão leve YOLOv10n garante tempos de ciclo visual previsíveis e baixo consumo computacional.

Dando continuidade ao aprimoramento dessas redes, a Ultralytics desenvolveu o YOLO11 (também chamado de YOLOv11), incorporando refinamentos focados em extração de características e eficiência computacional [27]. Nessa arquitetura, os blocos C2f foram substituídos pelos módulos C3k2 tanto no *backbone* quanto no *neck*, utilizando convoluções parciais com núcleos ajustáveis para acelerar as operações [27]. Outro avanço estrutural foi a inclusão do bloco C2PSA (*Cross-Stage Partial with Spatial Attention*), que adiciona autoatenção espacial multicabeça para orientar a rede a distinguir alvos pequenos contra fundos complexos, sem elevar substancialmente o tempo de processamento [27, 28]. Na versão compacta YOLO11n, o número de parâmetros diminuiu para aproximadamente 2,6 milhões (redução superior a 15% em relação ao modelo v8n), mantendo ou superando a precisão média de detecção com menor consumo de operações de ponto flutuante (FLOPs) [27, 28].

Mais recentemente, a Ultralytics introduziu o YOLO26 (ou YOLOv26), concebido com foco direto em dispositivos de borda (*edge-first optimization*) [29]. O modelo incorpora inferência nativa ponta a ponta sem NMS e simplifica a cabeça de detecção ao dispensar a perda focal de distribuição (DFL). Com isso, a rede elimina os múltiplos intervalos discretos de probabilidade anteriormente exigidos pela DFL, aliviando o uso de memória e simplificando o cálculo da regressão de bordas. Na versão compacta YOLO26n, essa otimização arquitetural proporciona execuções mais rápidas em processadores embarcados (CPUs e NPUs), tornando-a particularmente vantajosa para operações de aeronaves não tripuladas sob severas restrições Low-SWaP.

Para comparar o desempenho de diferentes modelos de detecção de forma objetiva, a literatura e as documentações especializadas empregam métricas padronizadas derivadas da matriz de confusão e da sobreposição geométrica entre predições e anotações reais (*ground truth*) [30, 31]. A métrica geométrica fundamental que define a validade de uma detecção é a Interseção sobre a União (IoU, do inglês *Intersection over Union*), formulada pela Equação (1):

$$\text{IoU} = \frac{\text{Área}(B_p \cap B_{gt})}{\text{Área}(B_p \cup B_{gt})} \tag{1}$$

em que B_p é a caixa delimitadora estimada pelo modelo e B_{gt} representa a caixa de referência correspondente. Define-se então um limiar de corte τ (geralmente $\tau = 0{,}50$): se a detecção corresponder à classe correta e satisfizer IoU $\geq \tau$, ela é considerada um Verdadeiro Positivo (TP). Se o IoU for inferior a τ ou a caixa surgir em uma região de fundo, categoriza-se como Falso Positivo (FP). Já os alvos presentes na imagem que não foram detectados pelo algoritmo constituem os Falsos Negativos (FN) [30].

A partir dessas quantidades, avalia-se a capacidade discriminatória da rede por meio da Precisão (P) e da Revocação (R, do inglês *Recall*), expressas nas Equações (2) e (3):

$$P = \frac{TP}{TP + FP} \tag{2}$$

$$R = \frac{TP}{TP + FN} \tag{3}$$

A Precisão expressa a proporção de acertos em relação ao total de detecções sinalizadas pelo modelo (penalizando alarmes falsos), enquanto a Revocação avalia a sensibilidade da rede em identificar todos os objetos verdadeiramente presentes na cena (penalizando omissões) [30]. O equilíbrio entre ambas as métricas sob determinado limiar de confiança é avaliado pela média harmônica denominada pontuação F_1 (F_1-*score*), calculada pela Equação (4):

$$F_1 = 2 \cdot \frac{P \cdot R}{P + R} \tag{4}$$

Como os valores de Precisão e Revocação variam ao longo dos limiares de confiança da rede, gera-se a curva de Precisão-Revocação ($P \times R$). A Precisão Média (AP, do inglês *Average Precision*) resume essa curva quantificando a área sob a curva por interpolação, conforme a Equação (5):

$$AP = \int_0^1 p(r)\, dr \tag{5}$$

Para generalizar o desempenho em cenários que envolvem C classes de objetos, calcula-se a Média da Precisão Média (mAP, do inglês *Mean Average Precision*) pela média aritmética dos valores de AP de cada classe, de acordo com a Equação (6):

$$\text{mAP} = \frac{1}{C} \sum_{c=1}^{C} AP_c \tag{6}$$

Na literatura e nos padrões do benchmark COCO (*Common Objects in Context*), duas

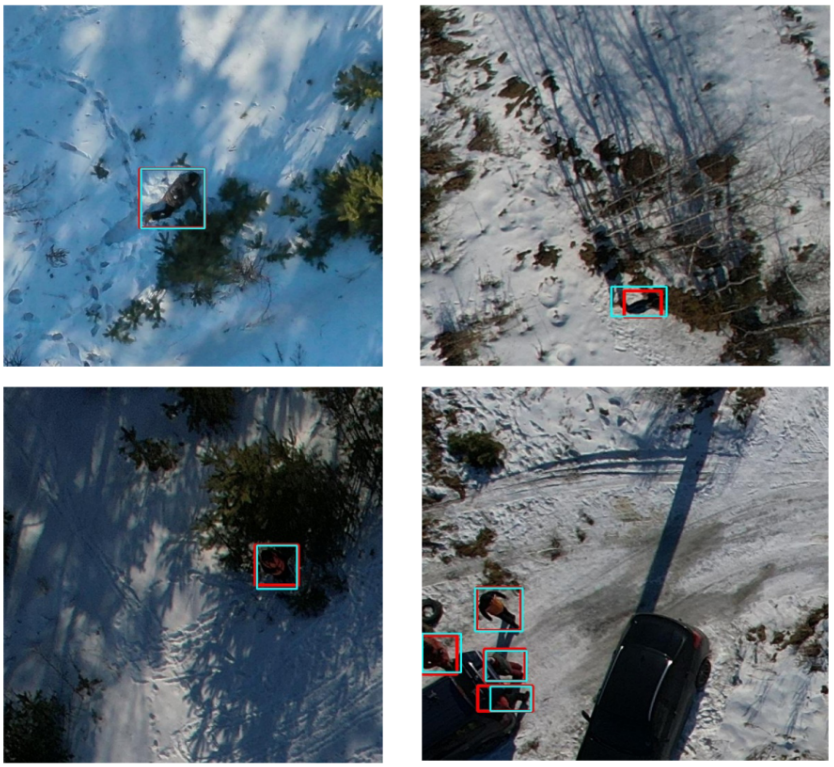
variações de mAP são comumente comparadas [30, 31]:

- mAP@0.5 (ou mAP_{50}): calcula o AP médio fixando o limiar de sobreposição em IoU $\geq 0{,}50$, avaliando a capacidade geral de localização e categorização do alvo;
- mAP@0.5:0.95 (ou mAP_{50-95}): computa a média do mAP em 10 limiares sucessivos de IoU, variando de $0{,}50$ a $0{,}95$ com incrementos discretos de $0{,}05$. Por exigir grande rigor no alinhamento espacial dos limites da caixa sob limiares mais severos, o mAP@0.5:0.95 atua como o principal critério de fidelidade geométrica para tarefas robóticas em que a posição do centroide orienta o guiamento cinemático [31].

Além da acurácia de detecção, a comparação prática de modelos para plataformas aéreas considera parâmetros de eficiência computacional [31]. Entre eles destacam-se o total de parâmetros da rede (*Params*), o volume de cálculos em ponto flutuante (*FLOPs*), a latência média de inferência por quadro (τ_{inf}) e a correspondente taxa de quadros por segundo (FPS $= 1000/\tau_{\text{total}}$), fatores determinantes para viabilizar a execução embarcada sob as restrições Low-SWaP do VANT.

Em testes comparativos recentes voltados à visão computacional embarcada em drones, pesquisas como a conduzida por Zhexebay *et al*. [28] mostram que essas gerações compactas do YOLO mantêm desempenho consistente na detecção de alvos aéreos. Os modelos atingem patamares de mAP@0.5 superiores a 90% operando sob taxas de quadros estáveis, demonstrando maturidade tecnológica para guiamento robótico autônomo. A aplicação prática desses detectores no isolamento e rastreamento de alvos a partir da perspectiva de uma câmera aérea é ilustrada na Figura 5 [28].

Figure 5: Exemplo prático de detecção de alvos em imagens aéreas obtidas por VANT utilizando modelos YOLO



Fonte: adaptado de [28].

Apesar da alta capacidade de reconhecimento das redes convolucionais, a inferência visual durante o voo expõe o sistema a perturbações dinâmicas próprias da operação aérea. O rastreamento contínuo no plano da imagem fica sujeito a ruídos frequentes, observados na forma de oscilações espúrias na posição do centroide e no tamanho da caixa delimitadora estimada. Esses distúrbios decorrem de vibrações mecânicas propagadas pelos motores, variações residuais de atitude da aeronave e oclusões transitórias provocadas por sombras ou pela passagem de hélices no campo de visão [9]. Uma vez que os controladores de voo exigem sinais de referência contínuos e suaves para evitar sobre-sinais (*overshoot*) e desgastes nos atuadores, os dados brutos de detecção não devem ser aplicados diretamente à malha cinemática.

Para contornar esse problema, a literatura utiliza estimadores estocásticos em cascata temporal com o modelo de aprendizado profundo, destacando-se o Filtro de Kalman. O filtro convencional, no entanto, é restrito a sistemas puramente lineares, o que limita sua aplicação direta em robótica aérea, já que a cinemática relativa entre a câmera do VANT e o alvo envolve projeções de perspectiva geométrica e dinâmicas não lineares no espaço tridimensional. Para contemplar essas características, adota-se o Filtro de Kalman Estendido (EKF, do inglês *Extended Kalman Filter*), que lineariza as equações

do sistema a cada instante de amostragem por meio de aproximações em série de Taylor de primeira ordem, utilizando matrizes Jacobianas avaliadas em torno da estimativa corrente [32–34].

O ciclo de estimação do EKF desenvolve-se em duas etapas recursivas principais: a predição e a correção (ou atualização) [32, 33]. A modelagem dinâmica parte de um sistema descrito por um modelo de transição de estados e por um modelo de observação, expressos nas Equações (7) e (8):

$$x_k = M(x_{k-1}) + w_k \tag{7}$$

$$z_k = h(x_k) + v_k \tag{8}$$

em que x_k é o vetor de estado no instante k; $M(\cdot)$ representa a função não linear que descreve a cinemática do sistema; w_k é o vetor de ruído de processo, considerado branco e de média nula; z_k denota o vetor de medições fornecido pelo detector visual; $h(\cdot)$ é a função não linear de observação, responsável por relacionar as variáveis do espaço de estados às coordenadas medidas no plano da imagem; e v_k define o ruído de medição visual associado.

Na etapa de predição, o modelo projeta o comportamento do sistema para o instante seguinte a partir do estado anterior estimado. As equações de predição para o estado *a priori* ($\hat{x}_{k|k-1}$) e para a covariância do erro predita ($P_{k|k-1}$) são formuladas pelas Equações (9) e (10):

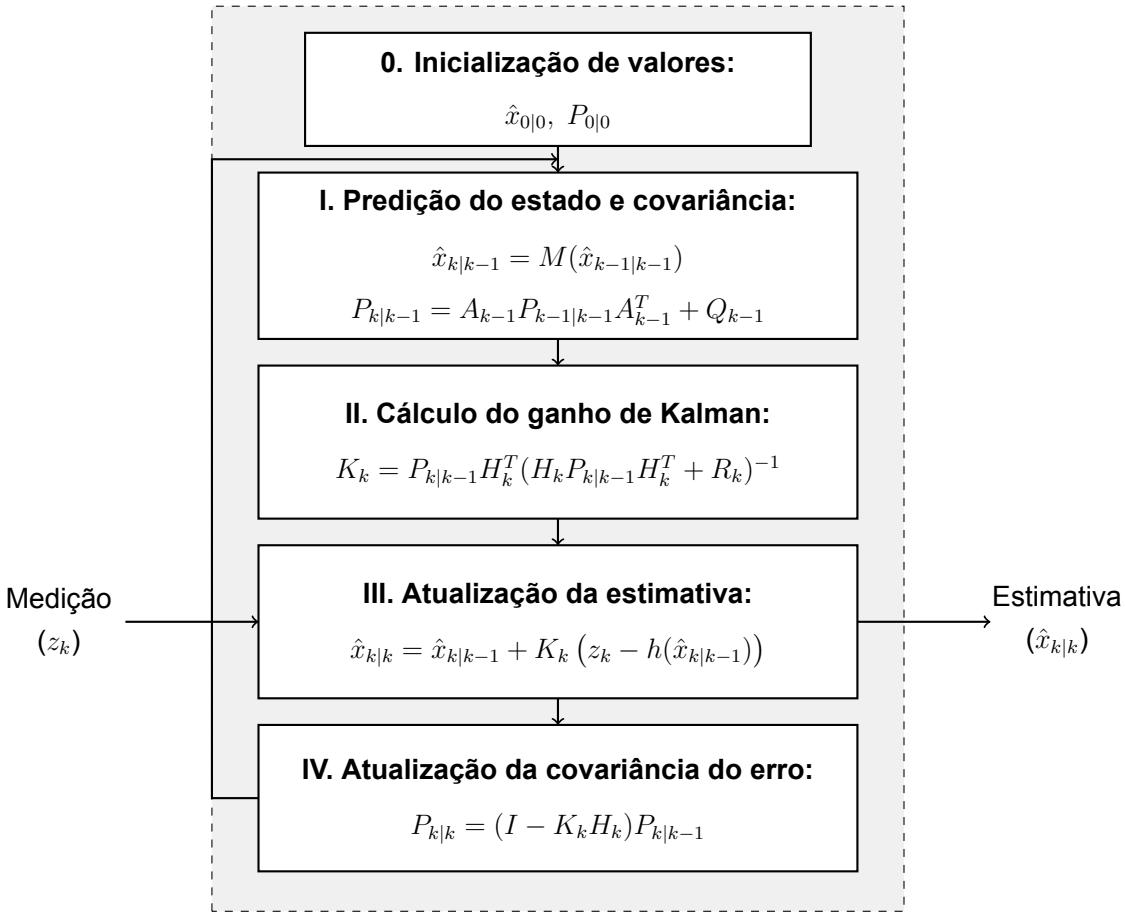
$$\hat{x}_{k|k-1} = M(\hat{x}_{k-1|k-1}) \tag{9}$$

$$P_{k|k-1} = A_{k-1} P_{k-1|k-1} A_{k-1}^T + Q_{k-1} \tag{10}$$

nas quais $\hat{x}_{k-1|k-1}$ e $P_{k-1|k-1}$ representam, respectivamente, o estado e a covariância estimados no passo anterior; A_{k-1} é a matriz Jacobiana associada à função não linear $M(\cdot)$, obtida pelo cálculo das derivadas parciais avaliadas em $\hat{x}_{k-1|k-1}$; e Q_{k-1} é a matriz de covariância do ruído de processo, calibrada para quantificar incertezas na modelagem cinemática e distúrbios externos [33].

Em seguida, na etapa de correção, o filtro incorpora a medição sensorial gerada pela rede neural para refinar a predição e reduzir a incerteza do estado. A dinâmica em malha fechada desse processo cíclico está sintetizada no fluxograma da Figura 6 [33]. O cálculo do Ganho de Kalman (K_k), a correção da estimativa *a posteriori* ($\hat{x}_{k|k}$) e a atualização da covariância do erro ($P_{k|k}$) são definidos pelas Equações (11), (12) e (13):

Figure 6: Fluxograma do algoritmo do Filtro de Kalman Estendido (EKF)



Fonte: adaptado de [33].

$$K_k = P_{k|k-1}H_k^T\left(H_kP_{k|k-1}H_k^T + R_k\right)^{-1} \tag{11}$$

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k\left(z_k - h(\hat{x}_{k|k-1})\right) \tag{12}$$

$$P_{k|k} = (I - K_kH_k)P_{k|k-1} \tag{13}$$

em que K_k representa o Ganho de Kalman, responsável por balancear a contribuição entre o modelo predito e a nova medição; R_k expressa a matriz de covariância do ruído de medição v_k, calibrada para refletir a dispersão associada à detecção visual; H_k simboliza a matriz Jacobiana da função não linear de observação $h(\cdot)$, calculada a partir de suas derivadas parciais avaliadas em $\hat{x}_{k|k-1}$; $\hat{x}_{k|k}$ é a estimativa corrigida do estado; e $P_{k|k}$ corresponde à matriz de covariância do erro atualizada [33].

Ao atuar como um estimador recursivo no plano da imagem, o EKF atenua os-

cilações ruidosas causadas por vibrações e suaviza o sinal fornecido ao controlador cinemático. Além disso, nos instantes em que a rede neural falha transitoriamente em detectar o alvo, seja por oclusões breves ou variações bruscas de iluminação, o filtro mantém a estimativa futura com base no histórico de movimento, garantindo a continuidade do guiamento do VANT sem descontinuidades abruptas na malha de servovisão [9, 35].

2.1.3 Visual Servoing

In autonomous robotics, Visual Servoing stands out as the fundamental technique for guiding robot motion using visual feedback extracted from one or more cameras, operating in a closed loop [10]. In Unmanned Aerial Vehicle (UAV) systems, in which navigation in GPS-denied environments or precise physical interaction (such as robotic gripper locking) requires millimetric reliability, Visual Servoing acts as the direct link between exteroceptive perception and kinematic actuation [4, 36].

The mathematical premise of Visual Servoing is based on the continuous minimization of an error vector $e(t)$, defined by the difference between the current visual features of the target $s(t)$ and a desired reference state s^* [36, 37]. In order for the reduction of this error to be converted into physical motion, camera kinematics and the variation of visual features are correlated through an Interaction Matrix, also known as the Image Jacobian (L_s) [38]. The robot velocity control law is therefore classically formulated through the pseudo-inverse of this matrix (L_s^+), guaranteeing an exponential decay of the visual error as the aircraft approaches the object [36, 38].

Historically, the literature consolidates the classification of Visual Servoing schemes into two primary architectures, distinguished by the spatial domain in which the error vector $e(t)$ is computed: Image-Based Visual Servoing (IBVS) and Position-Based Visual Servoing (PBVS) [10, 39–41].

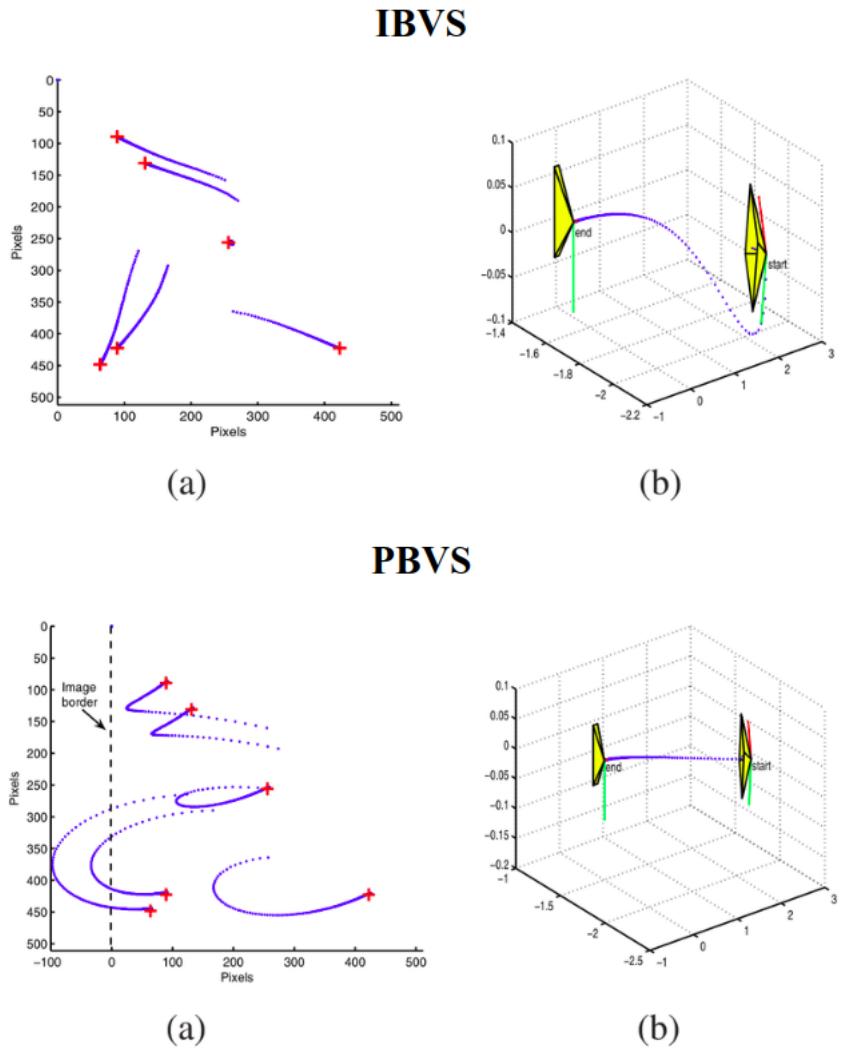
In the IBVS approach (2D model), the control law operates strictly in the image plane using pixel coordinates [37]. Although IBVS eliminates the need for a prior three-dimensional model of the target and provides high robustness to intrinsic calibration errors, it presents critical disadvantages in aerial robotics applications. Since the control is projected in pixel coordinates, the trajectory generated in three-dimensional (3D) space is unpredictable [37, 40, 41]. Furthermore, due to the phenomenon of mechanical under-actuation, the UAV requires large attitude variations (in roll or pitch) to perform translation [10]. Under pure IBVS control, these abrupt attitude changes generate strong dynamic couplings that may drive the controller into local singularities or even cause severe instabilities when target features move outside the camera Field of View (FoV) [41].

To mitigate FoV loss caused by aircraft attitude changes, a hardware solution widely adopted in the literature consists of mounting the camera on a stabilized support with

independent axes (gimbal) [42]. Since the gimbal exhibits mechanical response dynamics significantly faster than those of the quadcopter, it actively adjusts lens inclination continuously, isolating the camera from the robot attitude and assisting in retaining the target at the center of the image [42]. However, the exclusive use of a gimbal does not solve all limitations of aerial Visual Servoing. The addition of this dynamic mechanism makes the mathematical system even more complex, requiring the real-time computation of time-varying transformation matrices to correlate the moving camera reference frame with the chassis control reference frame [42]. Furthermore, even with the image mechanically stabilized by the gimbal, if the control loop operates purely in the two-dimensional domain (IBVS), the spatial trajectory of UAV approach remains unpredictable, which may generate dangerous overshoots during the critical phase of physical alignment [37, 41].

To overcome the remaining algorithmic limitations of IBVS and guarantee greater stability during final robotic gripper alignment, Position-Based Visual Servoing (PBVS — 3D model) may be adopted. In PBVS, the control objective does not consist solely of generating motion from the direct analysis of pixels but rather reconstructing the geometric pose (distance and orientation) of the target relative to the camera before computing the control effort [10, 41]. Figure 7 illustrates the classical contrast between these two approaches. While IBVS tends to maintain more regular trajectories in the image plane at the cost of potentially inefficient spatial motion, PBVS operates directly in Cartesian metric space, favoring more direct approach trajectories in physical space [11, 37, 40]. As a trade-off, the absence of explicit control over pixel coordinates may cause object features to describe broader trajectories in the image, increasing the risk that the target exceeds the limits of the camera Field of View (FoV) before capture is completed [37, 41].

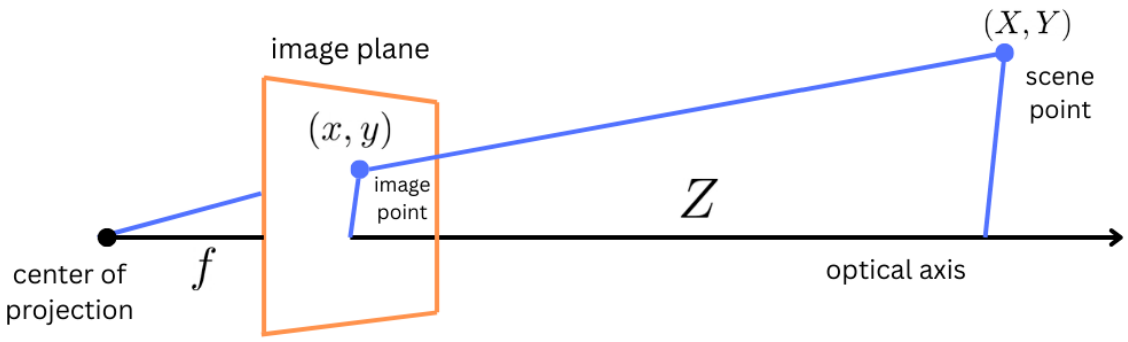
Figure 7: Qualitative comparison between the classical Image-Based Visual Servoing (IBVS) and Position-Based Visual Servoing (PBVS) schemes



Source: Adapted from Hafez et al. (2013).

Three-dimensional reconstruction in PBVS schemes is initially based on the application of the analytical Pinhole camera model. This model, geometrically illustrated in Fig. 8, acts as the bridge between domains by mapping the stabilized two-dimensional coordinates of the target into a three-dimensional vector in the camera focal reference frame through the incorporation of the intrinsic parameters of the lens, such as focal length and optical center [11, 36, 37].

Figure 8: Geometric representation of perspective projection based on the Pinhole camera model, illustrating the relationship between focal length and the conversion of a point in space onto the two-dimensional image plane



Source: Björkman (2023), cited in Pramono (2025).

Therefore, when adopting the mechanical architecture of a gimbal, the camera reference frame becomes decoupled from the rigid structure of the UAV. However, although the stabilizing support isolates the lens from aircraft attitude changes (preserving the target within the Field of View (FoV)), it introduces a new mathematical complexity: the relative orientation of the camera becomes dynamically time-varying with respect to the robot center of mass [42]. To cancel this undesired effect and prevent the autonomous rotation of the gimbal from being interpreted by the control loop as target motion, the vector extracted from the Pinhole model must be remapped. This is achieved by multiplying it by cascaded geometric transformation matrices of translation and rotation [11, 42]. Using the angular measurements from the gimbal itself and the Inertial Measurement Unit (IMU), these matrices perform instantaneous compensatory rotations, projecting the target coordinates from the moving camera reference frame to the UAV body reference frame and subsequently to an inertial reference frame aligned with the world [11, 16]. This approach concludes the perception pipeline by extracting the position error strictly in translational coordinates expressed in meters.

Since this is a computationally demanding algorithmic pipeline, integrating semantic extraction with neural networks, predictive filtering, Jacobian inversion, and time-varying three-dimensional matrix transformations, the architecture imposes a computational cost that low-level flight controllers alone are generally unable to support [36]. As an engineering solution, the onboard system may be hierarchically segmented. Thus, the complete computation of the PBVS control loop is executed on an auxiliary onboard computer (companion computer), typically implemented as a node within the ROS (Robot Operating System) ecosystem [4, 16]. Once the error vector in meters has been computed and converted into velocity signals, the companion computer del-

egates mechanical execution to the low-level flight controller (such as Pixhawk hardware operating ArduPilot) through the MAVLink/MAVROS serial communication protocol [4, 16]. This arrangement establishes Visual Servoing as the high-level control system of the UAV, in which vision (assisted by the gimbal) determines the coordinates in three-dimensional space in real time, while the flight controller regulates motor rotation.

2.1.4 Aerial Capture and Manipulation Systems

Historically, the applications of Unmanned Aerial Vehicles (UAVs) were concentrated on the execution of passive observation missions, in which the aircraft acted purely as a remote sensor. The need to interact with and modify the environment motivated the development of Unmanned Aerial Manipulators (UAMs), systems composed of a flying platform coupled with a physical interaction mechanism designed to capture, transport, or manipulate objects [13, 14].

According to the state of the art in the aerial manipulation literature, the methods and mechanical systems used to perform capture and physical interaction are divided into four main categories [13]:

- **Grippers (Figure 9):** Grippers represent the most common mechanical solution and are ideal for tasks involving purely object capture, payload transportation, and perching operations [14]. Since they are typically compact and lightweight, grippers are installed close to the Center of Mass (CoM) of the UAV, fundamentally operating with two actuation states (open and close). Because they do not require multiple articulation motors, grippers (whether rigid or made of compliant/-soft materials) demand lower payload capacity from the aircraft and significantly reduce inertial variations during flight [14, 43].

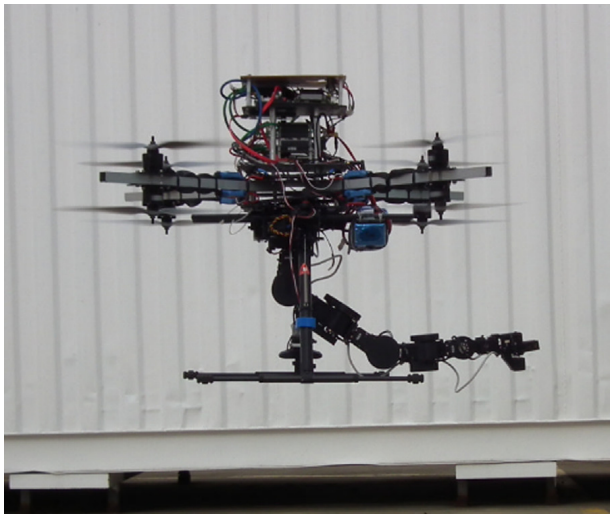
Figure 9: Aerial manipulation using attached grippers



Source: Ubellacker et al. (2024).

- **Articulated Robotic Arms (Figure 10):** For missions that require high dexterity rather than only rigid capture, the UAV is equipped with robotic arms ranging from one Degree of Freedom (1-DoF) systems to hyper-redundant manipulators [13]. The addition of these articulations expands the operational workspace, allowing the end-effector to reach complex targets, rotate valves, or perform assembly tasks. However, this additional capability introduces the disadvantage of increased weight and continuous displacement of the robot center of gravity with each arm movement [14].

Figure 10: UAV equipped with an articulated robotic arm



Source: Bonyan Khamseh et al. (2018).

- **Suspension Cables and Winches (Figure 11):** This method is frequently adopted when capture requires the UAV to operate at a safe distance from the object [43]. Its use is particularly suitable when the target has low mass or is located in narrow and unstable locations. By maintaining the capture mechanism suspended below the fuselage, the system reduces the effects of downwash, the descending airflow generated by the propellers, preventing the object from being displaced before capture [43]. However, this approach is more suitable for applications involving tensile forces and presents limitations for operations requiring compressive efforts.

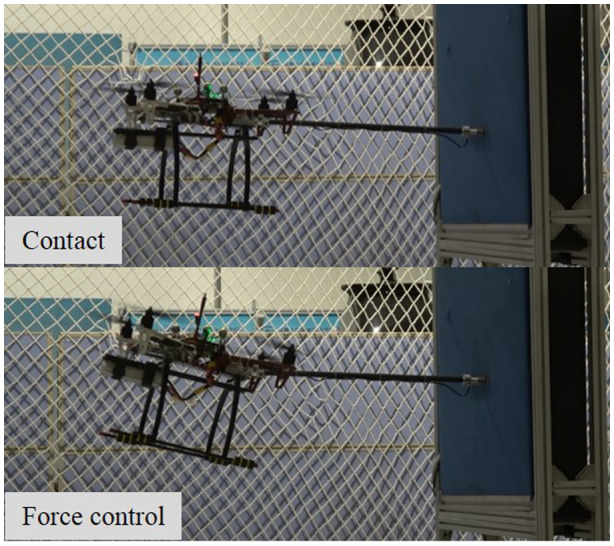
Figure 11: Cable-suspended aerial manipulation system



Source: Ladig et al. (2021).

- **UAV Body or Rigid Tools (Figure 12):** In limited manipulation scenarios that do not require grasping the target, the UAV chassis itself or a fixed rigid rod is used to apply direct force, such as pushing objects or performing contact inspection on walls [13].

Figure 12: Rigid-tool aerial manipulation system mounted on the UAV frame



Source: Meng et al. (2020).

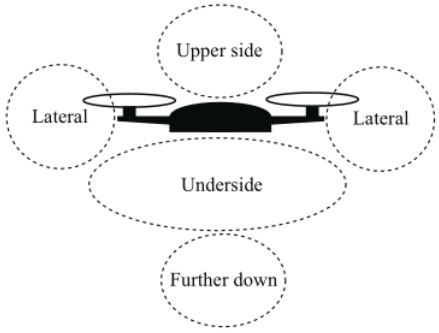
In addition to the choice of mechanism, the aerial capture method depends directly on the operational workspace configured in the multirotor chassis. As illustrated in Figure 13, this geometric configuration divides the robot operational area into three main interaction zones with the environment [43]:

- **Underside Capture:** This is the standard architecture in most aerial robotic projects. The capture mechanism is positioned below the fuselage, configuring the system to retrieve loads located on the ground or on flat platforms below the UAV flight level [43].
- **Upper-Side Capture:** For high-altitude missions, such as capture on ceilings, tubular structures, and the underside of bridges, the rotors represent a mechanical obstacle for lower-mounted manipulators [43]. In these cases, grippers and actuators are mounted on top of the UAV. This approach is widely explored for perching operations, allowing the robot to capture a fixed structure above itself, turn off its motors, and save energy while performing inspection tasks [14, 43].
- **Lateral-Side Capture:** Designed to access surfaces and targets vertically aligned with the UAV, such as building facades [43]. This approach requires extended mechanisms that prevent the rotors from colliding with the wall during approach.

Finally, regarding the nature of interaction, these methodologies are unified by the free-flight operational scenario [14]. In this context, physical contact with the environment should last for the shortest possible time, such that, in the task of aerial target

capture, the closure of the mechanism (gripper or arm) is characterized as a rapid and discrete mechanical event. Consequently, it is the combination between the selected actuation method (gripper, arm, or winch) and the operational workspace that determines the technical capability of the UAV to isolate and safely grasp a target under non-cooperative conditions [14].

Figure 13: Classification of operational spaces in aerial manipulation systems



Source: Ladig et al. (2021).

2.2 RELATED WORKS

2.2.1 Autonomous Object Capture by UAVs

In the article titled *Toward Image Based Visual Servoing for Aerial Grasping and Perching*, Thomas et al. [44] developed a system enabling small drones to autonomously approach and land on cylindrical structures, a maneuver known as perching. Inspired by the way birds land on branches, the study avoided overloading the UAV with heavy motors. Instead, the authors installed a simple gripper at the base of the aircraft. This gripper used the UAV's own velocity and the impact force with the target to close rapidly, securing the object without the need for additional electrical actuators.

To ensure that the drone hit the target accurately, the project employed Image-Based Visual Servoing (IBVS) assisted by a laboratory camera system (MOCAP) in an indoor environment. The main technological challenge of this approach was ensuring that the control system reacted fast enough to stabilize the drone at the exact moment the gripper contacted the cylinder. At this contact instant, the UAV transitioned from free flight to a state subjected to a strong physical impact disturbance.

The experimental results reported by Thomas et al. [44] successfully validated this bio-inspired approach. Operating a lightweight quadrotor of 388 grams equipped with a 478-gram gripper, the visual servoing architecture demonstrated the ability to grasp and transport 77-gram symmetric loads in free flight with high stability. In addition to

proving the accuracy of the vision system, the strategy enabled complete shutdown of the motors after gripper engagement, resulting in significant energy savings while the robot operated as a suspended observation platform.

In the article titled *Autonomous Marker-less Rapid Aerial Grasping*, Bauer et al. [45] developed a system focused on solving the problem of fast object capture in the air without the use of artificial markers. The main objective of the project was to create a quadrotor capable of identifying, approaching, and grasping targets in a fully autonomous manner under non-cooperative conditions. To prevent damage to the aircraft during high-speed physical impact, the authors equipped the UAV base with a soft and flexible robotic gripper designed to passively conform to the object shape.

To enable marker-less detection, the system used an onboard depth camera. The video stream was transmitted in real time to an external high-performance processing station (equipped with an RTX-3070 GPU). On this computer, a deep learning neural network based on image segmentation (Mask R-CNN) identified the object contour. The algorithm then fused these detections with depth camera data to generate a 3D map (point cloud) of the target, accurately estimating its geometry and determining optimal grasping points for gripper closure.

The experimental results demonstrated the feasibility of combining intelligent vision with compliant mechanical design. During free-flight experiments, the perception system was able to guide the UAV toward the target, while the natural flexibility of the soft gripper absorbed mechanical impact and compensated for small inevitable pose estimation errors. This approach achieved a capture success rate of 89% in aerial grasping trials. This metric confirms that fast and reliable aerial grasping is possible even when the environment or the target does not cooperate with the robot vision system.

In the article titled *High-speed aerial grasping using a soft drone with onboard perception*, Ubellacker et al. [46] aimed to develop a UAV capable of performing autonomous high-speed aerial grasping using only onboard perception. The project goal was to eliminate dependency on external infrastructure, such as motion capture (MOCAP) camera laboratories. To ensure safety during high-speed impact, the researchers introduced a soft robotic gripper designed to deform, absorb shock, and passively conform to the target at the exact moment of capture.

To enable marker-less perception, the visual system combined neural networks and depth sensors. First, an artificial intelligence model analyzed camera images to detect key points (object silhouette). Then, the onboard computer fused these detections with depth data to estimate the precise three-dimensional (3D) position and orientation of the target, allowing the UAV to autonomously plan its approach trajectory.

The experimental results validated the integration of onboard 3D vision and soft grippers. Flying at an approach speed of 0.5 m/s, the UAV achieved a perfect success rate of 10 out of 10 trials for bottle grasping, and 9 out of 10 trials for a medical

kit. The system also demonstrated versatility by successfully performing grasps in outdoor environments. Furthermore, the study identified operational limits of the platform: when the capture speed was increased beyond 2.0 m/s, the success rate for the bottle dropped to only 3 out of 10 trials (30%). This result highlights that, although the compliant gripper compensates for small pose errors, the system performance degrades under high-speed operation due to increased visual estimation error.

In the article titled *Natural Feature-based Visual Servoing for Grasping Target with an Aerial Manipulator*, Luo et al. [38] proposed an aerial manipulation architecture guided exclusively by natural visual features of the target. The main objective was to eliminate the need for cooperative artificial markers such as QR codes, ArUco tags, or reflective stickers. Instead, the UAV had to perform tracking by identifying only the natural textures and edges of the target itself. The system used a lightweight custom-built 6-DoF robotic arm attached to the UAV base to perform precision grasping.

To implement this idea, the method decomposed the task into stages, combining UAV flight control with robotic arm motion. The authors mounted a standard camera on the end-effector of the robotic arm and used an onboard minicomputer (Intel NUC) for image processing. The algorithm was designed to extract and track salient feature points of the target using the ORB feature detection method. Based on these points, the system computed the pixel displacement of the object and directly converted this visual information into velocity commands to drive the robotic arm motors autonomously and in real time.

The experimental results confirmed the maturity and efficiency of this contour-based visual approach. During practical tests, the aircraft was able to identify the target and initiate a fully autonomous approach from a distance of 3 meters. When the UAV reached 0.4 meters (40 centimeters) from the object, it stabilized in hover and fully transferred visual control to the robotic arm (which weighed only 0.9 kg). The camera guided the fine approach until a distance of 20 centimeters from the target was reached, at which point the system triggered the mechanical closure and successfully completed the grasp.

2.2.2 Object Detection and Tracking in UAVs

In the article titled *Vision-based system for a real-time detection and following of UAV*, Barisic et al. [9] developed a system enabling a UAV to detect, track, and follow another drone in real time. The challenge of this research was to maintain a fast-moving aerial object, subject to abrupt changes in altitude and direction, centered in the follower UAV camera image during fully autonomous flight.

To implement the system, the authors combined artificial intelligence with a Kalman Filter. In the vision stage, they trained a neural network (YOLOv3-Tiny) using a custom dataset composed of 10,000 drone images. The detection ran directly on the onboard computer of the aircraft. However, the size of the bounding box generated by the neural

network around the target exhibited jitter due to propeller-induced disturbances. To stabilize perception, the system employed a Kalman Filter to track eight continuous variables: the center coordinates, width, and height of the bounding box, as well as the velocities of all these quantities. In this way, even if the camera temporarily lost sight of the target, the filter could predict the exact location and size of the drone in space.

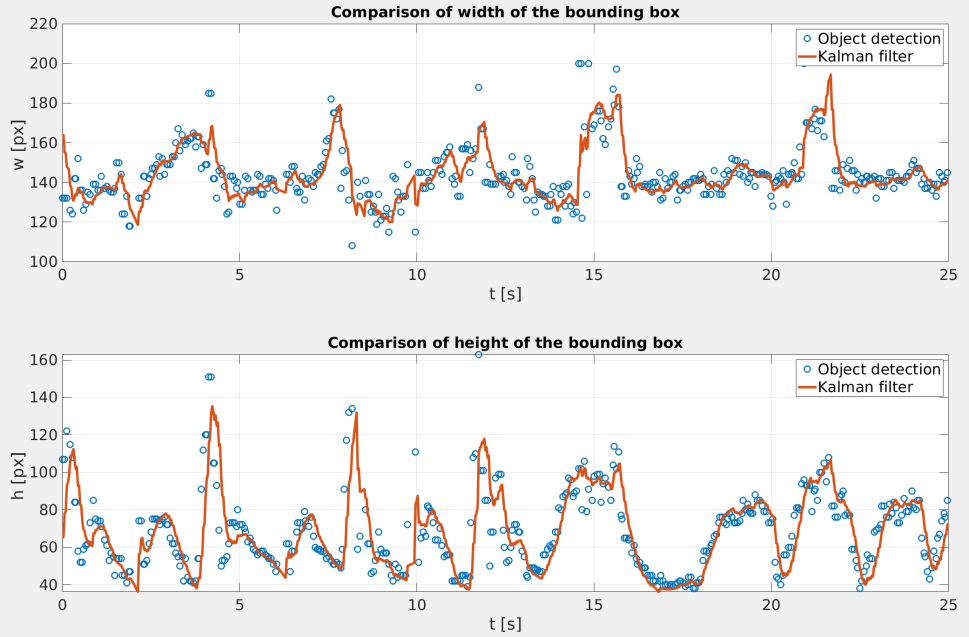
The experimental results demonstrated the success of integrating intelligent vision with predictive filtering. The camera processing operated at 20 frames per second (FPS), achieving a mean Average Precision (mAP) of 97.88% in detections. Although the original paper primarily validates the Kalman Filter through graphical results, the experiments confirm that its application was essential. By smoothing unstable bounding box measurements, the filter ensured that the follower UAV kept the target centered even when the tracked drone performed complex figure-eight maneuvers, enabling continuous and collision-free tracking.

In the article titled *Vision-based system for a real-time detection and following of UAV*, Barisic et al. [9] developed a vision-based system enabling a UAV to detect, track, and follow another multirotor in real time. The main challenge of this study was to keep a fast-moving aerial object, subject to abrupt changes in altitude and direction, centered in the camera field of view during fully autonomous flight.

To solve this problem, the authors proposed the integration of convolutional neural networks with the Kalman Filter. In the visual perception stage, they employed the YOLOv3-Tiny model, trained using a custom dataset composed of 10,000 UAV images, running directly on the aircraft onboard computer. However, the authors reported that the dimensions of the bounding box generated by the neural network exhibited oscillations and significant variations due to the rapid rotation of the target propellers. To mitigate this visual volatility, the system applied a Discrete Kalman Filter responsible for tracking eight continuous states: the center coordinates, the width and height of the bounding box, as well as their respective velocities. In this way, even in cases of occlusion and temporary loss of detection, the filter was able to predict the drone's spatial location and size.

The experimental results validated the effectiveness of integrating deep learning-based perception with predictive filtering. The onboard processing operated at a rate of 20 frames per second (FPS), achieving a mean Average Precision (mAP) of 97.88% in detections. The effectiveness of the Kalman Filter application is graphically shown in Fig. 14. By smoothing fluctuations and jittering bounding box measurements into a continuous predictive estimate, the filter ensured that the follower UAV computed control references and kept the target continuously centered, even when the tracked aircraft executed complex three-dimensional figure-eight maneuvers, enabling robust and collision-free tracking [9].

Figure 14: Comparison between Kalman Filter estimation and object detection output for the width and height of the bounding box



Source: Barisic et al. (2019).

In the article titled *Object Visual Tracking using Window-Matching Techniques and Kalman Filtering*, Vidal and Casanova [35] proposed a robust predictive method for tracking moving objects in video sequences. The focus of the study was to address the problem of "camera drift", a common failure in which the vision system becomes confused, gradually loses the true target, and starts tracking background regions or image shadows.

To solve this problem, the authors developed an algorithm combining visual search through Window-Matching techniques with the Kalman Filter. The vision system extracted image patches (regions of interest) using sliding windows (50×50 or 15×15 pixels) and mathematically computed which region in the next video frame most closely matched the target. To prevent errors when image quality degraded, the Kalman Filter was integrated into the pipeline. Thus, when the camera produced a false positive or the object became temporarily occluded, the Kalman prediction took priority, constraining the search area and estimating the target position based on its previously observed motion and velocity.

The experimental results confirmed the effectiveness of this combined approach for correcting tracking failures. Although the original study mainly presents graphical results, tests using 320×240 resolution videos demonstrated the superiority of the filtering approach. When tracking a vehicle at an urban intersection, partially occluded pedes-

trians, and a floating bottle in the sea (a highly cluttered and unstructured background), the vision-only algorithm quickly failed. However, with the addition of the Kalman Filter, the system compensated for uncertainties, reduced pixel drift, and maintained a smooth and stable trajectory on the target, demonstrating the effectiveness of predictive filtering in dynamic environments.

In the article titled *DS-YOLOv8-Based Object Detection Method for Remote Sensing Images*, Shen et al. [47] aimed to detect very small objects for monitoring using drone cameras and aerial imagery. The challenge of this study lies in the fact that, from high altitudes, objects lose their fine details and appear as small pixel clusters in the image. This causes traditional vision algorithms, trained on close-range scenarios, to frequently fail in classification tasks.

To address this issue, the researchers proposed the DS-YOLOv8 algorithm, an artificial intelligence model that modifies and improves the eighth version of the YOLO family. To compensate for the lack of resolution, they redesigned the internal network architecture by splitting image processing into smaller and more efficient channels. The goal of these modifications was to extract visual features in greater detail, preserving the shape information of small objects during processing while maintaining a lightweight and fast model suitable for real-time execution.

The experimental results demonstrated improved reliability in aerial vision tasks. The DS-YOLOv8 model achieved a mean Average Precision (mAP) of 91.0% and an F1-score of 90.4% for detecting small and distant targets. Despite these results, the study also identified limitations, showing that performance degrades in scenarios where objects are extremely densely clustered. Nevertheless, the reported metrics indicate that the modified architecture is highly effective and well-suited for aerial inspection platforms.

Finally, exploring computer vision in space, the article titled *A Space Non-Cooperative Target Recognition Method for Multi-Satellite Cooperative Observation Systems*, developed by Zhang et al. [48], aimed to identify and locate multiple non-cooperative targets, such as defunct satellites and space debris. The challenge of this research was to correct a common error in which the system detects parts of the same object as independent targets. Since the camera observes solar panels separated from the main body of the satellite, the algorithm would draw multiple redundant bounding boxes over the same object, fragmenting the image and misleading the control system of the pursuing platform.

To solve this problem, the authors developed a high-efficiency detection model divided into two stages, named LCNN-DMT. In the first stage, they proposed the MBRT-D algorithm, which analyzes the spatial distribution of bounding boxes on the image. If the boxes drawn around a solar panel and the satellite body are too close (below a defined distance threshold), the system automatically merges them into a single bound-

ing box, ensuring that the object is fully represented. In the second stage, this unified and cleaned representation is processed by a lightweight neural network (based on SqueezeNet), enhanced with attention mechanisms to focus on the most relevant features and quickly classify whether the object is a satellite or space debris.

The experimental results demonstrated the success of this approach. The bounding-box merging strategy completely eliminated fragmentation issues, providing reliable target localization. In numerical terms, the LCNN-DMT network achieved a mean Average Precision (mAP) of 97.50%. When compared with established detection algorithms, it significantly outperformed Faster R-CNN (89.17%) and its previous baseline model T-SCNN (86.64%). In addition to accuracy improvements, the model demonstrated high computational efficiency, processing images in only 6.1 milliseconds. Requiring only 0.928 million parameters and consuming just 0.464 GFLOPs, the study confirmed that this architecture is well suited for deployment on companion computers with severe power and computational constraints.

2.2.3 Visual Servoing Applied to UAVs

In the dissertation titled *Hybrid PBVS-IBVS Model Predictive Visual Servoing For Autonomous Docking of a Free-Flying Robot*, Tafarrel Firhannoza Pramono [37] aimed to develop a hybrid visual servoing method for autonomous docking of aerial robots. The objective was to combine the strengths of two visual control approaches: preventing the camera from losing sight of the target (a critical issue when the robot relies solely on 2D image tracking) while also correcting the precision and geometric calibration errors that arise when estimating the object pose exclusively in 3D space.

The system was developed and tested in simulation environments (such as ROS and Gazebo) and validated on real free-flying robotic platforms. The UAV was equipped with a depth camera capable of generating 3D point clouds. To enable real-time onboard processing, filtering techniques were applied to remove irrelevant points and reduce computational load. The onboard system used a Model Predictive Controller (MPC), which anticipates future states and dynamically blends navigation strategies: the UAV uses 3D vision for long-range approach (where the error is larger) and gradually switches to 2D image-based control when it is close to the target, enabling precise docking.

The practical and simulation results validated the performance of this smooth control transition. During laboratory validation tests (with real hardware), the robot was able to perform autonomous in-motion docking with success rates ranging from 80% to 100% of the trials, tracking the target from an initial distance greater than 1.5 meters. The computational performance also proved effective, with visual tracking running at 30 frames per second (30 Hz) and the flight controller updating trajectories at 15 Hz. Regarding docking impact accuracy, the robot's steady-state error was nearly zero,

achieving a spatial precision of only 1 millimeter position deviation and 0.25 degrees attitude deviation. These results demonstrate that combining the best of 2D and 3D techniques not only keeps the target within the camera field of view at all times but also enables extremely precise and smooth docking, even when the UAV starts fully misaligned with the target.

In the article titled *Fractional Order Robust Visual Servoing Control of A Quadrotor UAV with Larger Sampling Period*, Shang et al. [4] aimed to design a highly robust control system to ensure that a drone could maintain stable hovering. The practical problem addressed by the study was computational delay: since small onboard computers are slow in processing images, they output only a few frames per second (low FPS). This delay creates a "visual lag", which directly conflicts with the fast physical dynamics of the UAV, causing instability and oscillatory behavior or even loss of control.

To solve this problem, the authors proposed a control strategy beyond classical approaches, adopting a Fractional-Order Proportional-Derivative (FOPD) controller. In simple terms, fractional calculus introduces additional flexibility that allows the system to absorb and compensate for video delay more smoothly. On the hardware side, the system strictly separates tasks: an onboard companion computer handles the computationally heavy perception stage (even at low frame rates) and sends target coordinates to a main flight controller, which focuses exclusively on stabilizing motor outputs and maintaining UAV attitude and altitude.

The experimental tests, conducted at a flight altitude of 10 meters, demonstrated that FOPD control outperforms traditional PID controllers under delay conditions. During experiments, the system was forced to operate with an extremely large image delay period of 0.58 seconds per frame. Even while effectively operating with more than half a second of visual delay between processed frames, the fractional-order controller compensated for the lag and kept the UAV stabilized over the target within a maximum deviation radius of only 58 pixels in the image. In direct comparison, the classical PID controller exhibited oscillations and deviations reaching a radius of 68 pixels. These results confirm that fractional-order control improves flight stability by approximately 20%, ensuring accurate performance without requiring high-cost, high-performance onboard processors.

In the article titled *Visual Servoing Using Sliding-Mode Control with Dynamic Compensation for UAVs' Tracking of Moving Targets*, researchers Carvajal et al. [1] developed a system enabling a UAV to continuously track and follow a moving ground target. The challenge of this research was not only to follow the object in the image but also to ensure the simultaneous fulfillment of safety tasks, such as maintaining a constant safe distance between the drone and the target, and fixing the flight orientation so that the aircraft flew in the same direction as the pursued vehicle.

To put this idea into practice, the system was structured using the Sliding-Mode

Control (SMC) technique and divided into two actuation stages. In the first stage, the software processed the camera images at a rate of 50 frames per second (50 Hz) to identify the target (a ground robot with a red spherical marker) and converted its position on the screen into velocity commands for the drone. However, in the second stage, to prevent the drone from lagging behind or losing sight of the target due to its own flight inertia, the authors added a “dynamic compensator”. This second controller worked by predicting the ground target’s acceleration and velocity, which allowed for the correction and anticipation of the UAV’s motor commands to prevent response delays.

Field operational trials proved the effectiveness of this compensating system in eliminating delays and stabilizing the aircraft. In one of the most challenging practical experiments, the ground robot performed figure-eight maneuvers for 120 seconds continuously, while the drone was commanded to follow it, maintaining a distance of exactly 2.5 meters. The results demonstrated that the dynamic compensator rejected external disturbances (such as wind) and kept the UAV’s maneuvering velocity errors extremely close to zero. Ultimately, the UAV complied with the parameters required by the safety tasks, keeping the target centered in the camera lens at all times, thereby proving the robustness of the Sliding-Mode technique for tracking fast objects in practice.

In the article titled *Visual Servoing for an Autonomous Hexarotor Using a Neural Network Based PID Controller*, researchers Lopez-Franco et al. [36] aimed to develop an intelligent visual system to keep a six-rotor drone (hexarotor) perfectly aligned and hovering over a target. The challenge of the study was to solve the problems associated with traditional controllers. Because standard controllers have fixed flight rules, they fail and lose control of the aircraft when the system faces uncertainties, such as sudden changes in the robot’s weight or delays in camera image processing.

To resolve these failures, the authors created a hybrid system that combined purely two-dimensional visual tracking (on the camera image plane) with an Artificial Neural Network connected directly to a classical controller, forming a Neural PID (PID-ANN). In simple terms, the onboard computer analyzed the error between the target’s position on the screen and the center of the lens. Instead of calculating the movement using complex geometric equations or rigid correction values previously programmed, the neural network’s intelligence used this visual error to “learn” the new dynamics of the robot and automatically readjust the motor forces in milliseconds, actively adapting to the environment.

Practical and simulation results attested to the stability gain provided by this continuous adaptation. During testing, the researchers forced severe uncertainties on the robot, such as a sudden 50% increase in its mass and drastic changes to its mechanical inertia. Under these conditions, the classical control (standard PID) could not adapt to the new weight; it became destabilized and diverged from the target, accumulating an error of up to 1741 pixels of deviation in the image. In contrast, under the same con-

ditions, the Neural PID adapted its rules instantly, held the aircraft at the center of the target, and contained the maximum deviation to just 212 pixels. These figures prove that the neural network can compensate for the physical losses of the UAV, ensuring millimeter-accurate tracking without the need to process the complex 3D reconstruction of the world.

2.2.4 Comparative Analysis of Related Works

In order to substantiate the methodological choices of this work, Table 1 presents a comprehensive comparative summary of the main research developed in the field of autonomous aerial manipulation and target tracking. This literature survey systematically highlights the specific visual perception strategies, applied control techniques, and mechanical capture mechanisms adopted in each referenced study. By analyzing these diverse approaches, the table contrasts their most significant practical results against the operational limitations inherent to each system, such as environmental dependencies and computational constraints. Through this detailed mapping, special emphasis is placed on critical operational challenges, notably autonomous flight alignment, dynamic inertia compensation, and visual processing latency. Consequently, this evaluation not only clarifies the current state of the art but also provides a solid theoretical foundation to justify the specific control and computer vision architecture proposed in the subsequent sections of this research.

Table 1: Comparative Analysis of Related Works

Author (Year)	**Detection and Tracking**	**Control Technique**	**Capture Mechanism**	**Study Limitations**	**Main Results**
Thomas et al. (2014)	External cameras (MOCAP) / Visual Servoing (IBVS)	Post-impact reactive stabilization	Simple base gripper (impact closure)	Total dependence on laboratory with cameras (indoor). Does not work in outdoor environments.	Successful 77g perching; major battery savings.
Bauer et al. (2023)	Onboard visual perception (Marker-less)	Not detailed (autonomous approach)	Soft/flexible robotic gripper	Undamped impact at high speed requires maneuvering restrictions.	89% success rate in free flight; mechanical compensation of visual error.
Ubellacker et al. (2024)	Onboard 3D vision	Not detailed	Soft robotic gripper (shock absorption)	Drastic drop in accuracy (30% success) at speeds over 2.0 m/s due to visual error.	100% success at 0.5 m/s in capturing bottles and medical kits.

Continued on next page

Table 1 – continued from previous page

Author (Year)	Detection and Tracking	Control Technique	Capture Mechanism	Study Limitations	Main Results
Luo et al. (2020)	Natural visual features (edges/textures)	Multi-task Visual Servoing (IBVS/PBVS)	Lightweight 0.9 kg robotic arm (6-DoF)	Addition of excessive weight; requires the target to have very clear textures.	Autonomous capture at 3 m, flight stabilization at 0.4 m, and actuation at 20 cm.
Barisic et al. (2019)	YOLOv3 Tiny + Discrete Kalman Filter	Visual Servoing (Active pursuit / Following)	N/A (Only pursuit of another UAV)	The bounding box jitters aggressively due to camera/propeller movement.	mAP of 97.88% at 20 FPS; robust tracking even with the target performing figure-eight maneuvers.
Vidal & Casanova (2007)	Window-Matching + Kalman Filter	N/A (Predictive computer vision only)	N/A (Video tracking)	Without the Kalman Filter, the classical algorithm suffers from “camera drift” and loses the target to the image background.	Compensated for visual failures, partial occlusions, and dynamic backgrounds (e.g., bottle in the sea).
Shen et al. (2023)	DS-YOLOv8 (Focus on small/aerial targets)	N/A (Remote detection)	N/A	Performance drops significantly when targets are densely clustered.	mAP of 91.0% and F1-Score of 90.4% on very distant targets.
Zhang et al. (2024)	LCNN-DMT (SqueezeNet + Attention Mechanism)	N/A (Spatial Recognition)	N/A	Initial tendency of the network to fragment the target by drawing multiple separate boxes.	mAP of 97.50%; extremely fast execution in only 6.1 milliseconds (Low-SWaP).
Pramono (2025)	Hybrid Visual Servoing	Model Predictive Control (MPC)	Docking (Autonomous physical coupling)	Mathematical / geometric complexity in handling camera matrices.	Combined the 3D rectilinear trajectory of PBVS without letting the target escape the image edges (IBVS).

Continued on next page

Table 1 – continued from previous page

Author (Year)	Detection and Tracking	Control Technique	Capture Mechanism	Study Limitations	Main Results
Shang et al. (2016)	Low-frequency visual servoing (delayed image)	Cascaded FOPD Controller (Fractional Order)	N/A (Focus on hovering)	Severe processor latency limits maneuvers; classical PID control would not withstand it.	Stabilized flight under absurd image delays (0.58s), maximum deviation of only 58 pixels.
Carvajal et al. (2024)	50Hz Camera (color/sphere tracking)	Sliding-Mode Control (SMC) + Dynamic Compensator	N/A (Ground vehicle tracking)	Strong inertia; the drone would lose the target without the dynamic velocity compensator.	Anticipated acceleration and commands to avoid tracking delays.
Lopez-Franco et al. (2017)	Visual Servoing (Alignment over the target)	Neural PID (adaptive)	N/A (Hover over target)	Classical controllers diverge absurdly (1741 pixels) upon unmodeled disturbances.	Contained the error to 212 pixels even after a surprise 50% increase in UAV weight.

Source: Prepared by the author (2026).

The analysis of related works indicates that autonomous aerial manipulation has shown significant advancements in specific subsystems; however, limitations still exist regarding the integration of these components into complete architectures capable of operating exclusively with real-time onboard perception. Pioneering works, such as that by Thomas et al. [44], have demonstrated the mechanical viability of strategies like perching and underside capture using passive grippers. However, the reliance on external motion capture systems (MOCAP) restricts these solutions to controlled laboratory environments.

Aiming to expand the applicability of these approaches to unstructured and GPS-denied environments, various studies began to explore the use of onboard computer vision based on perception that does not require markers such as ArUco. In this context, the results presented by Bauer et al. [45] and Ubellacker et al. [46] highlight the viability of capturing dynamic targets using exclusively onboard sensors.

Within this scenario, the methods employed for extracting visual information become a central component of the system. Traditional techniques based on natural features present limitations related to computational cost and scalability [38]. Conversely, recent studies indicate the consistent performance of Convolutional Neural Networks in visual detection tasks. The results obtained by Shen et al. [47] and Zhang et al. [48] show that modern architectures can maintain high levels of precision (mAP) with computational costs compatible with onboard applications. Considering the requirements of this project, such evidence supports the choice of the YOLO architecture (v8n/v11n) as the primary detection method, aiming to perform the semantic isolation of the cage at high processing rates without compromising the resources available on the companion computer.

Nevertheless, the literature also indicates that the outputs produced directly by detection models are generally not suitable for immediate use in the control loop. As observed by Barisic et al. [9], visual tracking in UAVs can generate bounding boxes subject to noise and instabilities resulting from structural

vibration and partial occlusions caused by the propellers. In this regard, both the results presented by Barisic et al. [9] and the studies by Vidal and Casanova [35] reinforce the use of state estimation techniques to smooth and predict the observed motion. Thus, in this project, an Extended Kalman Filter (EKF) will be adopted, aiming to reduce oscillations in the pixel coordinates and maintain continuous estimates during temporary losses of tracking.

Finally, regarding dynamic control, studies focused on visual servoing highlight limitations associated with exclusively image-based control (IBVS). Pramono [37] and Carvajal et al. [1] argue that spatial reconstruction for the three-dimensional domain (PBVS) tends to produce more predictable trajectories suitable for approach and docking operations. Furthermore, Shang et al. [4] showed that delays between visual acquisition and inertial measurements can introduce effects that degrade the controller's performance. Therefore, the analyzed works substantiate the architecture proposed in this study, based on the conversion of filtered 2D coordinates into 3D metric coordinates using the Pinhole model, and the subsequent use of this error in a cascaded PD controller, aiming to provide greater stability during the approach and to reduce the effects of delays associated with visual processing.


3

3 METHODOLOGY

A metodologia descreve, de forma clara e detalhada, os procedimentos adotados para o desenvolvimento da pesquisa. É nesta seção que se explica como o estudo foi conduzido, permitindo que outros pesquisadores possam replicar ou compreender os passos realizados.

Devem ser apresentados os seguintes elementos, quando aplicável:

- **Tipo de pesquisa**: definir se é qualitativa, quantitativa ou quali-quantitativa, além de classificar como exploratória, descritiva, explicativa, estudo de caso, pesquisa de campo, bibliográfica, documental, entre outras.
- **Procedimentos metodológicos**: descrever como foi realizado o levantamento de dados, incluindo instrumentos (questionários, entrevistas, observações, análises documentais, softwares, entre outros) e etapas do processo.
- **População e amostra**: identificar o universo da pesquisa, bem como os critérios de seleção da amostra, se houver.
- **Análise dos dados**: indicar quais métodos, técnicas estatísticas ou ferramentas foram utilizados para o tratamento e análise dos dados coletados.
- **Materiais e métodos**: em pesquisas aplicadas ou experimentais, especificar os materiais, equipamentos, ferramentas e procedimentos técnicos utilizados.

A metodologia deve ser apresentada de forma objetiva, precisa e suficientemente detalhada, garantindo a confiabilidade e a possibilidade de reprodução do estudo.



4

4 RESULTS AND DISCUSSION

Esta seção tem como objetivo apresentar, analisar e interpretar os resultados obtidos na pesquisa. Os dados devem ser organizados de forma clara, utilizando tabelas, gráficos, quadros ou figuras, quando necessário, para facilitar a compreensão.

A análise dos resultados deve ser feita de forma crítica, relacionando-os com os objetivos propostos e com o referencial teórico previamente abordado. É fundamental interpretar o significado dos dados, verificando se eles corroboram ou refutam as hipóteses levantadas ou os estudos anteriores consultados.

Nesta etapa, não basta apenas descrever os resultados; é necessário discutir suas implicações, possíveis limitações, e o que eles revelam sobre o problema de pesquisa. A discussão pode ser apresentada juntamente com os resultados ou em um capítulo separado, conforme as normas da instituição ou a natureza do trabalho.

Portanto, esta seção deve responder às seguintes perguntas:

- Quais foram os principais resultados obtidos?
- Como esses resultados se relacionam com os objetivos do trabalho?
- Eles confirmam ou refutam o que foi encontrado na literatura?
- Quais são as possíveis explicações para os achados?
- Existem limitações nos dados ou na metodologia que influenciam os resultados?

A apresentação dos resultados e sua discussão devem ser feitas de maneira clara, objetiva e fundamentada, garantindo coerência com todo o desenvolvimento do trabalho.



5

5 CONCLUSION

A conclusão é a seção final do trabalho, onde o autor retoma os objetivos propostos no início e apresenta as considerações finais com base nos resultados alcançados. Seu papel é responder se o problema de pesquisa foi solucionado e se os objetivos foram atingidos.

Neste capítulo, não se introduzem novos dados, informações ou discussões. O foco está em:

- Retomar brevemente os objetivos do trabalho;
- Apontar se os objetivos foram alcançados;
- Destacar os principais resultados obtidos;
- Apresentar reflexões sobre as limitações do estudo, quando houver;
- Sugerir possíveis desdobramentos, melhorias ou pesquisas futuras sobre o tema.

A conclusão deve ser clara, objetiva e coerente com tudo o que foi desenvolvido ao longo do trabalho, fechando o raciocínio de forma lógica e consistente.



REFERENCES

References

[1] C. P. Carvajal, V. H. Andaluz, J. Varela-Aldás, F. Roberti, C. Del-Valle-Soto, and R. Carelli, "Visual servoing using sliding-mode control with dynamic compensation for uavs' tracking of moving targets," *Drones*, vol. 8, no. 12, p. 730, 12 2024.

[2] I. Abuzayed, A. R. Itani, A. Ahmed, M. Alkharaz, M. A. Jaradat, and L. Romdhane, "Design of lightweight aerial manipulator with a cog compensation mechanism," in *2020 Advances in Science and Engineering Technology International Conferences (ASET)*. IEEE, 2020.

[3] S. Cocuzza and A. Doria, "Modeling and identification of vibrations in a uav for aerial manipulation," *Mechanisms and Machine Science*, vol. 91, pp. 182–190, 2021.

[4] B. Shang, J. Liu, T. Zhao, and Y. Chen, "Fractional order robust visual servoing control of a quadrotor uav with larger sampling period," in *2016 International Conference on Unmanned Aircraft Systems (ICUAS)*. Arlington, VA, USA: IEEE, 6 2016, pp. 1225–1233.

[5] Z. Q. Zhao, P. Zheng, S. T. Xu, and X. Wu, "Object detection with deep learning: A review," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 30, no. 11, pp. 3212–3232, 11 2019.

[6] A. B. Amjoud and M. Amrouch, "Object detection using deep learning, cnns and vision transformers: A review," *IEEE Access*, vol. 11, pp. 35 479–35 516, 2023.

[7] V. Afifah and S. Erniwati, "Yolov8 for object detection: A comprehensive review of advances, techniques, and applications," *IJACI: International Journal of Advanced Computing and Informatics*, vol. 2, no. 1, pp. 53–61, 7 2025.

[8] A. A. Adegun, J. V. Fonou-Dombeu, S. Viriri, and J. Odindi, "Ontology-based deep learning model for object detection and image classification in smart city concepts," *Smart Cities*, vol. 7, no. 4, pp. 2182–2207, 8 2024.

[9] A. Barišić, M. Car, and S. Bogdan, "Vision-based system for a real-time detection and following of uav," in *Proceedings of the 2019 Workshop on Research, Education and Development of Unmanned Aerial Systems (RED UAS)*. Cranfield, UK: IEEE, 11 2019.

[10] B. Thuilot, P. Martinet, L. Cordesses, and J. Gallice, "Position based visual servoing: keeping the object in the field of vision," in *Proceedings of the 2002 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2002.

[11] L. A. Fagundes-Junior, C. M. Soria, R. F. Vassallo, and A. S. Brandão, "Visual control and mapping for uav-based platform inspection," in *Proceedings of the 2025 International Conference on Unmanned Aircraft Systems (ICUAS)*. IEEE, 2025, pp. 542–548.

[12] M. Jiang, "Application of fuzzy pid control in uav control system," in *Proceedings of the 3rd International Conference on Inventive Research in Computing Applications (ICIRCA 2021)*. IEEE, 9 2021, pp. 197–200.

[13] H. Bonyan Khamseh, F. Janabi-Sharifi, and A. Abdessameud, "Aerial manipulation—a literature survey," *Robotics and Autonomous Systems*, vol. 107, pp. 221–235, 9 2018.

[14] X. Meng, Y. He, and J. Han, "Survey on aerial manipulator: System, modeling, and control," *Robotica*, vol. 38, no. 7, pp. 1288–1317, 7 2020.

[15] A. Adriansyah, B. Sulle, and A. Minarso, "Design of ahrs for quadrotor control using digital motion processor," *Journal of Telecommunication, Electronic and Computer Engineering*, vol. 9, no. 1-5, pp. 77–81, 2017.

[16] G. Sciortino *et al.*, “Ros/gazebo-based simulation of quadcopter aircrafts,” in *2018 IEEE RTSI: Research and Technologies for Society and Industry, 4th International Forum*. Palermo, Italy: IEEE, 9 2018.

[17] Stickman Physics, “Drone physics: Pitch, roll, and yaw dynamics,” https://stickmanphysics.com, 2025, acessado em: 05 nov. 2026.

[18] ArduPilot Development Team, “Connect ESCs and motors: Octo Quad frame layout,” https://ardupilot.org/copter/docs/connect-escs-and-motors.html, 2026, acessado em: 05 nov. 2026.

[19] G. Zhang, G. Tong, and P. Chen, “Robust adaptive control of uav,” in *Proceedings of the 33rd Chinese Control and Decision Conference (CCDC)*. IEEE, 2021, pp. 5181–5184.

[20] J. Terven, D. M. Córdova-Esparza, and J. A. Romero-González, “A comprehensive review of yolo architectures in computer vision: from yolov1 to yolov8 and yolo-nas,” *Machine Learning and Knowledge Extraction*, vol. 5, no. 4, pp. 1680–1737, 2023.

[21] X. Zheng, H. Wang, Y. Shang, G. Chen, S. Zou, and Q. Yuan, “Starting from the structure: A review of small object detection based on deep learning,” *Image and Vision Computing*, vol. 146, p. 105054, 4 2024.

[22] A. Rawat, A. Sharma, A. K. Awasthi, A. Sharma, S. S. Tiang, and W. H. Lim, “Review of recent trends in sensing methodologies and ai techniques for non-cooperative aerial target recognition,” *International Journal of Mathematical, Engineering and Management Sciences*, vol. 11, no. 2, pp. 566–611, 4 2026.

[23] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 6 2016, pp. 779–788.

[24] G. Jocher, A. Chaurasia, and J. Qiu, “Ultralytics YOLOv8,” https://github.com/ultralytics/ultralytics, 2023, acessado em: 06 nov. 2026.

[25] Z. Wang, F. Meng, G. Wang, X. Li, and S. Zhang, “Research on classification of chinese herbal medicine pieces based on fusion of yolov8n and hsv,” in *Proceedings of the 2025 4th International Symposium on Robotics, Artificial Intelligence and Information Engineering (RAIIE)*. IEEE, 2025, pp. 72–77.

[26] A. Wang, H. Chen, L. Liu, K. Chen, Z. Lin, J. Han, and G. Ding, “YOLOv10: Real-time end-to-end object detection,” *arXiv preprint arXiv:2405.14458*, 2024.

[27] G. Jocher and J. Qiu, “Ultralytics YOLO11,” https://github.com/ultralytics/ultralytics, 2024, acessado em: 06 nov. 2026.

[28] D. M. Zhexebay, A. A. Skabylov, D. A. Turlykozhayeva, A. Bolysbay, U. K. Turmaganbet, T. Namazbayev, and M. Tao, “Real-time small object detection with yolov8n/8s and yolov11n/11s models in complex natural landscapes,” *Physical Sciences and Technology*, vol. 12, no. 1-2, pp. 142–153, 6 2025.

[29] G. Jocher and J. Qiu, “Ultralytics YOLO26,” https://github.com/ultralytics/ultralytics, 2026, acessado em: 06 nov. 2026.

[30] R. Padilla, W. L. Passos, T. L. B. Dias, S. L. Netto, and E. A. B. da Silva, “A comparative analysis of object detection metrics with a companion open-source toolkit,” *Electronics*, vol. 10, no. 3, p. 279, 2021.

[31] Ultralytics, “YOLO Performance Metrics and Model Evaluation,” https://docs.ultralytics.com/guides/yolo-performance-metrics/, 2024, acessado em: 06 nov. 2026.

[32] M. H. Franco, “Análise comparativa de desempenho entre o filtro de kalman estendido e a fusão madgwick-kalman na navegação inercial de vants,” Joinville, SC, Brasil, 2025.

[33] P. Kim, *Kalman Filter for Beginners: With MATLAB Examples*. CreateSpace Independent Publishing Platform, 2011.

[34] V. Kordic, Ed., *Kalman Filter*. Rijeka, Croatia: InTech, 2010.

[35] F. B. Vidal and V. H. Casanova Alcalde, “Window-matching techniques with kalman filtering for an improved object visual tracking,” in *Proceedings of the IEEE Conference on Automation Science and Engineering (CASE)*, 2007, pp. 829–834.

[36] C. Lopez-Franco, J. Gomez-Avila, A. Y. Alanis, N. Arana-Daniel, and C. Villaseñor, “Visual servoing for an autonomous hexarotor using a neural network based pid controller,” *Sensors*, vol. 17, no. 8, p. 1865, 8 2017.

[37] T. F. Pramono, “Hybrid pbvs-ibvs model predictive visual servoing for autonomous docking of a free-flying robot,” Master’s Thesis, KTH Royal Institute of Technology, Stockholm, Sweden, 2025.

[38] B. Luo, H. Chen, F. Quan, S. Zhang, and Y. Liu, “Natural feature-based visual servoing for grasping target with an aerial manipulator,” *Journal of Bionic Engineering*, vol. 17, no. 2, pp. 215–228, 3 2020.

[39] S. Hutchinson, G. Hager, and P. Corke, “A tutorial introduction to visual servo control,” *IEEE Transactions on Robotics and Automation*, vol. 12, no. 5, pp. 651–670, 1996.

[40] F. Chaumette, S. Hutchinson, and P. Corke, “Visual servoing,” in *Springer handbook of robotics*. Springer, 2016, pp. 841–866.

[41] A. H. A. Hafez, E. Cervera, and C. V. Jawahar, “Stable hybrid visual servo control by a weighted combination of image-based and position-based algorithms,” *International Journal of Control and Automation*, vol. 6, no. 3, pp. 149–164, 2013.

[42] A. Keipour, G. A. S. Pereira, R. Bonatti, R. Garg, P. Rastogi, G. Dubey, and S. Scherer, “Visual servoing approach to autonomous uav landing on a moving vehicle,” *Sensors*, vol. 22, no. 17, p. 6549, 9 2022.

[43] R. Ladig, H. Paul, R. Miyazaki, and K. Shimonomura, “Aerial manipulation using multirotor uav: A review from the aspect of operating space and force,” *Journal of Robotics and Mechatronics*, vol. 33, no. 2, pp. 196–204, 2021.

[44] J. Thomas, G. Loianno, K. Sreenath, and V. Kumar, “Toward image based visual servoing for aerial grasping and perching,” in *Proceedings of the 2014 IEEE International Conference on Robotics and Automation (ICRA)*. Hong Kong, China: IEEE, 2014, pp. 2113–2118.

[45] E. Bauer, B. G. Cangan, and R. K. Katzschmann, “Autonomous marker-less rapid aerial grasping,” in *2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2023.

[46] S. Ubellacker, A. Ray, J. M. Bern, J. Strader, and L. Carlone, “High-speed aerial grasping using a soft drone with onboard perception,” *npj Robotics*, vol. 2, no. 1, p. 5, 8 2024.

[47] L. Shen, B. Lang, and Z. Song, “Ds-yolov8-based object detection method for remote sensing images,” *IEEE Access*, vol. 11, pp. 125 122–125 137, 2023.

[48] Y. Zhang, J. Wang, J. Chen, D. Shi, and X. Chen, “A space non-cooperative target recognition method for multi-satellite cooperative observation systems,” *Remote Sensing*, vol. 16, no. 18, p. 3368, 9 2024.



APPENDICES

Appendix A - Título do apêndice A

Os apêndices são materiais suplementares **elaborados pelo próprio autor**, que contribuem para a compreensão, fundamentação ou detalhamento do trabalho, mas que não são essenciais para o desenvolvimento principal do texto.

Eles podem incluir, por exemplo:

- Questionários e roteiros de entrevistas utilizados na pesquisa;
- Documentos, códigos-fonte, tabelas extensas ou informações complementares;
- Detalhes técnicos ou cálculos que, se inseridos no corpo principal, tornariam a leitura cansativa;
- Materiais que apoiam a metodologia ou os resultados, mas que não são obrigatórios para a compreensão geral.

Cada apêndice deve ser identificado por uma letra maiúscula (Apêndice A, Apêndice B, etc.) e ter um título claro e objetivo. Eles são inseridos após as referências bibliográficas e antes do índice remissivo, se houver.

A inclusão dos apêndices deve ser feita de maneira organizada e referenciada no texto principal, para que o leitor saiba quando e por que consultar esses materiais complementares.

ANNEXES

Annex A - Título do Anexo A

Os anexos são documentos, materiais ou informações que **não foram elaborados pelo autor do trabalho**, mas que servem para complementar, ilustrar ou fundamentar o conteúdo apresentado.

Exemplos comuns de anexos incluem:

- Legislações, normas técnicas ou regulamentos;
- Manuais, folhetos, publicações oficiais;
- Textos, tabelas ou documentos externos que deram suporte à pesquisa;
- Materiais gráficos ou audiovisuais cedidos por terceiros.

Assim como os apêndices, os anexos são organizados em sequência e identificados por letras maiúsculas (Anexo A, Anexo B, etc.), com títulos claros.

Eles são inseridos após os apêndices (quando houver) ou diretamente após as referências bibliográficas, e devem ser referenciados no corpo do trabalho para que o leitor saiba quando consultá-los.



idp

Ensino que
te **conecta**